dữ liệu huấn luyện. Nếu không có dữ liệu và thuật toán học thì không thể xây dựng một chương trình học máy.

1.2. Dữ liệu

Các *nhiệm vụ* trong học máy được mô tả thông qua việc một hệ thống xử lý một điểm dữ liệu đầu vào như thế nào. Một mô hình học máy như một hàm toán học mà đầu vào là dữ liệu, đầu ra là kết quả chúng ta mong muốn hiểu biết về dữ liệu. Một điểm dữ liệu có thể là một bức ảnh, một đoạn âm thanh, một văn bản, hoặc một tập các hành vi của người dùng trên Internet. Để chương trình máy tính có thể học được, các điểm dữ liệu thường được đưa về dạng tập hợp các con số mà mỗi số được gọi là một *đặc trưng*.

Vậy mọi loại dữ liệu đều biểu diễn dưới dạng *vector đặc trưng*, ma trận hay tensor. Vector đặc trưng của một điểm dữ liệu thường được ký hiệu là $\mathbf{x} \in \mathbb{R}^d$ trong đó d là số lượng đặc trưng. Các mảng nhiều chiều được hiểu là đã bị *vector hoá* thành mảng một chiều. Kỹ thuật xây dựng vector đặc trưng cho dữ liệu được trình bày cụ thể hơn trong bài 2.

Kinh nghiệm trong học máy là bộ dữ liệu được sử dụng để xây dựng mô hình. Trong quá trình xây dựng mô hình, bộ dữ liệu thường được chia ra làm ba tập dữ liệu không giao nhau: Tập huấn luyện, tập kiểm tra, và tập xác thực.

Tập huấn luyện (training set) bao gồm các điểm dữ liệu được sử dụng trực tiếp trong việc xây dựng mô hình. *Tập kiểm tra* (test set) gồm các dữ liệu được dùng để đánh giá hiệu quả của mô hình. Để đảm bảo tính phổ quát, dữ liệu kiểm tra không được sử dụng trong quá trình xây dựng mô hình. Điều kiện cần để một mô hình hiệu quả là kết quả đánh giá trên cả tập huấn luyện và tập kiểm tra đều cao. Tập kiểm tra đại diện cho dữ liệu mà mô hình chưa từng thấy, có thể xuất hiện trong quá trình vận hành mô hình trên thực tế.

Để tăng hiệu quả của mô hình trên dữ liệu kiểm tra, người ta thường sử dụng một tập dữ liệu nữa được gọi là *tập xác thực* (validation set). Tập xác thực này được sử dụng trong việc đánh giá sai số kiểm tra và từ đó lựa chọn các siêu tham số mô hình sao cho tốt nhất có thể.

Phép đánh giá P là thước đo quá trình cải thiện tham số mô hình để biết rằng giữa đầu ra mong muốn từ mô hình và thực tế có khớp không. Phép đánh giá thường là sai số và chúng ta cần tối ưu hàm mất mát sao cho sai số nhỏ nhất có thể.

1.3. Các bài toán cơ bản trong học máy

1.3.1. Bài toán phân lớp

Bài toán *Phân lớp* hay phân loại là một trong những bài toán được nghiên cứu nhiều nhất trong học máy. Trong bài toán này, chương trình được yêu cầu xác định *lớp/nhãn* của một điểm dữ liệu trong số C nhãn khác nhau. Cặp (dữ liệu, nhãn) được ký hiệu là $(\mathbf{x}, y)$ với y nhận một trong C giá trị trong tập đích $\mathcal{Y}$. Việc xây dựng mô hình tương đương với việc đi tìm hàm số f ánh xạ một điểm dữ liệu $\mathbf{x}$ vào một phần tử $y \in \mathcal{Y} : y = f(\mathbf{x})$ trên tập dữ liệu huấn luyện đã biết sao cho sau đó mô hình được áp dụng trên các dữ liệu mới với sai số chấp nhận được. Khi đó ta xác định được nhãn của dữ liệu mới.

Ví dụ: Bài toán xác định email rác là một bài toán phân lớp trong học máy . Trong đó,

- Nhiệm vụ T là xác một email mới trong hộp thư đến là email rác hay không.
- Phép đánh giá P có thể định nghĩa là tỉ lệ email rác được xác định theo mô hình và đúng là email rác trong thực tế.
- Kinh nghiệm E là cặp các (email, nhãn) thu thập được trước đó. Dữ liệu này dùng để huấn luyện mô hình, tìm ra hàm $f(\mathbf{x})$.

Có một biến thể nhỏ ở đầu ra của hàm số $f(\mathbf{x})$ khi đầu ra không phải là một số mà là một vector $\mathbf{y} \in \mathbb{R}^C$ trong đó $y\mathbf{y} = (y_1, y_2, ..., y_c, ...y_C)$ và y_c là xác suất để điểm dữ liệu $\mathbf{x}$ rơi vào lớp thứ c. Lớp được chọn cuối cùng là lớp có xác suất rơi vào là cao nhất. Việc sử dụng xác suất này đôi khi rất quan trọng, nó giúp chỉ ra *độ chắc chắn* của mô hình. Nếu xác suất cao nhất là cao hơn nhiều so với các xác suất còn lại, ta nói mô hình có độ chắn chắn là cao khi phân lớp điểm dữ liệu $\mathbf{x}$. Ngược lại, nếu độ chênh lệch giữa xác suất cao nhất và các xác suất tiếp theo là nhỏ, thì khả năng mô hình đã phân loại nhầm là cao hơn. Hồi quy logistic là một ví dụ về phân lớp sử dụng xác suất.

1.3.2. Bài toán hồi quy

Nếu tập đích $\mathcal{Y}$ gồm các giá trị là các số thực thì bài toán được gọi là *hồi quy*. Trong bài toán này, ta cần xây dựng một hàm số $f : \mathbb{R}^d \to \mathbb{R}$, ánh xạ mỗi véc tơ dữ liệu với nhãn $y \in \mathcal{Y}$, đầu ra mong muốn dự đoán.

Ví dụ: Ước lượng giá của một căn nhà rộng x m^2, có y phòng ngủ và cách trung tâm thành phố z km. Ta mong muốn xây dựng hàm dự đoán dạng $f : \mathbb{R}^3 \to \mathbb{R}$, với giá $= f(x, y, z)$.

Bài toán hồi quy có thể mở rộng ra việc dự đoán nhiều đầu ra cùng một lúc, khi đó, hàm cần tìm sẽ là $f : \mathbb{R}^d \to \mathbb{R}^m$. Một ví dụ là bài toán tạo ảnh độ phân giải cao từ một ảnh có độ phân giải thấp hơn. Khi đó, việc dự đoán giá trị các điểm trong ảnh đầu ra là một bài toán hồi quy nhiều đầu ra.

1.3.3. Bài toán máy dịch

Trong bài toán *máy dịch*, chương trình máy tính được yêu cầu dịch một đoạn văn từ một ngôn ngữ sang một ngôn ngữ khác. Dữ liệu huấn luyện là các cặp văn bản song ngữ. Các văn bản này có thể chỉ gồm hai ngôn ngữ đang xét hoặc có thêm các ngôn ngữ trung gian.

Ví dụ: Google translate là một ứng dụng (với nhiều kỹ thuật học sâu khác được áp dụng) học máy trong lĩnh vực máy dịch.

1.3.4. Bài toán phân cụm

Bài toán phân cụm là bài toán chia tập dữ liệu $\mathcal{X}$ thành các cụm nhỏ dựa trên sự liên quan nào đó giữa các dữ liệu trong mỗi cụm. Trong bài toán này, dữ liệu huấn luyện không có nhãn, mô hình tự phân chia dữ liệu thành các cụm khác nhau dựa vào độ đo sự gần gũi của các đặc trưng dữ liệu.

Ví dụ: Phân cụm khách hàng dựa trên hành vi mua hàng. Dựa trên việc mua bán và theo dõi của người dùng trên một trang web thương mại điện tử, mô hình có thể phân người dùng vào các cụm theo sở thích mua hàng. Từ đó, mô hình có thể quảng cáo các mặt hàng mà người dùng có thể quan tâm trên cơ sở những mặt hàng này người cùng nhóm đã mua, đã quan tâm. Những đặc trưng của khách hàng cũng cần được véc tơ hóa và sự gần gũi về sở thích mua hàng được tính toán thông qua một độ đo.

1.3.5. Bài toán hoàn thiện dữ liệu

Bài toán hoàn thiện dữ liệu là bài toán dự đoán các trường dữ liệu còn thiếu trong dữ liệu đích. Nhiệm vụ của bài toán này là dựa trên mối tương quan giữa các điểm dữ liệu để dự đoán những giá trị còn thiếu. Các hệ thống khuyến nghị là một ví dụ điển hình của loại bài toán này. Hệ thống sẽ dự đoán sự quan tâm của các đối tượng (user) thể hiện bằng các thang điểm, số sao đánh giá mà họ chưa đánh giá các mặt hàng (item), dựa trên mối tương quan giữa các user với nhau hoặc các item với nhau. Các phần mềm khôi phục ảnh cũ, tô màu ảnh cũ sử dụng học máy cũng là những ứng dụng thuộc phạm vi hoàn thiện dữ liệu.

Ngoài ra, có nhiều bài toán học máy khác như *bài toán xếp hạng*, *bài toán giảm chiều dữ liệu*, *bài toán phát hiện bất thường*....tùy thuộc vào yêu cầu đầu ra, dữ liệu chúng ta có và khả năng giải quyết của thuật toán.

1.4. Các thuật toán học máy

Phân nhóm dựa theo phương thức học có các loại thuật toán học máy sau:

1.4.1. Học có giám sát

Một thuật toán học máy được gọi là *học có giám sát* nếu việc xây dựng mô hình dự đoán mối quan hệ giữa đầu vào và đầu ra được thực hiện dựa trên các cặp (đầu vào, đầu ra) đã biết trong tập huấn luyện. Nghĩa là dữ liệu huấn luyện đã có nhãn, là đầu ra mong muốn.

Các thuật toán phân lớp và hồi quy là hai ví dụ điển hình trong nhóm này.

Diễn giải theo toán học, học có giám sát xảy ra khi việc dự đoán quan hệ giữa đầu ra $\mathbf{y}$ và dữ liệu đầu vào $\mathbf{x}$ được thực hiện dựa trên các cặp $\{(\mathbf{x}_1, \mathbf{y}_1), (\mathbf{x}_2, \mathbf{y}_2), \ldots, (\mathbf{x}_N, \mathbf{y}_N)\}$ trong tập huấn luyện. Việc huấn luyện là việc xây dựng một hàm số f sao cho với mọi $i = 1, 2, \ldots, N$, $f(\mathbf{x}_i)$ gần với $\mathbf{y}_i$ nhất có thể. Hơn thế nữa, khi có một điểm dữ liệu $\mathbf{x}$ nằm ngoài tập huấn luyện, đầu ra dự đoán $f(\mathbf{x})$ cũng gần với đầu ra thực sự $\mathbf{y}$.

1.4.2. Học không giám sát

Trong các thuật toán học không giám sát, dữ liệu huấn luyện chỉ bao gồm các dữ liệu đầu vào $\mathbf{x}$ mà không có đầu ra tương ứng. Các thuật toán học máy có thể không dự đoán được đầu ra nhưng vẫn trích xuất được những thông tin quan trọng dựa trên mối liên quan giữa các điểm dữ liệu.

Các thuật toán giải quyết bài toán phân cụm và giảm chiều dữ liệu là các ví dụ điển hình của nhóm này. Trong bài toán phân cụm, có thể mô hình không trực tiếp dự đoán được đầu ra của dữ liệu nhưng vẫn có khả năng phân các điểm dữ liệu có đặc tính gần giống nhau vào từng nhóm.

1.4.3. Học bán giám sát

Thuật toán học bán giám sát là nhóm thuật toán học máy mà tập huấn luyện bao gồm các cặp (đầu vào, đầu ra) và dữ liệu khác chỉ có đầu vào, nghĩa là chứa cả dữ liệu có nhãn và không có nhãn trong tập huấn luyện.

Thực tế cho thấy ngày càng nhiều thuật toán rơi vào nhóm này vì việc thu thập nhãn cho dữ liệu có chi phí cao và tốn thời gian. Chẳng hạn, chỉ một phần nhỏ trong các bức ảnh y học có nhãn vì quá trình gán nhãn tốn thời gian và cần sự can thiệp của các chuyên gia.

1.4.4. Học củng cố

Mô hình học cách ra quyết định bằng cách giao tiếp với môi trường xung quanh. Các thuật toán thuộc nhóm này liên tục ra quyết định và nhận phản hồi từ môi trường để tự củng cố hành vi. Nhóm các thuật toán này có tên *học củng cố*.Chúng có thể không yêu cầu dữ liệu huấn luyện.

Việc huấn luyện một thuật toán học củng cố thông thường dựa trên một đại lượng được gọi là *điểm thưởng*. Mô hình cần tìm ra một thuật toán tối đa điểm thưởng đó qua rất nhiều lần chơi khác nhau. Học củng cố được áp dụng nhiều trong việc tạo ra các chương trình máy tính có khả năng tự chơi cờ, tự chơi game hay xe tự lái.

Ngoài ra còn có những cách thức phân loại khác như: Học dựa trên mẫu hay học dựa trên mô hình; Học theo batch hay học trực tuyến...

1.5. Hàm mất mát và tham số mô hình

Mỗi mô hình học máy được mô tả bởi bộ *các tham số mô hình*. Công việc của một thuật toán học máy là đi tìm các tham số mô hình tối ưu cho mỗi bài toán, nghĩa là đạt được tốt nhất theo phép đánh giá P. Việc đi tìm các tham số mô hình có liên quan mật thiết đến các phép đánh giá. Mục đích chính là đi tìm các tham số mô hình sao cho các phép đánh giá đạt kết quả tốt nhất. Trong bài toán phân loại, kết quả tốt có thể được hiểu là có ít điểm dữ liệu bị phân loại sai. Trong bài toán hồi quy, kết quả tốt là khi sự sai lệch giữa đầu ra dự đoán và đầu ra thực sự là nhỏ.

Quan hệ giữa một phép đánh giá và các tham số mô hình được mô tả thông qua một hàm số gọi là *hàm mất mát*. Hàm số này thường có giá trị nhỏ khi phép đánh giá cho kết quả tốt và ngược lại. Việc đi tìm các tham số mô hình sao cho phép đánh giá trả về kết quả tốt tương đương với việc tối thiểu hàm mất mát. Như vậy, việc xây dựng một mô hình học máy chính là việc đi giải một bài toán tối ưu. Quá trình đó được coi là quá trình *học* của *máy*.

Tập hợp các tham số mô hình thường được ký hiệu bằng θ, hàm mất mát của mô hình được ký hiệu là $\mathcal{L}(\theta)$ hoặc $J(\theta)$. Bài toán đi tìm tham số mô hình tương đương với bài toán tối thiểu hàm mất mát:

$$\theta^* = \underset{\theta}{\operatorname{argmin}}\, \mathcal{L}(\theta). \tag{1.1}$$

Trong đó, ký hiệu $\underset{\theta}{\operatorname{argmin}}\, \mathcal{L}(\theta)$ được hiểu là giá trị của θ để hàm số $\mathcal{L}(\theta)$ đạt giá trị nhỏ nhất, cần phân biệt với giá trị nhỏ nhất của $L(\theta)$, là giá trị mà ta ít quan tâm.

Sai số huấn luyện: Đại lượng này là mức độ sai khác giữa đầu ra thực và đầu ra dự đoán của mô hình. Trong nhiều trường hợp, giá trị này chính là hàm mất mát khi áp dụng lên dữ liệu huấn luyện. Hàm mất mát này cần có một thừa số $\frac{1}{N_{\text{hl}}}$, trong đó N_{hl} là số điểm dữ liệu huấn luyện, để tính giá trị trung bình mất mát trên mỗi điểm dữ liệu. Với các bài toán hồi quy, đại lượng này thường được xác định bởi *sai số trung bình bình phương*:

$$\text{sai số huấn luyện} = \frac{1}{2N_{\text{hl}}} \sum_{\text{tập huấn luyện}} \|\mathbf{y} - \hat{\mathbf{y}}\|_2^2 \tag{1.2}$$

với $\|\mathbf{y} - \hat{\mathbf{y}}\|_2^2$ là chuẩn Euclid của véc tơ. Với các bài toán phân loại, có nhiều cách đánh giá mô hình trên các tập dữ liệu. Chúng ta sẽ dần thấy trong các chương, bài sau.

Sai số kiểm tra: Tương tự như trên, áp dụng mô hình tìm được vào dữ liệu kiểm tra. Chú ý rằng dữ liệu kiểm tra không được sử dụng khi xây dựng mô hình. Với các mô hình hồi quy, đại lượng này thường được định nghĩa bởi

$$\text{sai số kiểm tra} = \frac{1}{2N_{\text{kt}}} \sum_{\text{tập kiểm tra}} \|\mathbf{y} - \hat{\mathbf{y}}\|_2^2 \tag{1.3}$$

Việc lấy trung bình là quan trọng vì lượng dữ liệu trong tập huấn luyện và tập kiểm tra có thể chênh lệch nhau.

1.6. Những thách thức chính của học máy

Vì nhiệm vụ chính của học máy là chọn và huấn luyện một thuật toán trên một tập dữ liệu, nên hai vấn đề có thể xảy ra là thuật toán tệ và dữ liệu xấu. Các thách thức chính đến từ đây.

1.6.1. Các thách thức đến từ dữ liệu xấu

Không đủ dữ liệu huấn luyện. Hầu hết các thuật toán Học Máy cần rất nhiều dữ liệu để có thể hoạt động hiệu quả. Ngay cả với những bài toán đơn giản, ta cũng cần đến hàng nghìn mẫu, và với những bài toán phức tạp như nhận diện ảnh hoặc giọng nói thì có thể lên đến hàng triệu mẫu (trừ khi ta có thể tận dụng một mô hình có sẵn).

Dữ liệu huấn luyện không mang tính đại diện. Để khái quát hóa tốt, điều quan trọng là dữ liệu huấn luyện phải có tính đại diện cho các trường hợp mới mà ta muốn khái quát hóa. Điều này đúng cho cả phương pháp học dựa trên mẫu hay học dựa trên mô hình.

Dữ liệu kém chất lượng. Nếu tập huấn luyện chứa đầy lỗi, điểm ngoại lai và nhiễu (chẳng hạn như do sai số đo lường), hệ thống sẽ gặp nhiều khó khăn trong việc

phát hiện các khuôn mẫu ẩn, và ít có khả năng hoạt động tốt. Việc dành thời gian làm sạch dữ liệu huấn luyện thường rất cần thiết. Sự thật là đa số các nhà khoa học dữ liệu dành phần lớn thời gian của họ chỉ để làm việc đó. Những ví dụ sau đây là các trường hợp mà ta cần làm sạch dữ liệu huấn luyện:

- Nếu một số mẫu rõ ràng là ngoại lai, ta có thể đơn thuần loại bỏ chúng hoặc sửa lỗi một cách thủ công.
- Với những mẫu bị thiếu một số đặc trưng (ví dụ: 5% khách hàng của bạn không cung cấp tuổi của họ), ta cần quyết định giữa việc bỏ qua luôn thuộc tính này, bỏ qua những mẫu bị thiếu, điền vào các giá trị còn thiếu (ví dụ, bằng tuổi trung vị), hoặc huấn luyện hai mô hình: một mô hình với đặc trưng đó và một mô hình thì không.

Các đặc trưng không liên quan. Hệ thống chỉ có thể học được nếu dữ liệu huấn luyện chứa đủ các đặc trưng liên quan và không quá nhiều các đặc trưng không liên quan. Một phần quan trọng dẫn đến một dự án Học Máy thành công là xây dựng được một bộ đặc trưng tốt để huấn luyện. Quy trình này được gọi là thiết kế đặc trưng và bao gồm các bước sau:

- Lựa chọn đặc trưng (lựa chọn những đặc trưng hữu ích nhất từ các đặc trưng sẵn có để huấn luyện)
- Trích xuất đặc trưng (kết hợp các đặc trưng sẵn có để tạo ra một đặc trưng hữu ích hơn, và như đã đề cập phía trên, các thuật toán giảm chiều có thể có ích)
- Tạo ra các đặc trưng mới bằng cách thu thập thêm dữ liệu

1.6.2. Các thách thức đến từ thuật toán tệ

Quá khớp dữ liệu huấn luyện. Trong học máy, khái niệm quá khớp có nghĩa là mô hình hoạt động tốt trên dữ liệu huấn luyện nhưng lại không có tính khái quát hóa. Quá khớp xảy ra khi mô hình quá phức tạp so với lượng mẫu và nhiễu của dữ liệu huấn luyện. Đây là những giải pháp để tránh vấn đề này:

- Đơn giản hóa mô hình bằng cách chọn mô hình có ít tham số hơn (ví dụ, một mô hình tuyến tính thay vì mô hình đa thức bậc cao), giảm số lượng thuộc tính trong dữ liệu huấn luyện, hoặc ràng buộc mô hình.
- Thu thập thêm dữ liệu huấn luyện.
- Giảm nhiễu trong dữ liệu huấn luyện (ví dụ như chỉnh sửa lỗi sai trong dữ liệu và loại bỏ những mẫu ngoại lai).

Việc ràng buộc một mô hình để làm cho nó đơn giản hơn và giảm nguy cơ quá khớp được gọi là *điều chuẩn*. Mức độ điều chuẩn áp dụng trong quá trình học có thể được kiểm soát bởi một siêu tham số. Một siêu tham số là một tham số của thuật toán chứ không phải của mô hình. Vì vậy, nó không bị ảnh hưởng bởi quá trình học. Giá trị của siêu tham số cần được đặt trước khi huấn luyện và sẽ được giữ nguyên trong suốt quá trình huấn luyện. Nếu ta đặt siêu tham số điều chuẩn quá cao, ta sẽ nhận được một mô hình gần như nằm ngang. Khi đó, thuật toán gần như chắc chắn sẽ không quá khớp dữ liệu huấn luyện, nhưng sẽ khó để tìm được một mô hình tốt. Điều chỉnh siêu tham số là một phần quan trọng trong quá trình xây dựng một hệ thống Học Máy.

Dưới khớp dữ liệu huấn luyện. Dưới khớp ngược lại với quá khớp: nó xảy ra khi mô hình quá đơn giản để học được cấu trúc của dữ liệu. Đây là những giải pháp chính để giải quyết vấn đề này:

- Chọn một mô hình mạnh hơn, với nhiều tham số hơn.
- Cung cấp đặc trưng tốt hơn cho thuật toán học (thiết kế đặc trưng).
- Giảm ràng buộc lên mô hình (ví dụ như giảm siêu tham số điều chuẩn).

1.7. Quy trình thực hiện một dự án học máy

Danh mục các công việc trong một dự án học máy bao gồm các bước sau:

a. Định hình bài toán và xem xét bức tranh tổng thể.

b. Thu thập dữ liệu.

c. Khám phá dữ liệu để có được thông tin chi tiết.

d. Chuẩn bị dữ liệu để tạo ra những các dữ liệu đầu vào phù hợp cho các thuật toán Học Máy.

e. Khám phá các mô hình học máy khác nhau và chọn ra những mô hình tốt nhất.

f. Tinh chỉnh các mô hình và kết hợp chúng lại thành một giải pháp hoàn hảo hơn.

g. Trình bày giải pháp.

h. Khởi chạy, giám sát, và bảo trì hệ thống.

Trong đó, mỗi bước trong quy trình lại có thể gợi ý các công việc thực hiện chi tiết như sau:

1.7.1. Định hình bài toán và xem xét bức tranh tổng thể

- Xác định mục tiêu theo phương diện kinh doanh.
- Giải pháp sẽ được sử dụng như thế nào?
- Các giải pháp hiện tại (nếu có) là gì?
- Định hình bài toán này như thế nào (có giám sát/không giám sát, trực tuyến/ngoại tuyến, v.v.)?
- Chất lượng của giải pháp sẽ được đo lường như thế nào?
- Thước đo chất lượng này có phù hợp với mục tiêu kinh doanh không?
- Chất lượng mô hình tối thiểu cần thiết để đạt được mục tiêu kinh doanh là bao nhiêu?
- Các bài toán tương tự là gì? Có thể sử dụng lại kinh nghiệm hoặc công cụ có sẵn được không?
- Yếu tố kiến thức chuyên môn có cần thiết không?
- Sẽ giải quyết bài toán theo cách thủ công như thế nào?
- Liệt kê những giả định đã đưa ra cho đến thời điểm hiện tại.
- Kiểm chứng các giả định nếu có thể.

1.7.2. Thu thập dữ liệu

Hãy tự động hóa càng nhiều càng tốt để có thể thu thập được dữ liệu mới một cách dễ dàng.

- Liệt kê loại dữ liệu và số lượng cần thiết.
- Tìm và ghi lại nơi có thể thu thập được dữ liệu đó.
- Kiểm tra xem dữ liệu sẽ chiếm bao nhiêu dung lượng.
- Kiểm tra các nghĩa vụ pháp lý và xin quyền sử dụng nếu cần.

- Xin quyền truy cập.
- Tạo một môi trường làm việc (có đủ dung lượng lưu trữ).
- Thu thập dữ liệu.
- Chuyển đổi dữ liệu thành định dạng có thể dễ dàng thao tác (mà không làm thay ổi thông tin dữ liệu).
- Đảm bảo các thông tin nhạy cảm phải được bảo vệ hoặc xóa bỏ (ví dụ, dạng ẩn danh).
- Kiểm tra kích thước và dạng dữ liệu (dạng chuỗi thời gian, mẫu, không gian địa lý, v.v.).
- Lấy mẫu để tạo tập dữ liệu kiểm tra, để nó sang một bên và không sử dụng trong quá trình huấn luyện.

1.7.3. Khám phá dữ liệu

Hãy cố gắng nhờ một chuyên gia trong ngành để hiểu rõ hơn về dữ liệu khi thực hiện các bước này.

- Tạo một bản sao dữ liệu dành cho việc khám phá (lấy mẫu với kích thước nhỏ hơn để có thể xử lý dễ dàng nếu cần).
- Tạo một Jupyter notebook để ghi lại quá trình khám phá dữ liệu.
- Nghiên cứu từng thuộc tính và đặc điểm của nó:
  - Tên
  - Dạng dữ liệu (dạng hạng mục, dạng số nguyên/số thực, dạng bị chặn/không bị chặn, dạng văn bản, dạng có cấu trúc, v.v.)
  - Phần trăm của những giá trị bị thiếu
  - Độ nhiễu và dạng nhiễu (ngẫu nhiên, ngoại lai, lỗi làm tròn số, v.v.)
  - Tính hữu ích cho tác vụ
  - Dạng phân phối của dữ liệu (Gauss, đều, logarit, v.v.)
- Đối với các tác vụ học có giám sát, hãy xác định (các) thuộc tính mục tiêu.

- Trực quan hóa dữ liệu.
- Nghiên cứu mối tương quan giữa các thuộc tính.
- Nghiên cứu cách bạn sẽ giải quyết bài toán theo cách thủ công.
- Xác định các phép biến đổi tiềm năng có thể áp dụng.
- Xác định dữ liệu bổ sung hữu ích (quay lại bước Thu thập Dữ liệu).
- Ghi lại những gì đã học được.

1.7.4. Chuẩn bị dữ liệu

Làm việc trên các bản sao của dữ liệu thay vì tập dữ liệu gốc (giữ nguyên tập dữ liệu gốc). Viết hàm cho tất cả các phép biến đổi dữ liệu, vì năm lý do sau:

- *Dễ dàng hơn trong việc chuẩn bị dữ liệu trong lần tiếp theo khi bạn có một tập dữ liệu mới*
- *Có thể sử dụng các phép biến đổi này trong những dự án tương lai*
- *Làm sạch và chuẩn bị tập kiểm tra*
- *Làm sạch và chuẩn bị các mẫu dữ liệu mới khi giải pháp được triển khai*
- *Dễ dàng để coi các lựa chọn trong việc chuẩn bị dữ liệu như các siêu tham số*

a. Làm sạch dữ liệu

- Sửa hoặc loại bỏ các điểm ngoại lai (không bắt buộc).
- Điền vào các giá trị còn thiếu (ví dụ với 0, trung bình, trung vị, v.v.) hoặc loại bỏ hàng (hoặc cột) chứa các giá trị đó.

b. Lựa chọn đặc trưng (không bắt buộc):

- Loại bỏ các thuộc tính không hữu ích cho tác vụ.

c. Thiết kế đặc trưng, nếu thích hợp:

- Biến các đặc trưng liên tục thành rời rạc.
- Phân tách các đặc trưng (ví dụ như hạng mục, thời gian, v.v..)
- Thêm các phép biến đổi đặc trưng tiềm năng.
- Tổng hợp các đặc trưng thành đặc trưng mới tiềm năng.

d. Co giãn đặc trưng:

- Chuẩn hóa các đặc trưng.

1.7.5. Rút gọn danh sách các mô hình tiềm năng

- *Nếu tập dữ liệu lớn, có thể lấy mẫu các tập huấn luyện nhỏ hơn để huấn luyện nhiều mô hình khác nhau trong một khoảng thời gian hợp lý (lưu ý rằng phương pháp này không hiệu quả với những mô hình phức tạp như các mạng nơ-ron lớn hoặc Rừng Ngẫu nhiên).*
- *Hãy cố gắng tự động hóa các bước này nhiều nhất có thể.*

- Huấn luyện nhiều loại mô hình đơn giản khác nhau (ví dụ như tuyến tính, naive Bayes, SVM, Rừng Ngẫu nhiên, Mạng nơ-ron, v.v..) sử dụng các tham số tiêu chuẩn.
- Đo lường và so sánh chất lượng của chúng. Với mỗi mô hình, sử dụng kiểm định N-fold, tính trung bình và độ lệch chuẩn của chất lượng mô hình trên N fold.
- Phân tích những biến quan trọng nhất của từng thuật toán.
- Phân tích những loại lỗi mà các mô hình gặp phải.
- Thực hiện nhanh một lượt lựa chọn và thiết kế đặc trưng.
- Thực hiện nhanh một hoặc hai lượt cả năm bước ở trên.
- Tạo danh sách rút gọn từ ba tới năm mô hình có tiềm năng nhất, ưu tiên các mô hình có các loại lỗi khác nhau.

1.7.6. Tinh chỉnh hệ thống

Nên sử dụng càng nhiều dữ liệu càng tốt tại bước này, đặc biệt là trong giai đoạn cuối của quá trình tinh chỉnh. Cố gắng tự động hóa càng nhiều càng tốt.

- Tinh chỉnh các siêu tham số sử dụng kiểm định chéo.
- Thử các phương pháp Ensemble. Kết hợp các mô hình tốt nhất thường sẽ cho kết quả tốt hơn so với từng mô hình riêng biệt.

- Khi đã tự tin với mô hình cuối cùng, hãy đo lường chất lượng trên tập kiểm tra để ước lượng lỗi tổng quát hóa. Đừng tinh chỉnh mô hình sau khi đo lường lỗi tổng quát hóa, sẽ bắt đầu bị quá khớp tập kiểm tra.

1.7.7. Trình bày giải pháp

- Ghi chép lại những gì đã làm.
- Thực hiện một bài thuyết trình hay.
- Giải thích tại sao giải pháp đưa ra đạt được mục tiêu kinh doanh.
- Trình bày những điểm thú vị của hệ thống. Mô tả những thứ hoạt động và không hoạt động. Liệt kê các giả định cũng như các hạn chế của hệ thống.
- Đảm bảo những phát hiện chính được truyền đạt bằng trực quan đẹp mắt và phát biểu dễ nhớ.

1.7.8. Triển khai

- Chuẩn bị để triển khai giải pháp (đưa dữ liệu đầu vào vào hệ thống, viết unit test, v.v..).
- Viết mã giám sát để kiểm tra định kỳ chất lượng của hệ thống trong quá trình hoạt động và kích hoạt cảnh bảo khi chất lượng đi xuống.
- Huấn luyện lại các mô hình theo định kỳ với dữ liệu mới (tự động hóa nhiều nhất có thể).

1.8. Câu hỏi ôn tập bài 1

Câu 1: Học máy là gì? Kể tên một số ứng dụng học máy cơ bản mà em biết.

Câu 2: Phân biệt các nhóm thuật toán học có giám sát, không giám sát?

Câu 3: Hàm mất mát là gì? Phân biệt tham số mô hình và siêu tham số?

Câu 4: Các thách thức đến từ dữ liệu có thể là gì trong quá trình thực hiện dự án học máy?

Câu 5: Thuật toán bị quá khớp là thế nào? Các giải pháp tránh quá khớp?

Câu 6: Quy trình cơ bản của một dự án học máy bao gồm các bước nào?

Bài 2

Các kỹ thuật xây dựng đặc trưng

Mục tiêu

Nắm được các thao tác tiền xử lý dữ liệu cơ bản

- *Dữ liệu được biểu diễn như thế nào?*
- *Mô hình, các pha huấn luyện, kiểm tra*
- *Các kỹ thuật trích chọn đặc trưng*
- *Các phương pháp chuẩn hóa dữ liệu thường dùng.*

2.1. Giới thiệu

Mỗi điểm dữ liệu trong một mô hình học máy thường được biểu diễn bằng một vector được gọi là *vector đặc trưng*. Trong cùng một mô hình, các vector đặc trưng của các điểm thường có kích thước như nhau. Điều này là cần thiết vì các mô hình bao gồm các phép toán với ma trận và vector, các phép toán này yêu cầu dữ liệu có chiều phù hợp để có thể thực hiện được. Tuy nhiên, dữ liệu thực tế thường ở dạng thô với kích thước khác nhau hoặc kích thước như nhau nhưng số chiều quá lớn gây trở ngại trong việc lưu trữ. Vì vậy, việc lựa chọn, tính toán đặc trưng phù hợp cho mỗi bài toán là một bước quan trọng.

Khi làm việc với các bài toán học máy , nhìn chung ta chỉ có được dữ liệu thô chưa qua chỉnh sửa và chọn lọc. Ngoài ra, ta có thể phải loại bỏ những dữ liệu nhiễu và đưa dữ liệu thô với kích thước khác nhau về cùng một chuẩn. Dữ liệu chuẩn này phải đảm bảo giữ được những thông tin đặc trưng của dữ liệu thô ban đầu. Không những thế, ta cần thiết kế những phép biến đổi để có những đặc trưng phù hợp cho từng bài toán. Quá trình quan trọng này được gọi là *trích chọn đặc trưng*.