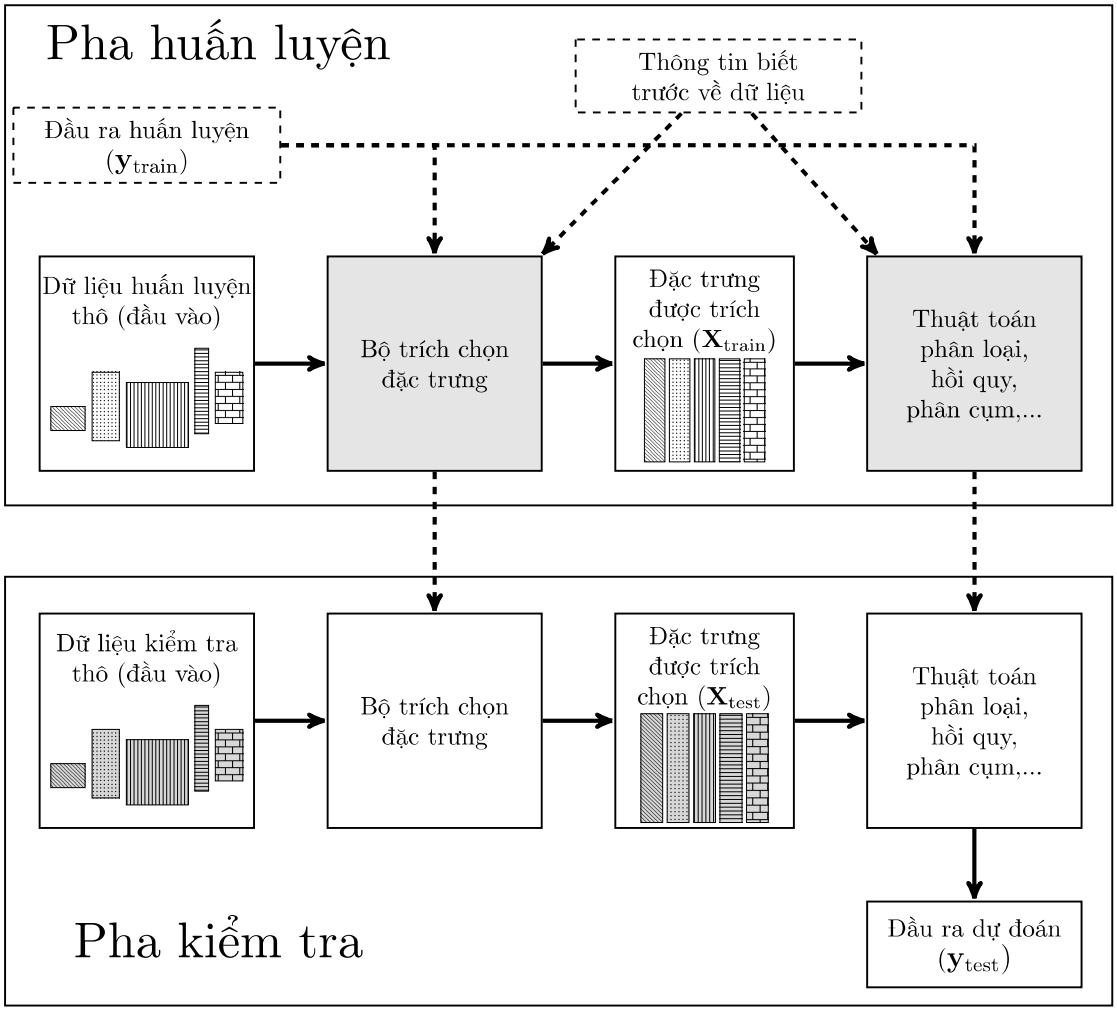

Hình 2.1. Mô hình chung trong các bài toán học máy

Để có cái nhìn tổng quan, chúng ta cần đặt bước trích chọn đặc trưng này trong cả quy trình xây dựng một mô hình học máy .

2.2. Mô hình chung cho các bài toán học máy

Phần lớn các mô hình học máy có thể được minh hoạ trong Hình 2.1. Có hai pha lớn trong mỗi bài toán học máy là *pha huấn luyện* và *pha kiểm tra*. Pha huấn luyện xây dựng mô hình dựa trên dữ liệu huấn luyện. Dữ liệu kiểm tra được sử dụng để đánh giá hiệu quả mô hình.

2.2.1. Pha huấn luyện

Có hai khối cần được thiết kế: Bộ trích chọn đặc trưng và Lựa chọn thuật toán huấn luyện.

Khối trích chọn đặc trưng có nhiệm vụ tạo ra một vector đặc trưng cho mỗi điểm dữ liệu đầu vào. Vector đặc trưng này thường có kích thước như nhau, bất kể dữ liệu đầu vào có kích thước như thế nào.

Đầu vào của khối trích chọn đặc trưng có thể là các yếu tố sau:

- *Dữ liệu huấn luyện đầu vào ở dạng thô* bao gồm tất cả các thông tin ban đầu. Ví dụ, dữ liệu thô của một ảnh là giá trị của từng điểm ảnh, của một văn bản là từng từ, từng câu; của một file âm thanh là một đoạn tín hiệu; của thời tiết là thông tin về hướng gió, nhiệt độ, độ ẩm không khí,... Dữ liệu thô này thường không ở dạng vector, không có số chiều như nhau hoặc một vài thông tin bị khuyết. Thậm chí chúng có thể có số chiều như nhau nhưng rất lớn.

- *Dữ liệu huấn luyện đầu ra*: dữ liệu này có thể được sử dụng hoặc không. Trong các thuật toán học không giám sát, ta không biết đầu ra nên hiển nhiên không có giá trị này. Trong các thuật toán học có giám sát, đôi khi dữ liệu này cũng không được sử dụng. Ví dụ, việc giảm chiều dữ liệu có thể không cần sử dụng dữ liệu đầu ra. Nếu dữ liệu đầu vào đã là các vector cột cùng chiều, ta chỉ cần nhân vào bên phải của chúng một ma trận chiếu ngẫu nhiên. Ma trận này có số hàng ít hơn số cột để đảm bảo số chiều thu được nhỏ hơn số chiều ban đầu. Việc làm này mặc dù làm mất đi thông tin, trong nhiều trường hợp vẫn mang lại hiệu quả vì đã giảm được lượng tính toán ở phần sau. Đôi khi ma trận chiếu không phải là ngẫu nhiên mà có thể được *học* dựa trên toàn bộ dữ liệu thô ban đầu.

  Trong nhiều trường hợp khác, dữ liệu đầu ra của tập huấn luyện cũng được sử dụng để tạo bộ trích chọn đặc trưng. Việc giữ lại nhiều thông tin không quan trọng bằng việc giữ lại các thông tin có ích.

- *Các thông tin biết trước về dữ liệu*: Ngoài dữ liệu huấn luyện, các thông tin biết trước ngoài lề cũng có tác dụng trong việc xây dựng bộ trích chọn đặc trưng. Chẳng hạn, có thể dùng các bộ lọc để giảm nhiễu nếu dữ liệu là âm thanh, hoặc dùng các bộ dò cạnh để tìm ra cạnh của các vật thể trong dữ liệu ảnh. Nếu dữ liệu là ảnh các tế bào và ta cần đưa ảnh về kích thước nhỏ hơn, ta cần lưu ý về độ phân giải của tế bảo của ảnh trong kích thước mới. Ta cần xây dựng một bộ trích chọn đặc trưng phù hợp với từng loại dữ liệu.

Sau khi xây dựng bộ trích chọn đặc trưng, dữ liệu thô ban đầu được đưa qua và tạo ra các vector đặc trưng tương ứng gọi là *đặc trưng đã trích xuất*. Những đặc trưng này được dùng để huấn luyện các thuật toán học máy chính như phân loại, phân cụm, hồi quy,... trong khối thuật toán.

2.2.2. Pha kiểm tra

Ở pha kiểm tra, vector đặc trưng của một điểm dữ liệu thô mới được tạo bởi bộ trích chọn đặc trưng thu được từ pha huấn luyện. Vector đặc trưng này được đưa vào thuật toán chính đã tìm được để đưa ra quyết tra. Có một lưu ý quan trọng là khi xây dựng bộ trích chọn đặc trưng và các thuật toán chính, ta không được sử dụng dữ liệu kiểm tra. Các công việc đó được thực hiện chỉ dựa trên dữ liệu huấn luyện.

2.3. Một số kỹ thuật trích chọn đặc trưng

2.3.1. Trực tiếp lấy dữ liệu thô

Xét bài toán với dữ liệu là các bức ảnh xám có kích thước $m \times n$ điểm ảnh. Cách đơn giản nhất để tạo ra vector đặc trưng cho bức ảnh này là xếp chồng các cột của ma trận điểm ảnh để được một vector $m \times n$ phần tử. Vector này có thể được coi là vector đặc trưng với mỗi đặc trưng là giá trị của một điểm ảnh. Việc làm đơn giản này đã làm mất thông tin về vị trí tương đối giữa các điểm ảnh vì các điểm ảnh gần nhau theo phương ngang trong bức ảnh ban đầu không còn gần nhau trong vector đặc trưng. Tuy nhiên, trong nhiều trường hợp, kỹ thuật này vẫn mang lại kết quả khả quan.

2.3.2. Lựa chọn đặc trưng

Đôi khi, việc trích chọn đặc trưng đơn giản là chọn ra các thành phần phù hợp trong dữ liệu ban đầu. Việc làm này thường xuyên được áp dụng khi một lượng dữ liệu thu được không có đầy đủ các thành phần hoặc dữ liệu có quá nhiều chiều mà phần lớn không mang nhiều thông tin hữu ích.

2.3.3. Giảm chiều dữ liệu

Giả sử dữ liệu ban đầu là một vector $\mathbf{x} \in \mathbb{R}^D$, $\mathbf{A}$ là một ma trận trong $R^{d \times D}$ và $\mathbf{z} = \mathbf{A}\mathbf{x} \in \mathbb{R}^d$. Nếu $d < D$, ta thu được một vector với số chiều nhỏ hơn. Đây là một kỹ thuật phổ biến trong giảm chiều dữ liệu. Ma trận $\mathbf{A}$ được gọi là *ma trận chiếu* (projection matrix), có thể là một ma trận ngẫu nhiên. Tuy nhiên, việc chọn một ma trận chiếu ngẫu nhiên đôi khi mang lại kết quả tệ không mong muốn vì thông tin có thể bị thất thoát quá nhiều. Một phương pháp phổ biến để tối thiểu lượng thông tin mất đi có tên là *phân tích thành phần chính* (principal component analysis).

Lưu ý: Kỹ thuật xây dựng đặc trưng không nhất thiết luôn làm giảm số chiều dữ liệu, đôi khi vector đặc trưng có thể có có kích thước lớn hơn dữ liệu thô ban đầu nếu việc này mang lại hiệu quả tốt hơn.

2.3.4. Túi từ

Túi từ là một kỹ thuật tạo véc tơ đặc trưng từ văn bản. Chúng ta xây dựng từ điển gồm tất cả các từ được sử dụng trong bài toán. Sau đó xây dựng véc tơ đặc trưng của câu thông qua việc đếm số lần xuất hiện của từ trong câu xét trên từ điển đã có. *Ví dụ.* Xét hai câu

```
(1) "John likes to watch movies. Mary likes movies too."
```

và

```
(2) "John also likes to watch football games."
```

Dựa trên hai văn bản này, ta có danh sách các từ được sử dụng, được gọi là *từ điển* (dictionary hoặc codebook) với mười *từ* như sau:

```
["John", "likes", "to", "watch", "movies", "also", "football", "games", "
    Mary", "too"]
```

Với mỗi văn bản, ta sẽ tạo ra một vector đặc trưng có số chiều bằng 10, mỗi phần tử đại diện cho số từ tương ứng xuất hiện trong văn bản đó. Với hai văn bản trên, ta sẽ có hai vector đặc trưng:

```
(1) [1, 2, 1, 1, 2, 0, 0, 0, 1, 1]
(2) [1, 1, 1, 1, 0, 1, 1, 1, 0, 0]
```

Văn bản (1) có một từ `"John"`, hai từ `"likes"`, không từ `"also"`, không từ `"football"`,... nên ta thu được vector tương ứng như trên.

Có một vài điều cần lưu ý trong kỹ thuật túi từ:

- Với những ứng dụng thực tế, từ điển có số lượng từ lớn hơn rất nhiều, có thể đến cả triệu, như vậy vector đặc trưng thu được sẽ rất dài. Một văn bản chỉ có một câu, và một tiểu thuyết nghìn trang đều được biểu diễn bằng các vector có kích thước như nhau.

- Có rất nhiều từ trong từ điển không xuất hiện trong một văn bản. Như vậy các vector đặc trưng thu được thường có nhiều phần tử bằng không. Các vector đó được gọi là *vector thưa*. Để việc lưu trữ được hiệu quả hơn, ta không lưu mọi thành phần của một vector thưa mà chỉ lưu vị trí của các phần tử khác

không và giá trị tương ứng. Chú ý rằng nếu có hơn một nửa số phần tử khác không, việc làm này lại phản tác dụng. Tuy nhiên, trường hợp này ít xảy ra vì hiếm có văn bản chứa tới một nửa số từ trong từ điển.

- Các từ hiếm gặp được xử lý như thế nào? Một kỹ thuật thường dùng là thêm phần tử `<Unknown>` vào trong từ điển. Mọi từ không có trong từ điển đều được coi là `<Unknown>`.

- Tuy nhiên, những từ hiếm đôi khi lại mang những thông tin quan trọng nhất mà chỉ loại văn bản đó có. Đây là một nhược điểm của túi từ. Có một phương pháp cải tiến giúp khắc phục nhược điểm này tên là *term frequency-inverse document frequency* (TF-IDF) dùng để xác định tầm quan trọng của một từ trong một văn bản dựa trên toàn bộ văn bản trong cơ sở dữ liệu.

- Nhược điểm lớn nhất của túi từ là nó không mang thông tin về thứ tự của các từ, cũng như sự liên kết giữa các câu, các đoạn văn trong văn bản. Thứ tự của các từ trong văn bản thường mang thông tin quan trọng. Ví dụ, ba câu sau đây: "Thịt nướng chị Tươi?", "Thịt chị nướng tươi", và "Nướng thịt chị Tươi" khi được trích chọn đặc trưng bằng túi từ sẽ cho ra ba vector giống hệt nhau, mặc dù ý nghĩa khác hẳn nhau.

2.4. Chuẩn hoá vector đặc trưng

Các điểm dữ liệu đôi khi được đo đạc bằng những đơn vị khác nhau, chẳng hạn mét và feet. Đôi khi, hai thành phần của dữ liệu ban đầu chênh lệch nhau lớn, chẳng hạn một thành phần có khoảng giá trị từ 0 đến 1000, thành phần kia chỉ có khoảng giá trị từ 0 đến 1. Lúc này, chúng ta cần chuẩn hóa dữ liệu trước khi thực hiện các bước tiếp theo.

Chú ý: Việc chuẩn hóa này chỉ được thực hiện khi vector dữ liệu đã có cùng chiều.

Sau đây là một vài phương pháp chuẩn hóa thường dùng.

2.4.1. Chuyển khoảng giá trị

Phương pháp đơn giản nhất là đưa tất cả các đặc trưng về cùng một khoảng, ví dụ $[0, 1]$ hoặc $[-1, 1]$. Để muốn đưa đặc trưng thứ i của một vector đặc trưng $\mathbf{x}$ về khoảng $[0, 1]$, ta sử dụng công thức

$$x'_i = \frac{x_i - \min(x_i)}{\max(x_i) - \min(x_i)} \tag{2.1}$$

trong đó x_i và x'_i lần lượt là giá trị đặc trưng ban đầu và giá trị đặc trưng sau khi được chuẩn hóa. $\min(x_i), \max(x_i)$ là giá trị nhỏ nhất và lớn nhất của đặc trưng thứ i xét trên toàn bộ dữ liệu huấn luyện.

2.4.2. Chuẩn hoá theo phân phối chuẩn

Một phương pháp khác thường được sử dụng là đưa mỗi đặc trưng về dạng một phân phối chuẩn có kỳ vọng là 0 và phương sai là 1. Công thức chuẩn hóa là

$$x'_i = \frac{x_i - \bar{x}_i}{\sigma_i} \tag{2.2}$$

với $\bar{x}_i, \sigma_i$ lần lượt là kỳ vọng và độ lệch chuẩn của đặc trưng đó xét trên toàn bộ dữ liệu huấn luyện.

2.4.3. Chuẩn hoá các véc tơ về cùng độ dài 1

Một lựa chọn khác cũng được sử dụng rộng rãi là biến vector dữ liệu thành vector có độ dài Euclid bằng 1. Việc này có thể được thực hiện bằng cách chia mỗi vector đặc trưng cho chuẩn ℓ_2 của nó:

$$\mathbf{x}' = \frac{\mathbf{x}}{\|\mathbf{x}\|_2} \tag{2.3}$$

2.5. Câu hỏi ôn tập bài 2

Câu 1: Điểm dữ liệu trước khi đưa vào chương trình được biểu diễn dưới dạng nào?

Câu 2: Đặc trưng là gì? Các kỹ thuật trích chọn đặc trưng cơ bản?

Câu 3: Ôn lại các phép toán cơ bản về véc tơ, ma trận. (Theo tài liệu hd của giáo viên).

Câu 4: Ôn lại Chuẩn của véc tơ, ma trận. (Theo tài liệu hướng dẫn của giáo viên).

Câu 5: Ôn lại xác suất thống kê. (Theo tài liệu hướng dẫn của giáo viên).

Câu 6: Trình bày các phương pháp chuẩn hóa véc tơ đặc trưng.

2.6. BÀI TẬP CUỐI CHƯƠNG

Bài 1. Định nghĩa của Học Máy là gì?

Bài 2. Liệt kê bốn loại bài toán mà Học Máy giải quyết tốt?

Bài 3. Tập huấn luyện đã gán nhãn là gì?

Bài 4. Hai tác vụ học có giám sát phổ biến nhất là gì?

Bài 5. Liệt kê bốn tác vụ học không giám sát phổ biến?

Bài 6. Chúng ta sẽ sử dụng loại thuật toán Học Máy nào để cho phép rô bốt đi lại trong các địa hình

Bài 7. Chúng ta sẽ sử dụng loại thuật toán nào để phân nhóm khách hàng thành nhiều nhóm?

Bài 8. Chúng ta sẽ đặt bài toán phát hiện thư rác là bài toán học có giám sát hay học không giám sát?

Bài 9. Hệ thống học trực tuyến là gì?

Bài 10. Thế nào là học ngoài bộ nhớ chính?

Bài 11. Loại thuật toán nào dựa vào phép đo độ tương đồng để đưa ra dự đoán?

Bài 12. Sự khác biệt giữa tham số mô hình và siêu tham số của thuật toán là gì?

Bài 13. Thuật toán học dựa trên mô hình đang tìm kiếm thứ gì? Chiến lược phổ biến nhất mà chúng sử dụng để thành công là gì? Chúng đưa ra dự đoán như thế nào?

Bài 14. Chúng ta có thể liệt kê bốn thách thức chính trong Học Máy không?

Bài 15. Nếu mô hình của chúng ta hoạt động tốt trên dữ liệu huấn luyện nhưng lại khái quát kém đối với dữ liệu mới, điều gì đang xảy ra? chúng ta có thể liệt kê ba giải pháp khả thi cho vấn đề này không?

Bài 16. Tập kiểm tra là gì và tại sao chúng ta lại muốn sử dụng nó?

Bài 17. Mục đích của tập kiểm định là gì?

Bài 18. Tập huấn luyện - phát triển là gì, khi nào chúng ta cần sử dụng và làm thế nào để sử dụng nó?

Bài 19. Vấn đề gì có thể xảy ra nếu chúng ta tinh chỉnh siêu tham số bằng tập kiểm tra?

Chương II

CÁC THUẬT TOÁN HỌC CÓ GIÁM SÁT

Chương này trình bày các thuật toán học có giám sát điển hình, bao gồm các thuật toán phân lớp và hồi quy cũng như thuật toán tối ưu bổ trợ. Sau khi kết thúc chương này, sinh viên nắm chắc các kỹ thuật học có giám sát, biết huấn luyện các mô hình trên dữ liệu thực tế:

a. Hồi quy tuyến tính.

b. K lân cận.

c. Bộ phân loại Navie Bayes.

d. Hạ Gradient.

e. Thuật toán học Perceptron.

f. Hồi quy Logistic

g. Hồi quy Softmax

h. Máy véc tơ hỗ trợ

Nội dung chương 2 được học trong 8 bài, mỗi bài 2 tiết. Đề nghị làm hết câu hỏi ôn tập cuối mỗi bài, bài tập cuối chương, bài tập thực hành và đọc thêm tài liệu theo hướng dẫn. Những bài học trong chương bao gồm: