Bài 9: KỸ THUẬT NHẬN DẠNG

Mục tiêu:

Bài học cung cấp các kiến thức tổng quan về các kỹ thuật nhận dạng, tập trung vào kỹ thuật máy véc tơ hỗ trợ, và giới thiệu các độ đo để đánh giá các hệ thống xử lý ảnh.

Một trong những vấn đề quan trọng của thị giác máy tính là khả năng kết hợp các phương pháp trí tuệ nhân tạo với xử lý ảnh đặc trưng ảnh vào việc phát hiện, nhận dạng và định danh đối tượng. Nhận dạng mẫu có nhiều ứng dụng trong các hệ thống tương tác người máy

9.1-Giới thiệu

Thuật ngữ phân loại trong lĩnh vực khai phá dữ liệu được hiểu là việc gán đối tượng vào một trong các lớp được xác định trước. Phân loại là dạng bài toán phổ biên và có nhiều ứng dụng khác nhau trong các hệ thống tự động. Trong lĩnh vực xử lý ảnh, bài toán phân loại mẫu và nhận dạng đối tượng được hiểu là việc phân loại, xác định các mẫu thuộc lớp nào đó một cách chính xác dựa vào việc đo lường về đối tượng dựa trên các đặc trưng của đối tượng. Nói cách khác, nhận dạng đối tượng nhằm mục đích phân loại các mẫu (dữ liệu) dựa trên kiến thức có trước về đối tượng hoặc dựa vào thông tin thống kê, đo lường được trích rút ra từ các mẫu trong tập dữ liệu huấn luyện. Hiện nay, có nhiều cách tiếp cận như nhận dạng người trong các hệ thống tương tác người máy; nhận dạng khuôn mặt và định danh cá thể, nhận dạng phương tiện giao thông trong các hệ thống giao thông thông minh, hỗ trợ lái xe; nhận dạng hành động trong các hệ thống giám sát thông minh, chăm sóc y tế; nhận dạng chữ viết,…Lĩnh vực nhận dạng đối tượng liên quan đến các phương pháp, kỹ thuật của xử lý ảnh và học máy. Để huấn luyện mô hình và nhận dạng đối tượng, các mẫu dữ liệu thường được số hóa và biểu diễn thành vector đặc trưng trong một không gian đa chiều tương ứng, được gọi là không gian đặc trưng. Nhờ vào vector đặc trưng này để có thể phân tích, đánh giá nhằm xây dựng được mô hình đối tượng phục vụ phân loại, nhận dạng chúng. Trong nhận dạng, các phương pháp học máy có giám sát và không giám sát đều được nghiên cứu và ứng dụng. Các kỹ thuật học máy có giám sát thường được sử dụng như cây quyết định, mạng nơron, SVM, Boosting, rừng ngẫu nhiên. Nhận dạng theo học máy có giám sát thì việc phân loại thường dựa vào tập dữ liệu mẫu đã được gán nhãn theo các lớp bởi các ‘chuyên gia’ để phân tích và xây dựng mô hình nhận dạng. Tập dữ liệu mẫu để học được gọi là tập dữ liệu huấn luyện và quá trình phân tích, xây dựng mô hình đối tượng được gọi là quá trình huấn luyện máy nhận dạng hay huấn luyện mô hình. Ngược lại, các phương pháp học không có giám sát, tập dữ liệu phân loại không cần được gán nhãn trước mà bản

thân thuật toán phải tự phân loại, xác định lớp của đối tượng dựa vào phân tích, thống kê từ các đặc trưng của tập mẫu dữ liệu đưa vào.

Quá trình nhận dạng đối tượng được mô tả bằng sơ đồ tổng quát như sau:

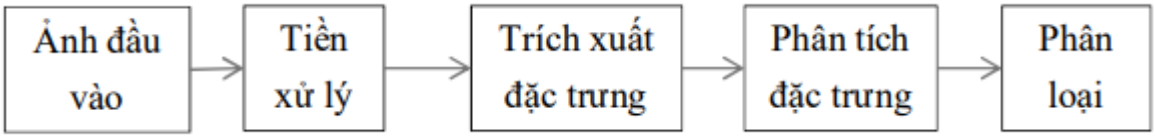

Hình 9.1. Sơ đồ tổng quát quá trình nhận dạng đối tượng

Phần dưới trình bày một số kỹ thuật học máy

Cây quyết định

Cây quyết định (decision tree) là một lĩnh vực nghiên cứu cụ thể của ngành học máy. Các kỹ thuật cây quyết định được sử dụng khá nhiều trong các lĩnh vực khai phá tri thức và nhận dạng mẫu. Cây quyết định là một kiểu mô hình dự báo (predictive model), được xây dựng trên cơ sở cấu trúc cây, dùng để phân lớp các mẫu dữ liệu dựa vào chuỗi các luật suy diễn (rules). Trong mô tả cấu trúc cây của cây quyết định, các nút lá đại diện cho các quyết định phân loại, các nhánh đại diện cho luật kết hợp các thuộc tính để dẫn tới phân loại nào đó. Một cây quyết định có thể được huấn luyện bằng cách chia tập dữ liệu huấn luyện thành các tập con để kiểm tra theo từng giá trị thuộc tính đơn hoặc một nhóm các thuộc tính. Việc phân loại có thể được mô tả như là các kết hợp phân loại đơn giản bằng cách sử dụng kỹ thuật suy diễn toán học. Quá trình huấn luyện mô hình phân loại là quá trình xây dựng cây quyết định. Hiện nay có nhiều phương pháp xây dựng cây quyết định cho bài toán phân loại đối tượng như ID3, C4.5,...

Kỹ thuật Boosting

Kỹ thuật Boosting là một dạng thuật toán học máy quần thể (machine learning ensemble algorithm) bằng cách xây dựng nhiều bộ phân loại cùng lúc (tương tự như rừng ngẫu nhiên) và sau đó kết hợp chúng lại theo trọng số xác định của từng phân loại thành phần. Mỗi bộ phân loại thành phần được gọi là phân loại yếu (weak classifier), các bộ phân loại yếu được hợp lại với nhau tạo thành một phân loại mạnh (strong classifier). Một trong những thuật toán phổ biến của boosting là AdaBoost (Adaptive boosting), được đề xuất bởi Freund và Schapire năm 1999. AdaBoost là bộ phân loại mạnh phi tuyến, hoạt động trên nguyên tắc kết hợp các bộ phân loại yếu theo trọng số để tạo ra một bộ phân loại mạnh hơn theo kiểu thích ứng (với mẫu dữ liệu). Theo đó, AdaBoost sử dụng các trọng số để đánh dấu các mẫu khó phân loại. Càng vào những mức sâu của phân loại yếu, bộ phân loại càng tập trung vào những mẫu khó phân loại, trong khi những mẫu phân loại dễ sẽ có giá trị ảnh hưởng nhỏ hơn. Nghĩa là trong quá trình huấn luyện, mỗi bộ phân loại yếu tiến hành cập nhật lại trọng số theo hướng giảm dần trọng số các mẫu phân loại đúng (các mẫu dễ) và tăng trọng số của những mẫu phân loại sai (các mẫu khó) để áp dụng cho việc xây dựng các bộ phân loại yếu sau đó. Dựa trên ý tưởng này, các bộ phân loại sau có thể tập trung chủ yếu vào các mẫu khó mà bộ phân loại trước đó

phân loại không đúng. Cuối cùng, các bộ phân loại yếu được kết hợp lại theo trọng số tùy thuộc độ chính xác phân loại của chúng để tạo ra bộ phân loại mạnh.

Mạng neural nhân tạo

Mạng neural nhân tạo (ANN- artificial neural network) thường được gọi tắt là mạng neural (NN- neural network). Mạng neural là mô hình tính toán được xây dựng dựa trên nguyên tắc hoạt động và phát triển của mạng neural sinh học. Kiến trúc mạng neural gồm tập các nút gọi là các neural và tập các cung (hay gọi là cạnh) để kết nối các neural với nhau. Tập các nút được tổ chức thành các lớp, gọi là các layer. Trong đó có một lớp đầu vào (input layer) và một lớp đầu ra (output layer), các lớp giữa gọi là các lớp ẩn (hidden layer). Mỗi cung kết nối 2 cặp neural với nhau, trong đó có một nút vào và một nút ra, nhằm mục đích truyền thông tin và xử lý tính giá trị mới cho các nút ra. Mối liên hệ giữa các nút được thể hiện thông qua hàm biến đổi (gọi là hàm truyền) cùng với bộ trọng số tương ứng cho hàm truyền. Thông thường, kiến trúc của một mạng neural được xây dựng trước và các trọng số được xác định trong quá trình huấn luyện, tuy nhiên một số kiểu mạng có khả năng thay đổi để thích ứng (adaptive) với dữ liệu thực tế và có thể tự thay đổi cấu trúc của mạng dựa trên các thông tin trong quá trình học, một số kiểu như mạng neural đa lớp (MLNN- Multi layer neural network) và mạng Neural tự tổ chức (SOM- Self organizing maps)

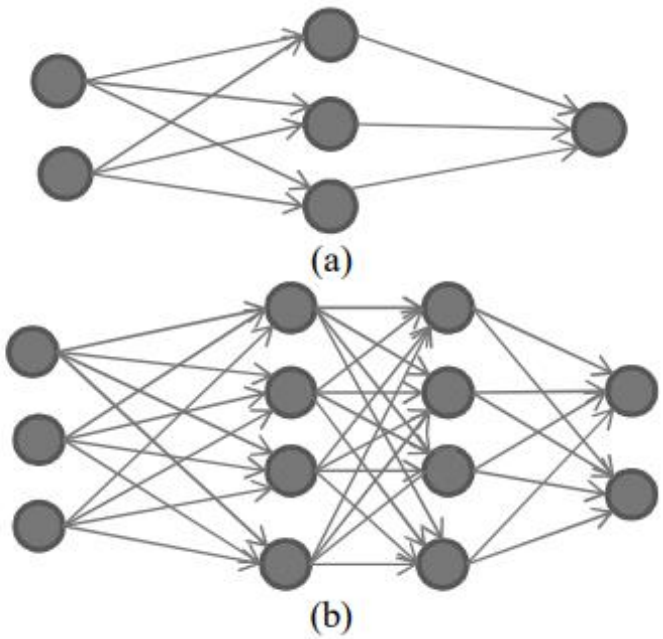

Hình 9.2 Minh họa kiến trúc mạng neural: (a) mạng có một lớp ẩn, (b) mạng có hai lớp ẩn

Một trong những phần tử quan trọng của NN là khả năng học của nó. Một NN không chỉ là hệ thống phức tạp mà còn là một hệ thống thích nghi phức tạp, có nghĩa là có thể thay đổi cấu trúc bên trong dựa vào luồng thông tin truyền qua nó. Đặc biệt, những thay đổi này thu được thông qua việc điều chỉnh bộ trọng số. Trong hình minh họa trên, mỗi cung thể hiện một kết nối giữa hai neural và chỉ hướng của luồng dữ liệu đi qua trong mạng. Mỗi kết nối có một trọng số nhất định, là giá trị có chức năng điều khiển tín hiệu nữa hai neural với nhau. Nếu mạng cho kết quả phân lớp đủ tốt thì không cần thiết phải

điều chỉnh lại trọng số nữa. Tuy nhiêu nếu mạng cho kết quả chưa đủ tốt (với sai số trên ngưỡng cho phép) thì hệ thống phải thích nghi bằng cách điều chỉnh trọng số để thay đổi kết quả đầu ra theo hướng tốt hơn.

Một trong những lợi thế của NN là khả năng được sử dụng như một xấp xỉ hàm tùy ý học từ các mẫu dữ liệu quan sát được. Một số yêu cầu chính trong xây dựng mô hình mạng neural là vấn đề chọn mô hình phù hợp bài toán ứng dụng phụ thuộc vào cách mô tả mẫu dữ liệu. Nghĩa là một mô hình quá phức tạp sẽ dẫn đến khó khăn trong quá trình huấn luyện mô hình, trong khi đó những mô hình đơn giản lại không giải quyết được bài toán phức tạp. Vấn đề lựa chọn thuật toán học cũng có ý nghĩa hết sức quan trọng. Thuật toán học chủ yếu liên quan đến việc xây dựng bộ tham số (hyperparameter) và làm sao ước lượng các tham số tối ưu và hội tụ nhanh nhất có thể để phân lớp tốt nhất. Trong thực tế, lựa chọn và điều chỉnh một thuật toán để huấn luyện trên dữ liệu quan sát yêu cầu một số lượng lớn đáng kể trong thực nghiệm.

Phân theo phương pháp huấn luyện, mạng neural có thể thuộc dạng học có giám sát hoặc học không có giám sát, học tăng cường. Với cách tiếp cận học có giám sát, quá trình huấn luyện được thực hiện trên tập dữ liệu đã có gán nhãn (bởi chuyên gia). Học không giám sát, mạng neural xử lý trên bộ mẫu dữ liệu không cần gán nhãn trước. Quá trình thực hiện được xem như quá trình tìm kiếm các đặc trưng tiềm năng (tiềm ẩn) trong tập dữ liệu. Ví dụ thuật toán phân cụm dữ liệu bằng cách chia tập dữ liệu ban đầu vào các nhóm theo một số tính chất nào đó chưa biết trước. Bên cạnh đó, học tăng cường là chuỗi các kỹ thuật liên quan đến xây dựng mô hình dựa vào quan sát. Ví dụ một con chuột chạy qua một mê cung. Nếu nó quay trái, nó sẽ gặp được một miếng phô mát, nếu nó quay phải nó sẽ bị một số rủi ro nào đó. Giả sử rằng con chuột sẽ học theo thời gian để quyết định qua trái. Mạng thần kinh của chuột đưa ra quyết định với một kết quả (qua trái hoặc qua phải) và quan sát môi trường quanh nó. Nếu như quan sát thấy vấn đề đó là tiêu cực, mạng thần kinh có thể điều chỉnh trọng số để tạo ra một quyết định khác cho những lần tiếp theo. Học tăng cường ngày nay được sử dụng khá phổ biến trong các hệ thống tự động hóa và hệ thống tương tác người máy. Ví dụ tại thời điểm t, một robot thực hiện một nhiệm vụ và quan sát kết quả. Nó có thể va chạm vào tường, bị rơi khỏi bàn, va chạm với các đối tượng khác hoặc nó không gặp vấn đề gì. Mạng neural xem xét việc học tăng cường trong ngữ cảnh của các mô hình hệ thống xe tự động. Những khả năng của mạng neural giúp học và tạo ra những thay đổi đối với cấu trúc theo thời gian và làm cho mạng neural trở nên thông minh hơn.

Mạng neural có nhiều ứng dụng và đạt được những kết quả nhất định trong lĩnh vực trí tuệ nhân tạo: Nhận dạng mẫu là một trong những ứng dụng phổ biến của mạng neural như nhận dạng ký tự quang học, nhận dạng mặt người, nhận dạng dáng người, định danh đối tượng và con người qua hình ảnh, phát hiện và nhận dạng tín hiệu biển báo giao thông, phát hiện các hành động bất thường trong các hệ thống giám sát thông minh. Dự đoán theo chuỗi thời gian, mạng neural có thể được sử dụng để tạo ra các dự đoán ví dụ như giá trị chứng khoán thay đổi như thế nào, dự báo thời tiết,… Xử lý tín hiệu: Như các hệ thống lọc âm thanh, khử nhiễu tín hiệu thu vào, khuếch đại các âm thanh quan trọng. Trong điều khiển như việc dự đoán chuyển động để điều khiển tay lái điều hướng.

9.2. Phương pháp máy véc tơ hỗ trợ

9.2.1 Giới thiệu

Phương pháp máy vector hỗ trợ (Support vector machine-SVM) là thuật toán phân loại, thuộc phương pháp học có giám sát, được đề xuất bởi Corinna và Vapnik vào năm 1995. Ban đầu SVM được thiết kế cho bài toán phân loại nhị phân, sau này được mở rộng để áp dụng cho phân loại đa lớp khác nhau. Với một mẫu dữ liệu huấn luyện thuộc hai loại xác định trước, thuật toán SVM tiến hành huấn luyện để xây dựng mô hình nhằm phân loại các mẫu dữ liệu theo các lớp tương ứng như tập dữ liệu huấn luyện. Một mô hình SVM là một cách biểu diễn các vector hỗ trợ phân loại trong không gian nhiều chiều và lựa chọn siêu phẳng (hyperplane) phân loại giữa hai lớp sao cho cực đại khoảng cách từ các mẫu dữ liệu huấn luyện (các điểm trong không gian n chiều) tới mặt phẳng phân loại. Các mẫu mới đưa vào để phân loại phải được biểu diễn trong cùng một không gian như tập huấn luyện và SVM phân loại vào một trong hai lớp tùy thuộc vào giá trị cụ thể của mẫu dữ liệu thuộc phía nào của mặt siêu phẳng phân loại.

Đến nay, SVM là một trong những phương pháp phân lớp được sử dụng rộng rãi nhất trong lĩnh vực khoa học máy tính và phân tích số liệu. SVM thực hiện hiệu quả trên tập dữ liệu lớn và xử lý hiệu quả trên không gian có số chiều lớn, đặc biệt áp dụng cho các bài toán phân loại dữ liệu hình ảnh, văn bản, và tiếng nói,… SVM hoạt động khá linh hoạt và có khả năng áp dụng nhiều hàm nhân khác nhau và có thể phân loại theo phương pháp tuyến tính hoặc phi tuyến. Trong thực tế, SVM đạt độ chính xác khá cao so với kỹ thuật học máy truyền thống khác. Phương pháp SVM có nhiều phiên bản được phát triển theo hướng tiếp cận phân loại tuyến tính, phân loại phi tuyến và đã được lập trình thành công cụ. Thư viện LibSVM của nhóm tác giả Chang và Lin là một trong những công cụ được sử dụng khá phổ biến hiện nay.

9.2.2 Phân loại tuyến tính

Nội dung cơ bản của kỹ thuật SVM tuyến tính được mô tả như sau : Cho trước một tập dữ liệu huấn luyện S gồm n mẫu $(x_1, y_1),\ldots,(x_n, y_n)$ với x_i là mẫu dữ liệu được biểu diễn dưới dạng các điểm trong không gian p chiều (hoặc xem nó là vector có p phần tử) và $y_i \in \{-1\ 1\}$ là nhãn tương ứng để chỉ lớp của mẫu dữ liệu đó. Mục tiêu của SVM là tìm một siêu phẳng có khả năng phân tách tập mẫu thành 2 tập theo nhãn của nó với lề đạt khoảng cách cực đại, lề là khoảng cách từ siêu phẳng đến các điểm (trong p chiều) gần nhất.

Các siêu phẳng cần tìm ở đây chính là các đường thẳng trong trường hợp không gian hai chiều, mặt phẳng trong trường hợp không gian ba chiều và tổng quát hơn là các siêu phẳng không gian con R^{d-1} chiều trong không gian R^d.

Siêu phẳng trong không gian đa chiều có thể được viết dưới dạng

$$w \bullet x - b = 0$$

Trong đó, w là vector pháp tuyến của siêu phẳng, w không nhất thiết là vector đơn vị. Tham số b/|| w || được xác định là khoảng cách từ siêu phẳng đến gốc tọa độ theo vector pháp tuyến w.

Lề cực đại (maximal margin) là khoảng cách lớn nhất từ siêu phẳng đến các điểm gần nhất, nghĩa là khoảng cách xa nhất từ siêu phẳng đến đường thẳng song song với nó đi qua điểm gần nhất, mà không chứa điểm dữ liệu nào bên trong nó. Các vector hỗ trợ (support vectors) là các điểm dữ liệu gần nhất nằm trên lề cực đại.

Hình minh họa cho thấy có vô số đường thẳng có thể phân loại hai lớp dữ liệu thành hai miền khác nhau, các đường này được gọi là siêu phẳng. Mục tiêu là cần tìm ra siêu phẳng 'tốt nhất' để phân lớp dữ liệu. Siêu phẳng SVM tìm kiếm là siêu phẳng có giá trị lề lớn nhất, còn gọi là siêu phẳng với lề cực đại (maximal margin hyperplane). Để phân loại tốt nhất cần xây dựng siêu phẳng tối ưu. Lề càng lớn thì sai số tổng quát của thuật toán phân loại càng bé. Nghĩa là nó nằm càng xa các điểm dữ liệu của tất cả các lớp càng tốt. Muốn các điểm dữ liệu có thể được chia tách một cách tuyến tính, cần xác định hai siêu phẳng sao cho không có điểm nào ở giữa chúng và khoảng cách giữa chúng là lớn nhất.

Đối với dữ liệu có khả năng phân loại tuyến tính, các vector hỗ trợ tìm các siêu phẳng phân tách có giá trị lề càng lớn càng tốt. Giả sử tất cả dữ liệu huyến luyện thỏa mãn điều kiện :

$$w.x_i + b \geq +1 \;\; khi \; y_i = +1$$
$$w.x_i + b \leq -1 \;\; khi \; y_i = -1$$

Kết hợp hai công thức lại ta có :

$$y_i(w.x_i + b) \geq 1 \; với \; i = 1,..,n$$

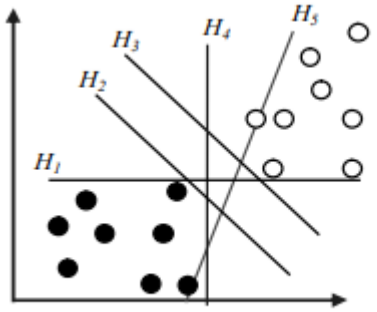

(a)

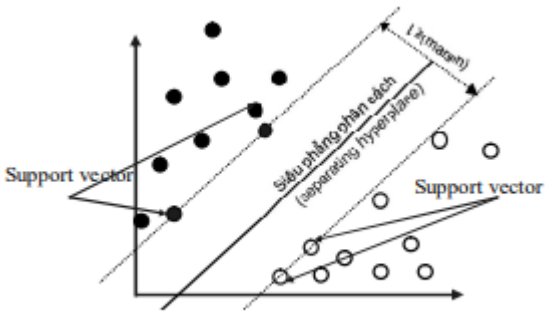

(b)

Hình 9.3. Siêu phẳng phân tách mẫu dữ liệu thành 2 lớp: a) các siêu phẳng ứng cử viên; b) lề phân loại và các vector hỗ trợ tìm được

Đối với vector hỗ trợ x_i là các điểm nằm trên đường biên giới hạn của siêu phẳng H_+: $w.x_i+b= +1$ với khoảng cách đến gốc tọa độ là $|1-b|/||w||$ và các điểm nằm trên đường biên giới hạn của siêu phẳng H_-: $w.x_i+b=-1$ với khoảng cách đến gốc tọa độ là $|-1-b/||w||$. Bài toán tối ưu tương đối khó giải vì hàm mục tiêu phụ thuộc vào $||w||$, là một hàm có khai căn. Tuy nhiên có thể thay $||w||$ bằng hàm mục tiêu $½ ||w||^2$ mà không làm thay đổi lời giải đối với bài toán. Như vậy, vấn đề cần thiết là cực tiểu hóa mục tiêu $½ ||w||^2$ theo w và b với điều kiện $yi(w.xi+b) \geq 1$.

Bằng cách thêm các nhân tử Lagrange α, bài toán trở thành dạng sau:

$$\min_{w,b} \max_{\alpha \geq 0} \left\{ \frac{1}{2} \|w\|^2 - \sum_{i=1}^{n} \alpha_i [y_i (w.x_i - b) - 1] \right\}$$

Nghĩa là cần tìm điểm cực tiểu cục bộ. Mỗi mẫu huấn luyện x_i tương ứng với một hệ số Lagrange α_i, khi đó tất cả các điểm không nằm trên lề $y_i(w.x_i+b)>1$ đều không ảnh hưởng đến giá trị hàm mục tiêu vì lúc đó hệ số Lagrange α_i có thể thiết lập bằng không ($\alpha_i =0$). Nghĩa là những điểm không nằm trên lề thì có hệ số Lagrange bằng không và không tham gia vào việc xác định hàm mục tiêu.

Sau khi huấn luyện, các mẫu có $\alpha_i >0$ được gọi là vector hỗ trợ và nằm trên một trong hai siêu phẳng H_+ hoặc H_-. Khi đã xác định được tập vector hỗ trợ phân loại nghĩa là đã thu được mô hình máy phân loại SVM, với mỗi mẫu thử (đánh giá, testing) có thể đơn giản được phân loại theo siêu phẳng H_+ và H_- tạo ra bằng cách dùng hàm dấu theo công thức sau:

Sign(w.x+b)

H+

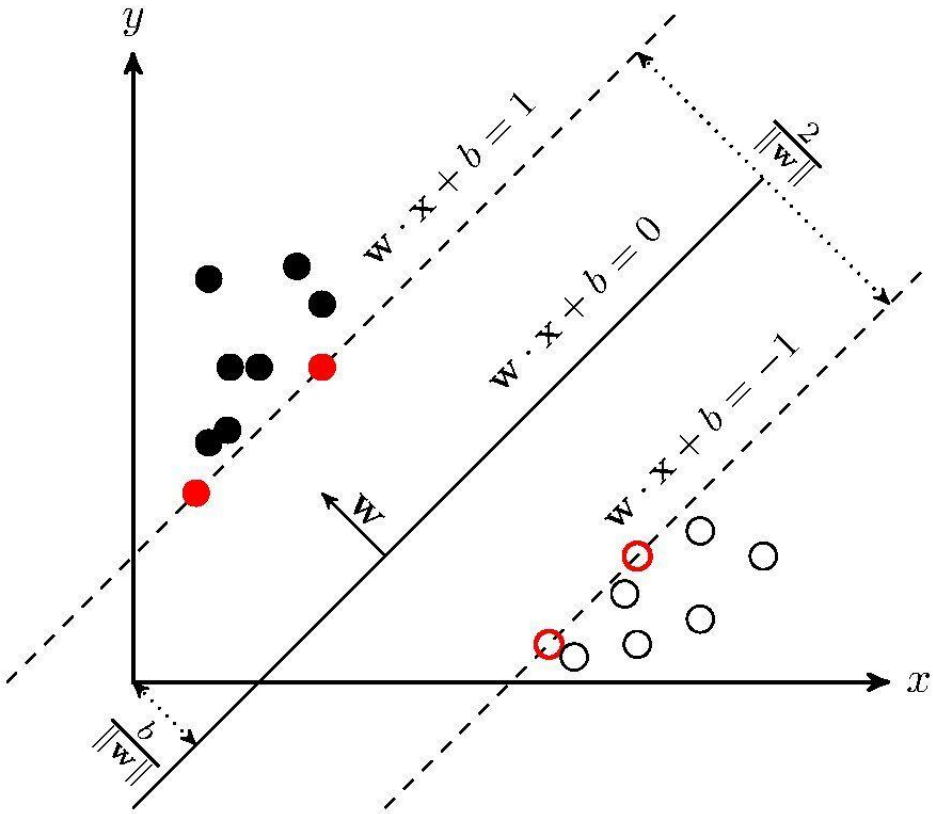

H-

Hình 9.4 Mô hình phân lớp SVM

Có thể giải bài toán tối ưu hóa trên bằng các kỹ thuật thông thường cho quy hoạch toàn phương. Theo điều kiện Karush-Kuhn-tucker (KKT), lời giải có thể được viết dưới dạng tổ hợp tuyến tính của các vector huấn luyện

$$w = \sum_{i=1}^{n} \alpha_i \, y_i x_i$$

Các điều kiện KKT đóng vai trò quan trọng trong giải quyết tối ưu các vấn đề lập trình phi tuyến. Điều kiện KKT được thể hiện như sau:

$\alpha_i = 0 \leftrightarrow y_i(w.x_i+b) \geq 1$

$\alpha_i = C \leftrightarrow y_i(w.x_i+b) \leq 1$

$0 \leq \alpha_i \leq C \leftrightarrow y_i(w.x_i+b) = 1$

Với bài toán lề cực đại cứng thì điều kiện $0 \leq \alpha_i$ được sử dụng để thay thế cho điều kiện $0 \leq \alpha_i \leq C$.

9.2.3. Phân loại tuyến tính lề mềm

Trong trường hợp không thể tìm được siêu phẳng phân tách lề mềm, thì kỹ thuật phân loại lề mềm (soft margin classification) được sử dụng để chọn một siêu phẳng phân tách tập mẫu dữ liệu huấn luyện tốt nhất có thể và cực đại hóa khoảng cách giữa siêu phẳng với các mẫu được phân loại đúng. Phương pháp lề mềm sử dụng thêm các biến bổ sung ξ_i (xem như giá trị bù cho phần tử sai) nhằm đo độ sai lệch của mẫu bị phân loại sai x_i qua đó giá trị này có tác dụng kéo phần tử x_i về đúng phía nhãn.

$y_i(w.x_i-b)\geq 1-\xi_i$ với i=1,…,n

Hay nói cách khác, hàm mục tiêu có bổ sung thêm hệ số mới để phạt (penalty) các điểm bị phân loại nhầm, giá trị ξ_i khác không và bài toán tối ưu hóa trở thành bài toán tối ưu giữa lề cực đại và mức phạt nhỏ nhất. Nếu hàm phạt là tuyến tính thì bài toán trở thành dạng sau:

$$\min_{w,\xi,b}\left\{\frac{1}{2}\|w\|^2+C\sum_{i=1}^{n}\xi_i\right\}\ với\ y_i(w.x_i-b)\geq 1-\xi_{i,}\quad \xi_i\geq 0$$

Có thể giải bài toán trên bằng nhân tử Lagrange tương tự trường hợp cơ bản phân loại lề cứng. Bài toán cần giải trở thành:

$$\min_{w,\xi,b}\max_{\alpha,\beta}\left\{\frac{1}{2}\|w\|^2+C\sum_{i=1}^{n}\xi_i-\sum_{i=1}^{n}\alpha_i[y_i(w.x_i-b)-1+\xi_i]-\sum_{i=1}^{n}\beta_i\xi_i\right\}$$

Với α_i, $\beta_i \geq 0$

9.2.4 Hàm nhân

Hàm nhân (hay còn gọi là hàm lõi, Kernel function) ký hiệu K là một hàm số trên không gian X, với mọi cặp vector u, v $\in$ X, ta có:

K(u, v) =$\Phi(u)\Phi(v)$

Với Φ là ánh xạ từ không gian mẫu X tới một không gian thuộc tính F được xác định Φ: $R^d \rightarrow F$

Khi đó, hàm phân loại có dạng:

$$f(x)=\sum_{e_i\neq 0}y_i\alpha_i K(x_i,x)+b$$

Trong thực tế, có hai loại hàm nhân được sử dụng phổ biến là hàm đa thức (polynomail function) và hàm cơ sở bán kính (RBF-radial basis function).

+ Hàm nhân đa thức trên không gian R^d có dạng:

K(u, v) = $(u.v)^p$

Với p=2 và d=2, ta có thể xây dựng ánh xạ Φ từ không gian số thực hai chiều R^2 vào không gian số thực ba chiều R^3 như sau:

$$\Phi: R^2 \rightarrow R^3$$

$$(u_1, u_2) \rightarrow (u_1^2, \sqrt{2}u_1u_2, u_2^2)$$

Hàm nhân K(u,v) là tích vô hướng của hai vector Φ (u) và Φ (v) trong không gian R^3. Lưu ý rằng một số hàm nhân có thể tương ứng với nhiều ánh xạ khác nhau.

Với d > 2 ta có:

$$(u.v)^2 = (\sum_{i=1}^{d} u_i v_i)^2 = \sum_{i=1}^{d}\sum_{j=1}^{d} u_i\, u_j\, v_i v_j = \sum_{(i,j)=(1,1)}^{(d,d)} (u_i u_j)(v_i v_j)$$

+ Hàm nhân RBF: Hàm cơ sở bán kính là một hàm giá trị thực mà giá trị của nó chỉ phụ thuộc vào khoảng cách từ gốc tọa độ, sao cho thỏa mãn điều kiện Φ(x) = Φ(||x||).

Có một số dạng hàm RBF như hàm mũ $K(u,v) = e^{-\|u-v\|^2/2\sigma^2}$ với σ thường được gọi là độ rộng của hàm hay giá trị độ lệch chuẩn, số chiều trong không gian đặc trưng có thể là vô hạn hoặc hữu hạn với giá trị lớn. Do vậy, khả năng của hàm các hàm tuyến tính cũng trở nên không giới hạn.

9.2.5 Tuyến tính hóa phân loại phi tuyến

Có một cách tiếp cận tương đối phổ biến là phân loại phi tuyến (nonlinear classification) có thể thực hiện ánh xạ vector đặc trưng phi tuyến vào không gian nhiều chiều hơn để có thể tuyến tính hóa rồi dùng phân loại tuyến tính trong không gian mới này. Đặc biệt, Φ là một hàm ánh xạ từ không gian mẫu d chiều ban đầu vào không gian đặc trưng F được định nghĩa bởi Φ: $R^d \rightarrow F$.

Đối với một vector đặc trưng ban đầu $x \in R^d$ và vector đặc trưng đã biến đổi được xác định theo hàm biến đổi Φ(x) với nhãn của nó vẫn giữ nguyên. Như vậy, mẫu huấn luyện ban đầu (x_i, y_i) được biến đổi thành (Φ(x1),y1),…,(Φ(x_n),y_n).

Như vậy, phân loại phi tuyến thực hiện bằng cách biến đổi qua một không gian khác để có thể tuyến tính hóa phân loại. Nghĩa là trong trường hợp không thể phân chia các lớp dữ liệu một cách tuyến tính trong không gian ban đầu thì thực hiện biến đổi dữ liệu vào không gian mới nhiều chiều hơn, để việc phân loại trở nên dễ dàng hơn trong không gian mới theo cách tiếp cận tuyến tính đã có. Quá trình tuyến tính hóa được thể hiện như ví dụ minh họa trong hình dưới đây với trường hợp (a) là biến đổi trong không gian 1D thành 2D có thể sử dụng hàm biến đổi Φ(x)=ax 2+b còn trường hợp (b) là biến đổi 2D thành 3D theo một hàm biến đổi cụ thể.

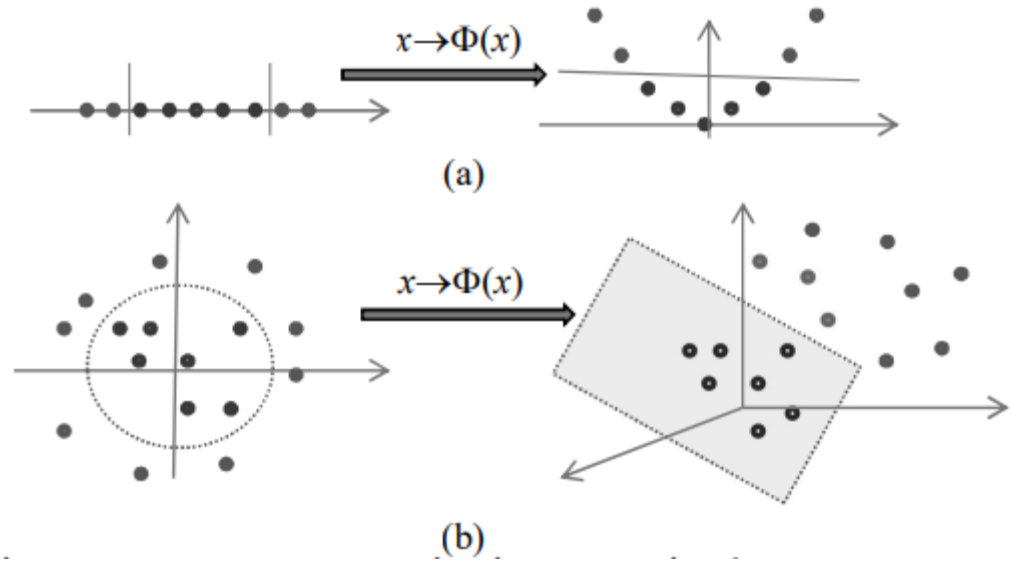

Hình 9.5. Tuyến tính hóa phân loại phi tuyến bằng cách biến đổi tập dữ liệu sang một không gian mới có khả năng phân loại tuyến tính

9.3 Các độ đo

- Chúng ta cần một phép đánh giá để xem mô hình sử dụng có hiệu quả không và để so sánh khả năng của các mô hình.

1. Accuracy (độ chính xác):

- Acc = Số mẫu nhận dạng đúng/Tổng số mẫu nhận dạng
- Y_true = [0, 0, 0, 0, 1, 1, 1, 2, 2, 2]
- Y_pred = [0, 1, 0, 2, 1, 1, 0, 2, 1, 2]
- Độ chính xác =6/10=0.6 (60%)

2. Confusion matrix

- Confusion matrix thể hiện có bao nhiêu điểm dữ liệu *thực sự* thuộc vào một class, và được *dự đoán* là rơi vào một class.

Y_true = [0, 0, 0, 0, 1, 1, 1, 2, 2, 2]
Y_pred = [0, 1, 0, 2, 1, 1, 0, 2, 1, 2]

normalized confusion matrix, ta lấy mỗi hàng của *unnormalized confusion matrix* sẽ được chia cho tổng các phần tử trên hàng đó.

		Predict			
		0	1	2	Tổng
True label	0	2	1	1	4
	1	1	2	0	3
	2	0	1	2	3

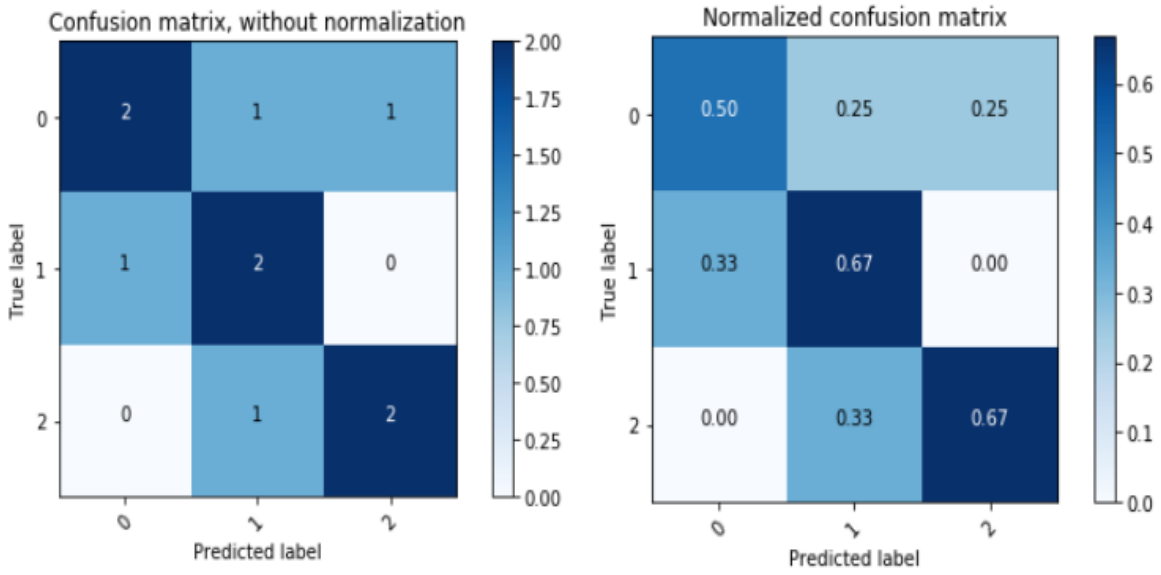

3. **True/False Positive/Negative**

- Cách đánh giá này thường được áp dụng cho các bài toán phân lớp có hai lớp dữ liệu. Cụ thể hơn, trong hai lớp dữ liệu này có một lớp quan *trọng* hơn lớp kia và cần được dự đoán chính xác.
- Ví dụ, trong bài toán xác định có bệnh ung thư hay không thì việc không bị *sót* (miss) quan trọng hơn là việc chẩn đoán nhầm *âm tính* thành *dương tính*.
- Trong bài toán xác định có mìn dưới lòng đất hay không thì việc *bỏ sót* nghiêm trọng hơn việc *báo động nhầm* rất nhiều.
- Trong bài toán lọc email rác thì việc cho nhầm email quan trọng vào thùng rác nghiêm trọng hơn việc xác định một email rác là email thường.
- Định nghĩa lớp dữ liệu *quan trọng* hơn cần được xác định đúng là lớp *Positive* (P-dương tính), lớp còn lại được gọi là *Negative* (N-âm tính).
- True Positive (TP): số lượng điểm của lớp *positive* được phân loại đúng là *positive*.
- True Negative (TN): số lượng điểm của lớp *negative* được phân loại đúng là *negative*.

- False Positive (FP): số lượng điểm của lớp *negative* bị phân loại nhầm thành *positive*.
- False Negative (FN): số lượng điểm của lớp *positive* bị phân loại nhầm thành *negative*

		Predicted	
		Positive	Negative
Actual	Positive	TP	FN
	Negative	FP	TN

- **Với các bài toán có nhiều lớp dữ liệu**, ta có thể xây dựng bảng True/False Positive/Negative cho **mỗi lớp** nếu coi lớp đó là lớp *Positive*, các lớp còn lại gộp chung thành lớp *Negative*, giống như cách làm trong one-vs-rest.

		Predicted		
		cat	dog	Rabbit
Actual	Cat	5	3	0
	Dog	2	3	1
	rabbit	0	2	11

	Predicted	
	Cat	Non-cat

Actual	Cat	5 TP	3 FN
	Non-cat	2 FP	17 N

4.Precision và recall

- Với bài toán phân loại mà tập dữ liệu của các lớp là chênh lệch nhau rất nhiều, có một phép hiệu quả thường được sử dụng là Precision-Recall.
- Trước hết xét bài toán phân loại nhị phân. Ta cũng coi một trong hai lớp là *positive*, lớp còn lại là *negative*.
- Với một cách xác định một lớp là *positive*, Precision được định nghĩa là tỉ lệ số điểm true positive trong số những điểm được phân loại là *positive* (TP + FP).
- Recall được định nghĩa là tỉ lệ số điểm true positive trong số những điểm thực sự là *positive* (TP + FN).

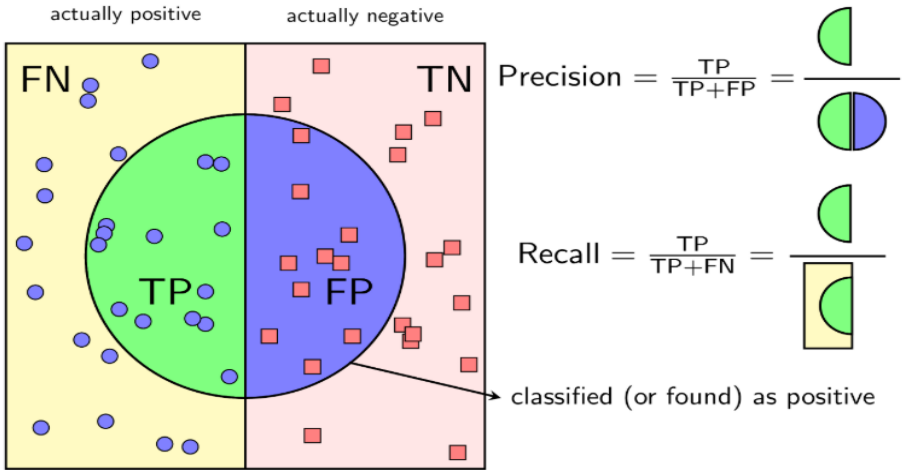

- Precision cao đồng nghĩa với việc độ chính xác của các điểm tìm được là cao.
- Recall cao đồng nghĩa với việc True Positive Rate cao, tức tỉ lệ bỏ sót các điểm thực sự *positive* là thấp.
- Khi Precision = 1, mọi điểm tìm được đều thực sự là *positive*, tức không có điểm *negative* nào lẫn vào kết quả.
- Tuy nhiên, Precision = 1 không đảm bảo mô hình là tốt, vì câu hỏi đặt ra là liệu mô hình đã tìm được tất cả các điểm *positive* hay chưa. Nếu một mô hình chỉ tìm được đúng một điểm *positive* mà nó chắc chắn nhất thì ta không thể gọi nó là một mô hình tốt.

- Khi Recall = 1, mọi điểm *positive* đều được tìm thấy. Tuy nhiên, đại lượng này lại không đo liệu có bao nhiêu điểm *negative* bị lẫn trong đó. Nếu mô hình phân loại mọi điểm là *positive* thì chắc chắn Recall = 1.
- Một mô hình phân lớp tốt là mô hình có cả Precision và Recall đều cao, tức càng gần một càng tốt.

- Khi Recall = 1, mọi điểm *positive* đều được tìm thấy. Tuy nhiên, đại lượng này lại không đo liệu có bao nhiêu điểm *negative* bị lẫn trong đó. Nếu mô hình phân loại mọi điểm là *positive* thì chắc chắn Recall = 1.
- Một mô hình phân lớp tốt là mô hình có cả Precision và Recall đều cao, tức càng gần một càng tốt.

1. F1-score

$$\frac{2}{F_1} = \frac{1}{\text{precision}} + \frac{1}{\text{recall}} \text{ hay } F_1 = 2\frac{1}{\frac{1}{\text{precision}} + \frac{1}{\text{recall}}} = 2\frac{\text{precion} \cdot \textit{recall}}{\text{precision} + \text{recall}}$$

F1 score có giá trị nằm trong nửa khoảng (0,1]. F1 càng cao, bộ phân lớp càng tốt. Khi cả recall và precision đều bằng 1 (tốt nhất có thể), F1=1.

precision	recall	F_1
1	1	1
0.1	0.1	0.1
0.5	0.5	0.5
1	0.1	0.182
0.3	0.8	0.36

Như vậy, một bộ phân lớp với precision = recall = 0.5 tốt hơn một bộ phân lớp khác với precision = 0.3, recall = 0.8 theo cách đo này.

Câu hỏi

1. Học máy được chia thành những kỹ thuật học nào.
2. Trình bày kỹ thuật học có giám sát.
3. Trình bày kỹ thuật học không có giám sát.
4. Trình bày kỹ thuật cây quyết định, cho ví dụ.
5. Trình bày kỹ thuật Boosting.
6. Trình bày kỹ thuật mạng nơron.
7. Trình bày kỹ thuật phân loại SVM

8. Trình bày ứng dụng phân loại SVM

9. Lập trình kỹ thuật SVM

10. Trình bày các bài toán thực tế sử dụng các phương pháp nhận dạng đã học