Chủ đề 9: Kỹ thuật nhận dạng

1. Mục tiêu

Bài học cung cấp các kiến thức tổng quan về các kỹ thuật nhận dạng, tập trung vào kỹ thuật máy véc tơ hỗ trợ, và giới thiệu các độ đo để đánh giá các hệ thống xử lý ảnh.

2. Nội dung

- Giới thiệu
- Phương pháp máy vecto hỗ trợ
- Các độ đo hệ thống

3. Giao nhiệm vụ

Làm bài kiểm tra trắc nghiệm trên hệ thống LMS

Kỹ thuật nhận dạng

Kỹ thuật nhận dạng

- Kết hợp các phương pháp trí tuệ nhân tạo với xử lý đặc trưng ảnh vào việc phát hiện, nhận dạng và định danh đối tượng.
- Các kỹ thuật học máy liên quan:
  - Cây quyết định
  - Mạng nơron
  - SVM
  - Boosting
  - Rừng ngẫu nhiên

9.1. Giới thiệu

- Nhận dạng đối tượng nhằm mục đích phân loại các mẫu dựa trên kiến thức có trước về đối tượng hoặc dựa vào thông tin thống kê, đo lường được trích rút ra từ các mẫu trong tập dữ liệu huấn luyện
- Lĩnh vực nhận dạng đối tượng liên quan đến các phương pháp, kỹ thuật của xử lý ảnh và học máy

9.1. Giới thiệu

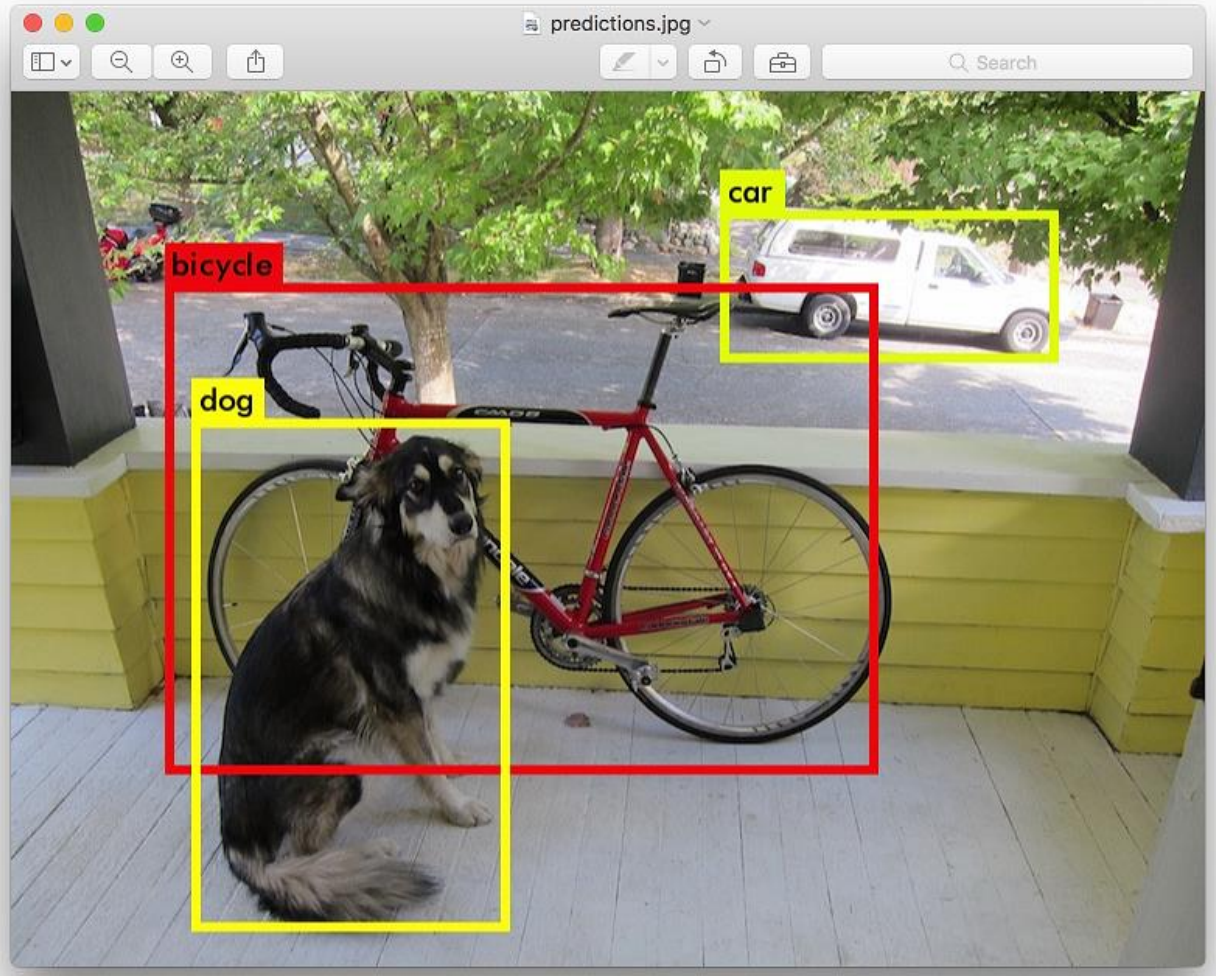

9.1. Giới thiệu

- Các mẫu dữ liệu thường được số hóa và biểu diễn thành vector đặc trưng trong một không gian đa chiều tương ứng, được gọi là không gian đặc trưng
- Nhờ vào vector đặc trưng này để có thể phân tích, đánh giá nhằm xây dựng được mô hình đối tượng phục vụ phân loại, nhận dạng chúng

Đặc trưng

- Vector đặc trưng (Feature vectors)

Thông thường một đối tượng có thể biểu diễn một vài đặc trưng.

x1= shape (thông tin cạnh)

x2 = size (các giá trị thực)

x3 = color (các giá trị màu rgb)

.....

xd = các đặc trưng khác (các giá trị thực)

x trở thành một vector đặc trưng

x là một điểm trong không gian đặc trưng d chiều

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \cdot \\ \cdot \\ \cdot \\ x_d \end{bmatrix}$$

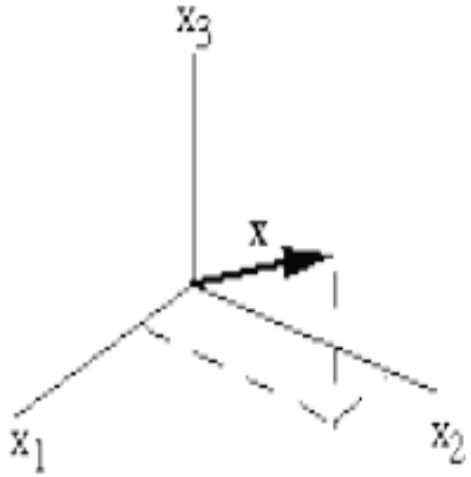

9.1. Giới thiệu

Các phương pháp học

- Supervise learning (Học có giám sát)
- Unsupervised learning (Học không có giám sát)
- Semi-supervised learning (học bán giám sát)
- Reinforcement learning (học củng cố)

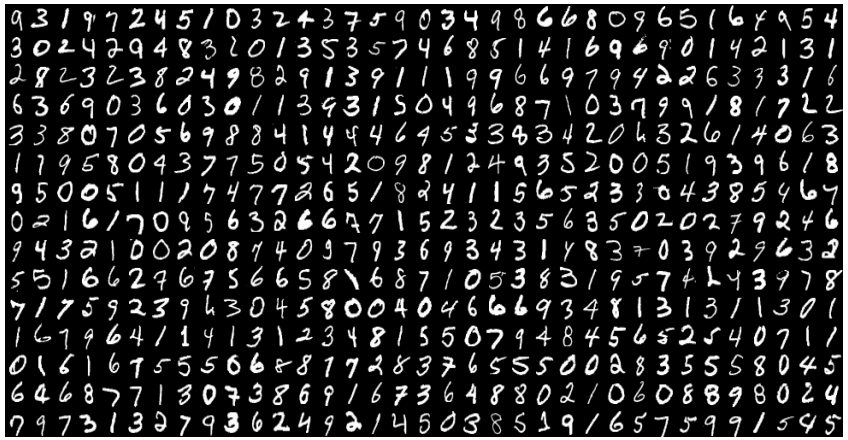

MNIST: *bộ cơ sở dữ liệu của chữ số viết tay.*

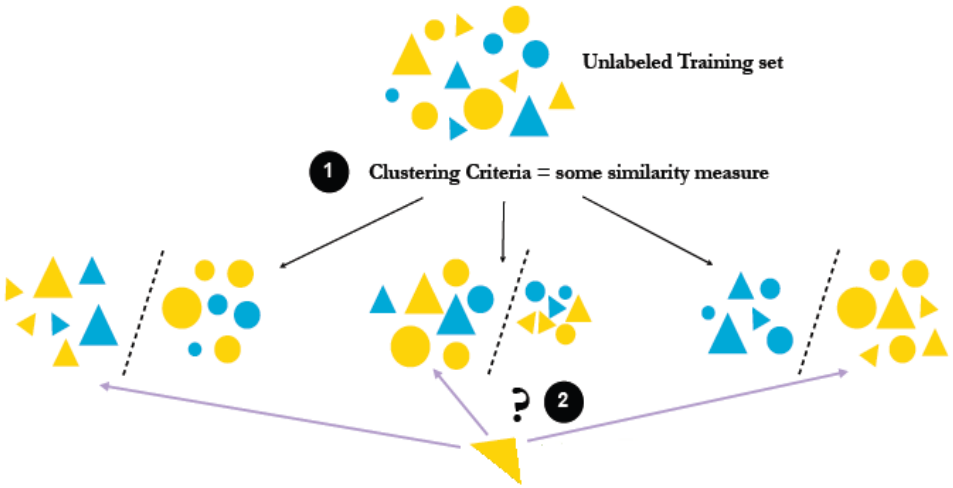

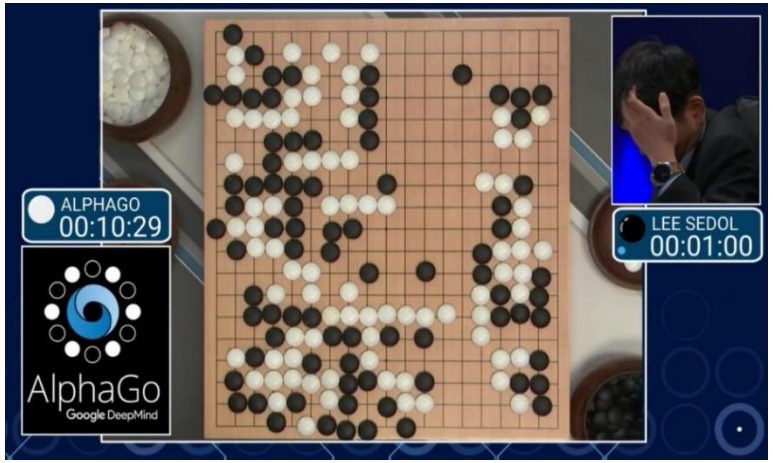

9.1. Giới thiệu

- Trong nhận dạng, các phương pháp học máy có giám sát và không giám sát đều được nghiên cứu và ứng dụng
- Các kỹ thuật học máy có giám sát thường được sử dụng như cây quyết định, mạng neural, SVM, Boosting, rừng ngẫu nhiên (random forest).

9.1. Giới thiệu

- Nhận dạng theo học máy có giám sát thì việc phân loại thường dựa vào tập dữ liệu mẫu đã được gán nhãn theo các lớp bởi các ‘chuyên gia’ để phân tích và xây dựng mô hình nhận dạng
- Tập dữ liệu mẫu để học được gọi là tập dữ liệu huấn luyện và quá trình phân tích, xây dựng mô hình đối tượng được gọi là quá trình huấn luyện máy nhận dạng hay huấn luyện mô hình

9.1. Giới thiệu

- Phương pháp học không có giám sát, tập dữ liệu phân loại không cần được gán nhãn trước mà bản thân thuật toán phải tự phân loại, xác định lớp của đối tượng dựa vào phân tích, thống kê từ các đặc trưng của tập mẫu dữ liệu đưa vào.

Mô hình chung cho các bài toán nhận dạng

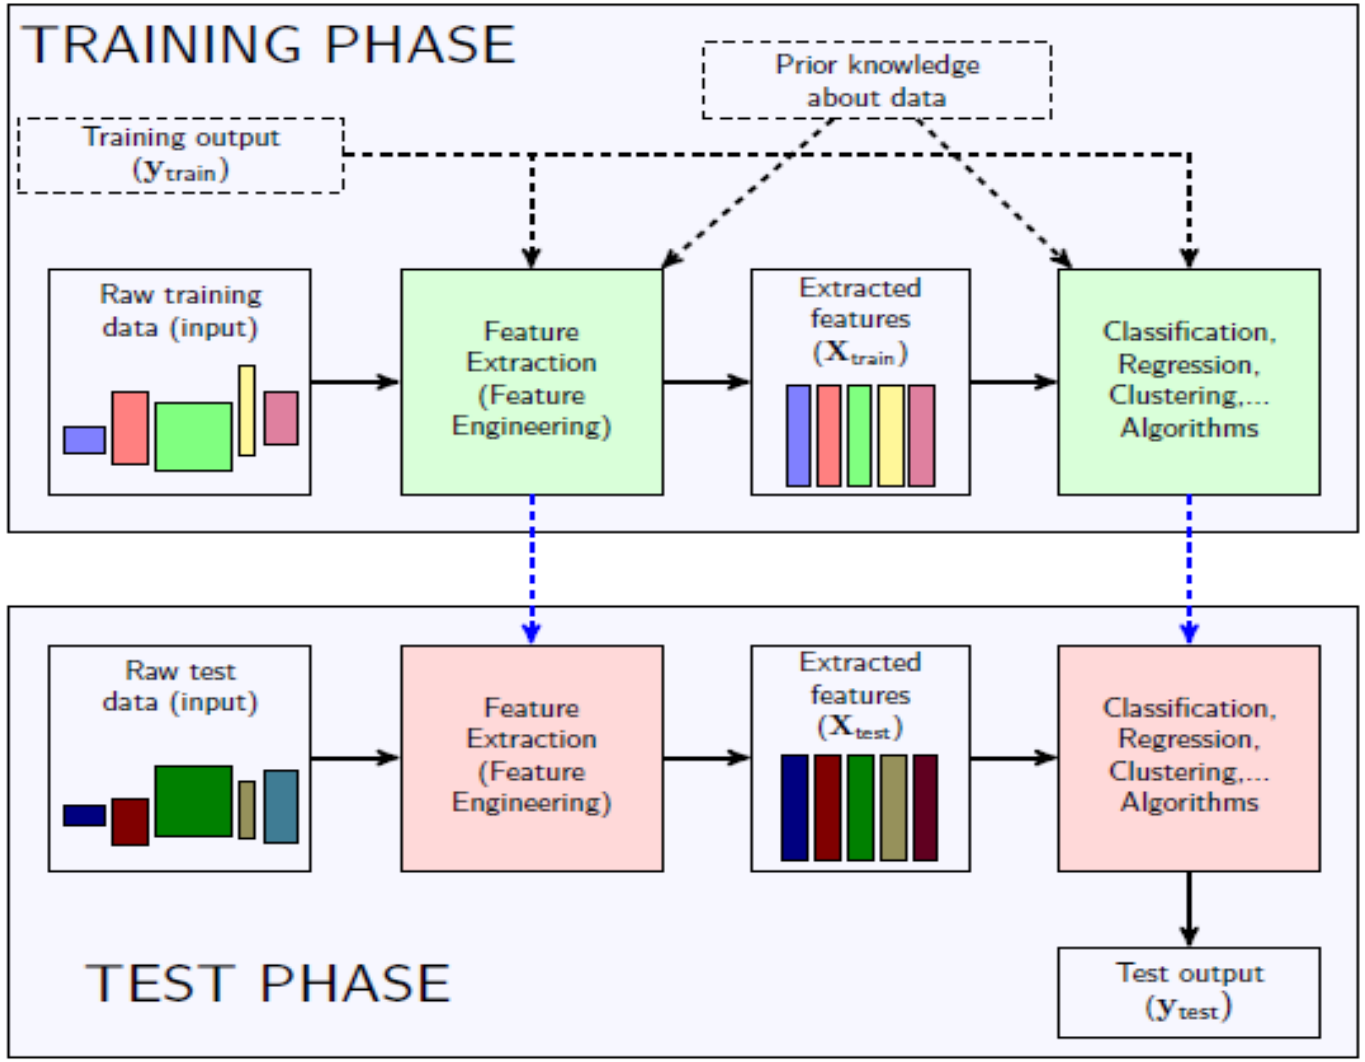

Cây quyết định (decision tree)

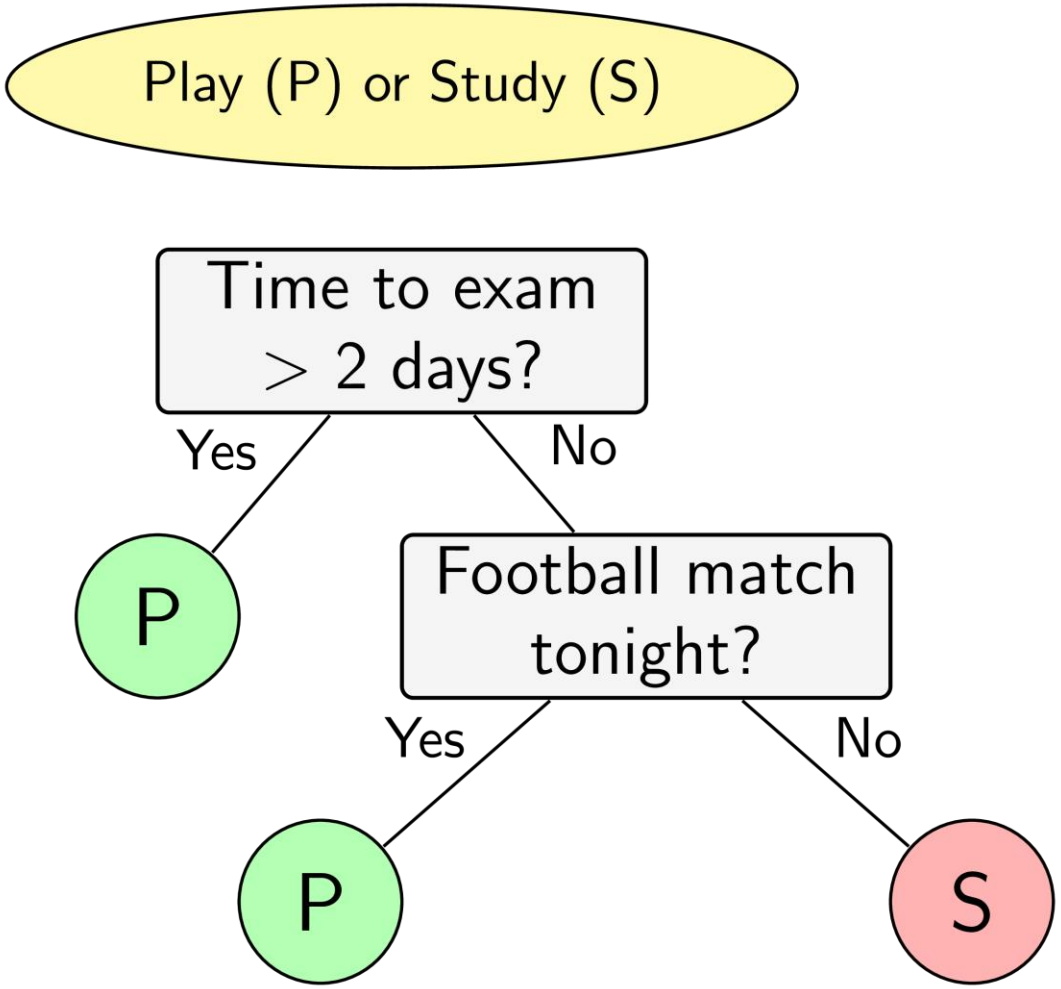

Cây quyết định (decision tree)

- Việc quan sát, suy nghĩ và ra các quyết định của con người thường được bắt đầu từ các câu hỏi. Machine learning cũng có một mô hình ra quyết định dựa trên các câu hỏi. Mô hình này có tên là *cây quyết định* (*decision tree*).

Cây quyết định (decision tree)

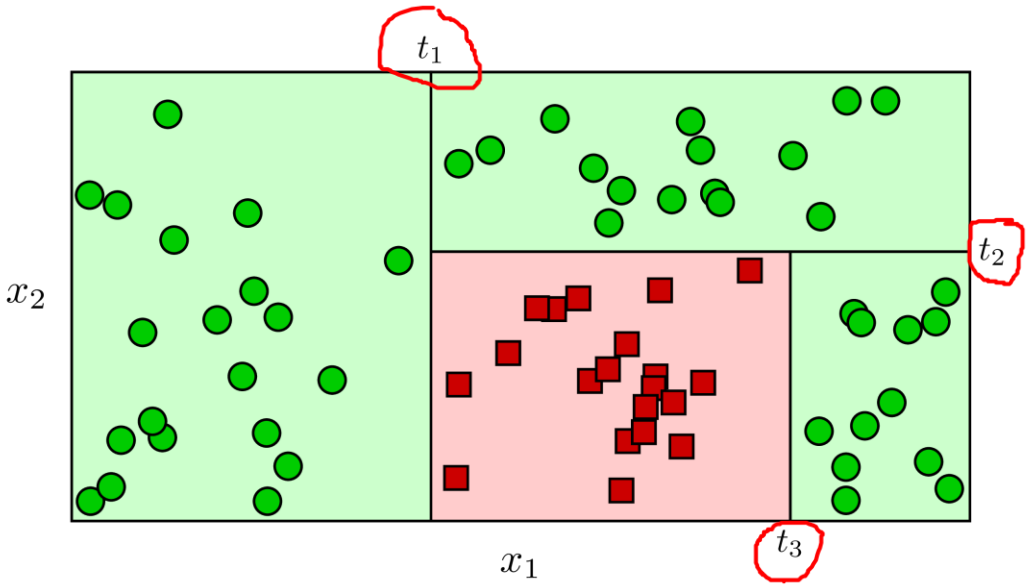

(a)

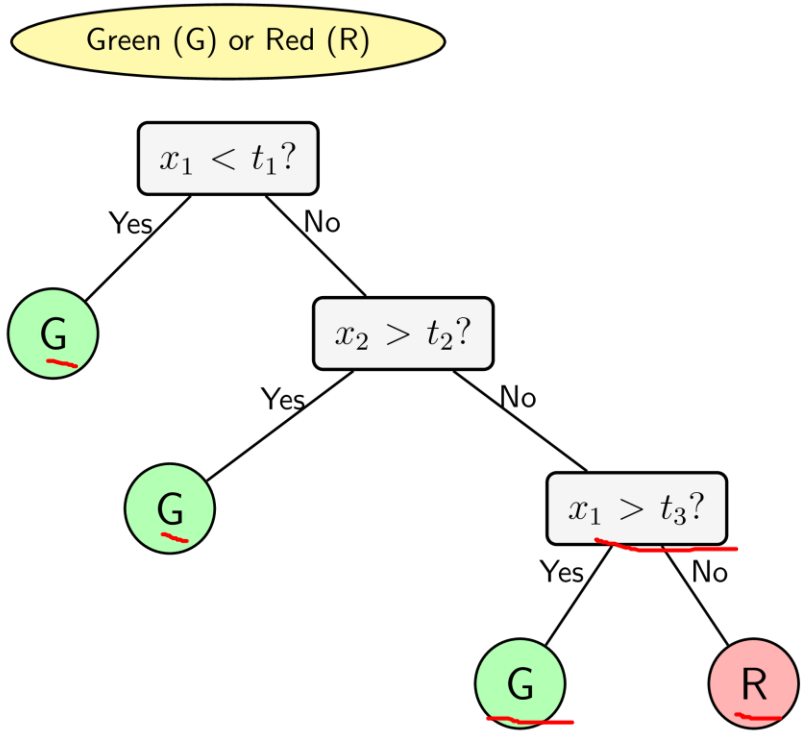

(b)

Cây quyết định (decision tree)

- Cây quyết định là một kiểu mô hình dự báo, được xây dựng trên cơ sở cấu trúc cây, dùng để phân lớp các mẫu dữ liệu dựa vào chuỗi các luật suy diễn.
- Các nút lá đại diện cho các quyết định phân loại, các nhánh đại diện cho luật kết hợp các thuộc tính để dẫn tới phân loại nào đó.
- Một cây quyết định có thể được huấn luyện bằng cách chia tập dữ liệu huấn luyện thành các tập con để kiểm tra theo từng giá trị thuộc tính đơn hoặc một nhóm các thuộc tính.

Cây quyết định (decision tree)

- Việc phân loại có thể được mô tả như là các kết hợp phân loại đơn giản bằng cách sử dụng kỹ thuật suy diễn toán học
- Quá trình huấn luyện mô hình phân loại là quá trình xây dựng cây quyết định. Hiện nay có nhiều phương pháp xây dựng cây quyết định cho bài toán phân loại đối tượng như ID3, C4.5,...

Rừng ngẫu nhiên (Random Forest)

- Rừng ngẫu nhiên (randomforest-RF) được phát triển chủ yếu dựa vào tập các cây quyết định (decisiontree) được xây dựng bằng cách lựa chọn ngẫu nhiên các tập con thuộc tính từ tập thuộc tính ban đầu. Việc lựa chọn tập con thuộc tính ngẫu nhiên không nhất thiết phải tách rời nhau. Như vậy việc lựa chọn thuộc tính và xây dựng mỗi cây được thực hiện theo thuật toán có tính chất ngẫu nhiên.

Rừng ngẫu nhiên (Random Forest)

- Rừng ngẫu nhiên cũng là một dạng thuật toán học có giám sát.
- Một số điểm mạnh của thuật toán RF là có thể sử dụng cho cả bài toán phân loại và bài toán hồi quy, có thể xử lý trong trường hợp dữ liệu thiếu giá trị, khi rừng có nhiều cây hơn có thể giúp giải quyết bài toán overfitting với dữ liệu.
- Kỹ thuật rừng ngẫu nhiên được sử dụng nhiều trong lĩnh vực thị giác máy tính, phân loại đối tượng.

Rừng ngẫu nhiên (Random Forest)

- Đầu vào là bộ dữ liệu huấn luyện (X,Y) với X là tập mẫu dữ liệu với m đặc trưng (thuộc tính) và Y là tập nhãn tương ứng;
- Bước1: Chọn ngẫu nhiên k thuộc tính từ tập m thuộc tính với k<<m;
- Bước2: Từ tập k thuộc tính, xác định thuộc tính d có khả năng phân loại “tốt nhất” và tạo ra một nút phân loại;
- Bước3: Chia tập dữ liệu trên tập thuộc tính k theo nút d vừa tìm được;
- Bước4: Lặp lại bước 2 -3 cho đến khi đã xây dựng xong cây với tập thuộc tính k;
- Bước5: Lặp lại bước1-4 để xây dựng tập các cây của rừng ngẫu nhiên.

Rừng ngẫu nhiên (Random Forest)

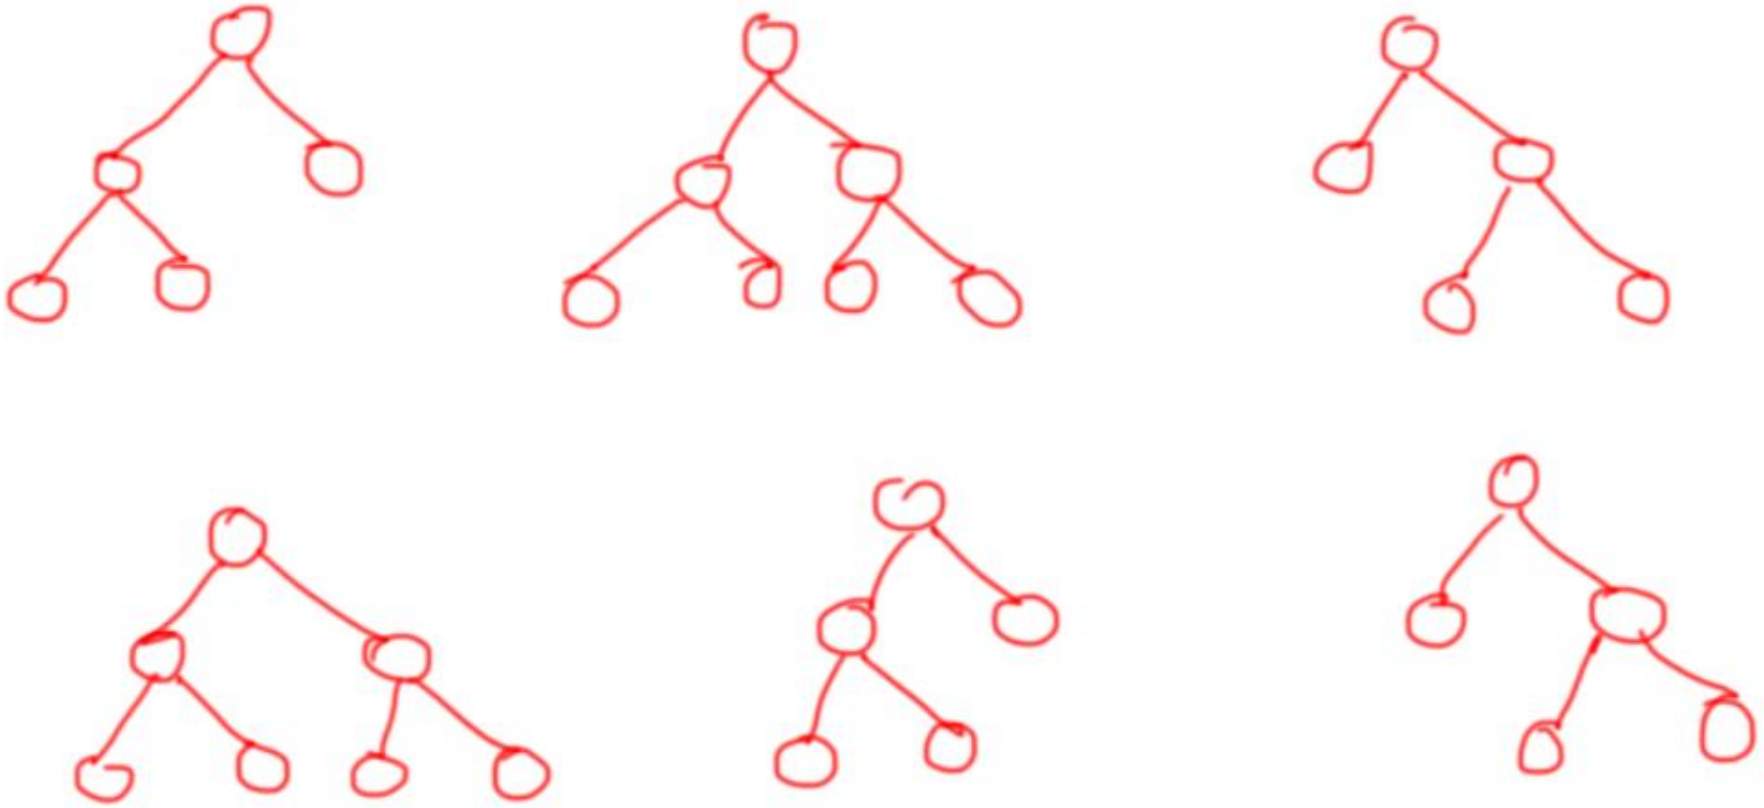

Rừng ngẫu nhiên (Random Forest)

Thuật toán Random Forest có 6 cây quyết định, 5 cây dự đoán 1 và 1 cây dự đoán 0, do đó sẽ vote là cho ra dự đoán cuối cùng là 1.

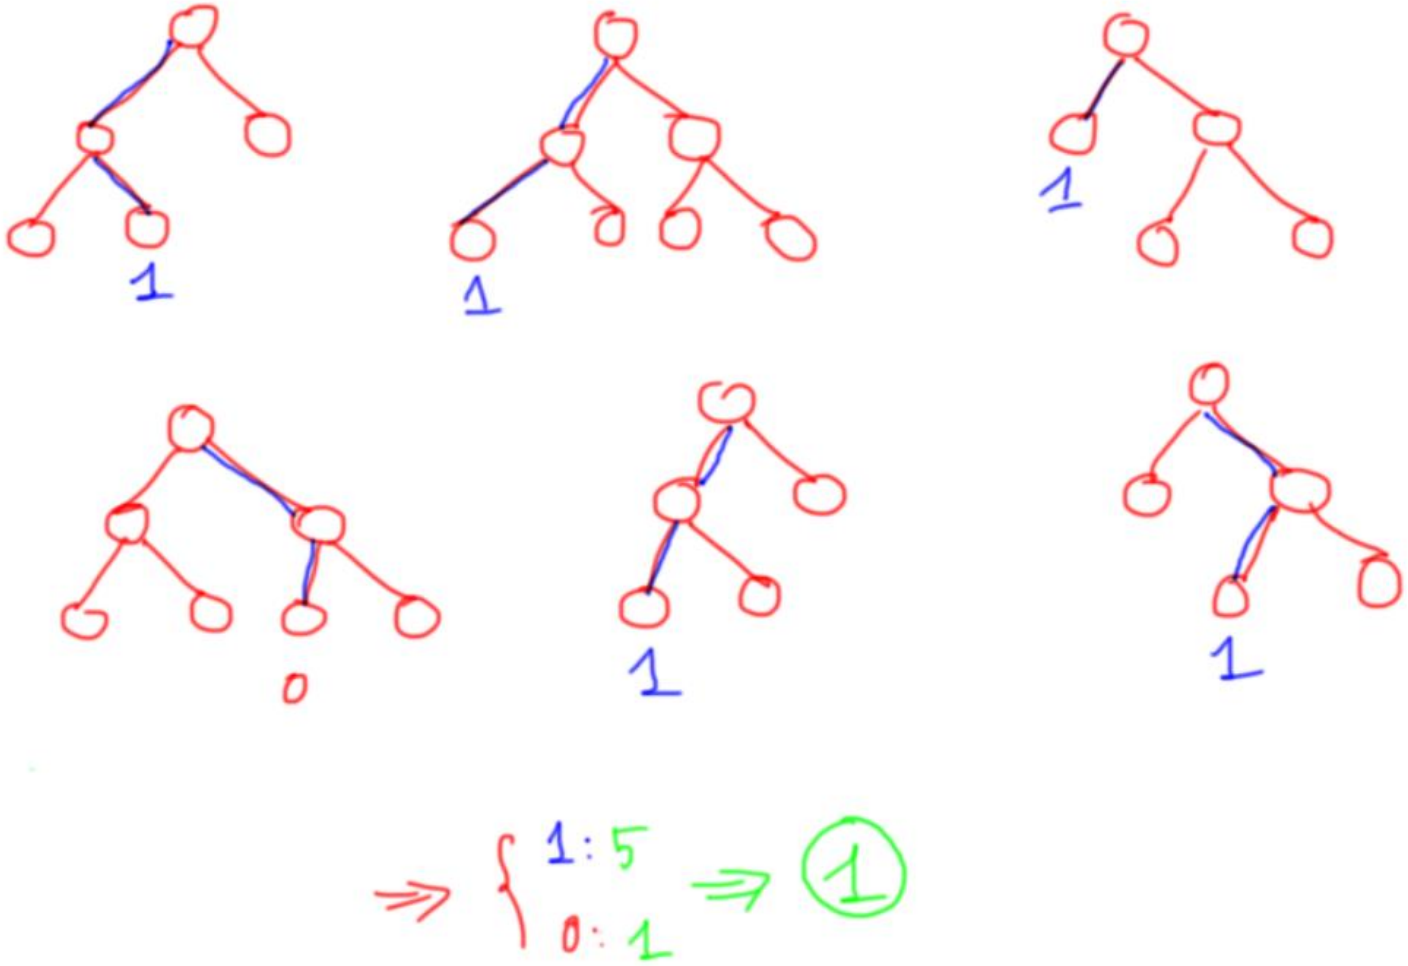

Kỹ thuật Boosting

Một dạng thuật toán học máy quần thể bằng cách xây dựng nhiều bộ phân loại cùng lúc và sau đó kết hợp chúng lại theo trọng số xác định của từng phân loại thành phần.

- Mỗi bộ phân loại thành phần được gọi là phân loại yếu, các bộ phân loại yếu được hợp lại với nhau tạo thành một phân loại mạnh.

Kỹ thuật Boosting

- AdaBoost là bộ phân loại mạnh phi tuyến hoạt động trên nguyên tắc kết hợp các bộ phân loại yếu theo trọng số để tạo ra một bộ phân loại mạnh hơn theo kiểu thích ứng (với mẫu dữ liệu).

- AdaBoost sử dụng các trọng số để đánh dấu các mẫu khó phân loại. Càng vào những mức sâu của phân loại yếu, bộ phân loại càng tập trung vào những mẫu khó phân loại, trong khi những mẫu phân loại dễ sẽ có giá trị ảnh hưởng nhỏ hơn.

Mạng neural nhân tạo (ANN- artificial neural network)

Mạng nơ ron là một hệ thống tính toán lấy cảm hứng từ sự hoạt động của các nơ ron trong hệ thần kinh của con người.

Hoạt động của các nơ ron

- Nơ-ron là đơn vị cơ bản cấu tạo hệ thống thần kinh và là thành phần quan trọng nhất của não.
- Đầu người gồm khoảng 10 triệu nơ-ron và mỗi nơ-ron lại liên kết với tầm 10.000 nơ ron khác.

Mạng neural nhân tạo

- Mỗi nơ-ron có phần thân (soma) chứa nhân, các tín hiệu đầu vào qua sợi nhánh (dendrites) và các tín hiệu đầu ra qua sợi trục (axon) kết nối với các nơ-ron khác.

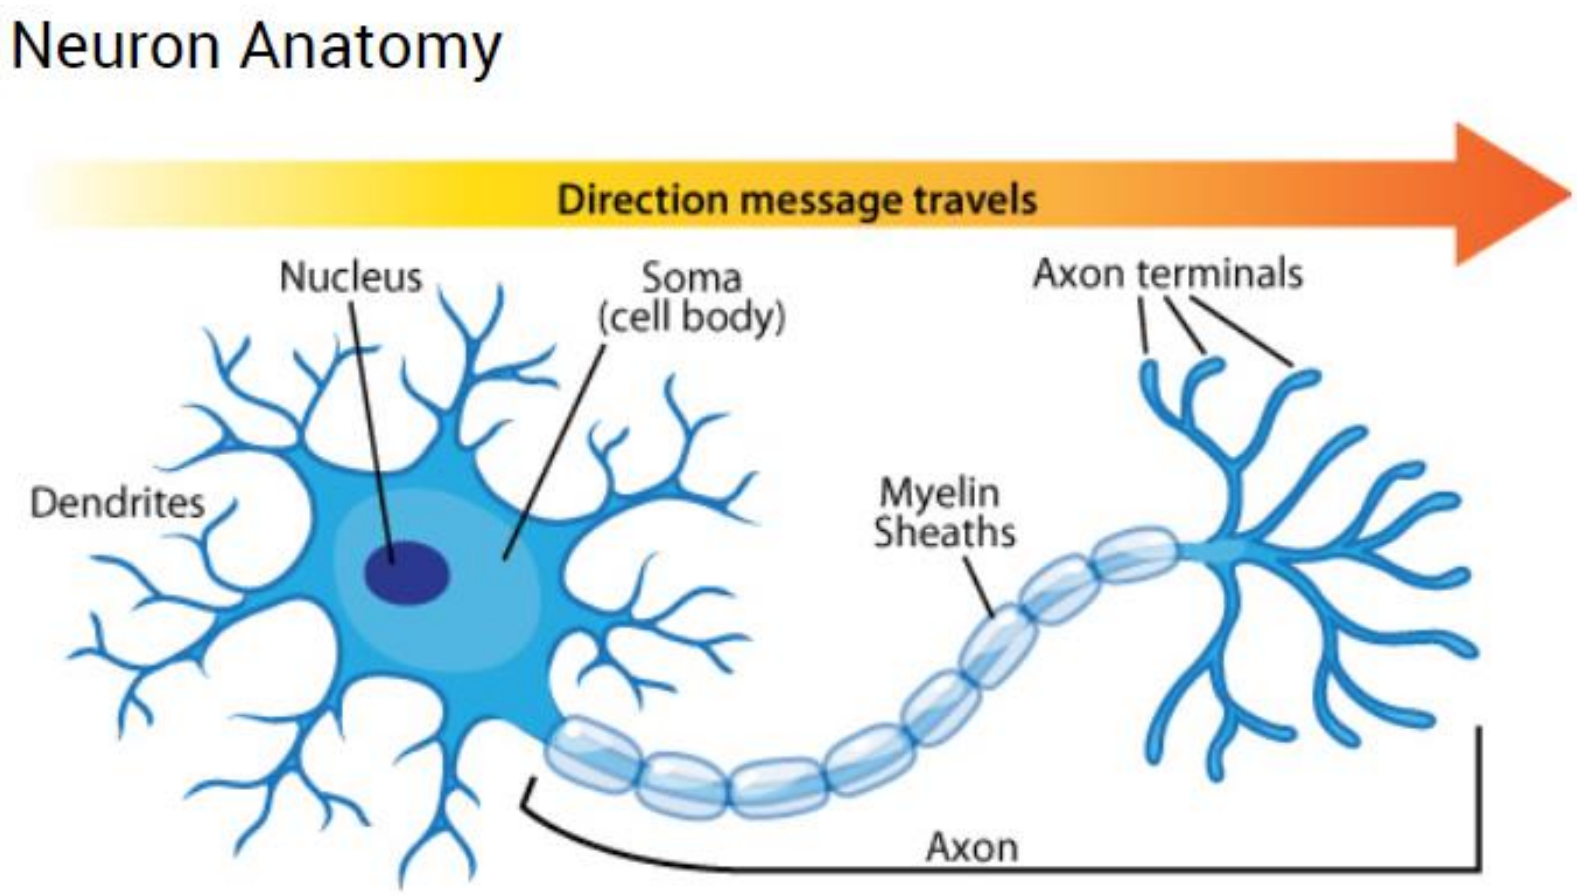

Mạng neural nhân tạo

Logistic regression là mô hình neural network đơn giản nhất chỉ với input layer và output layer

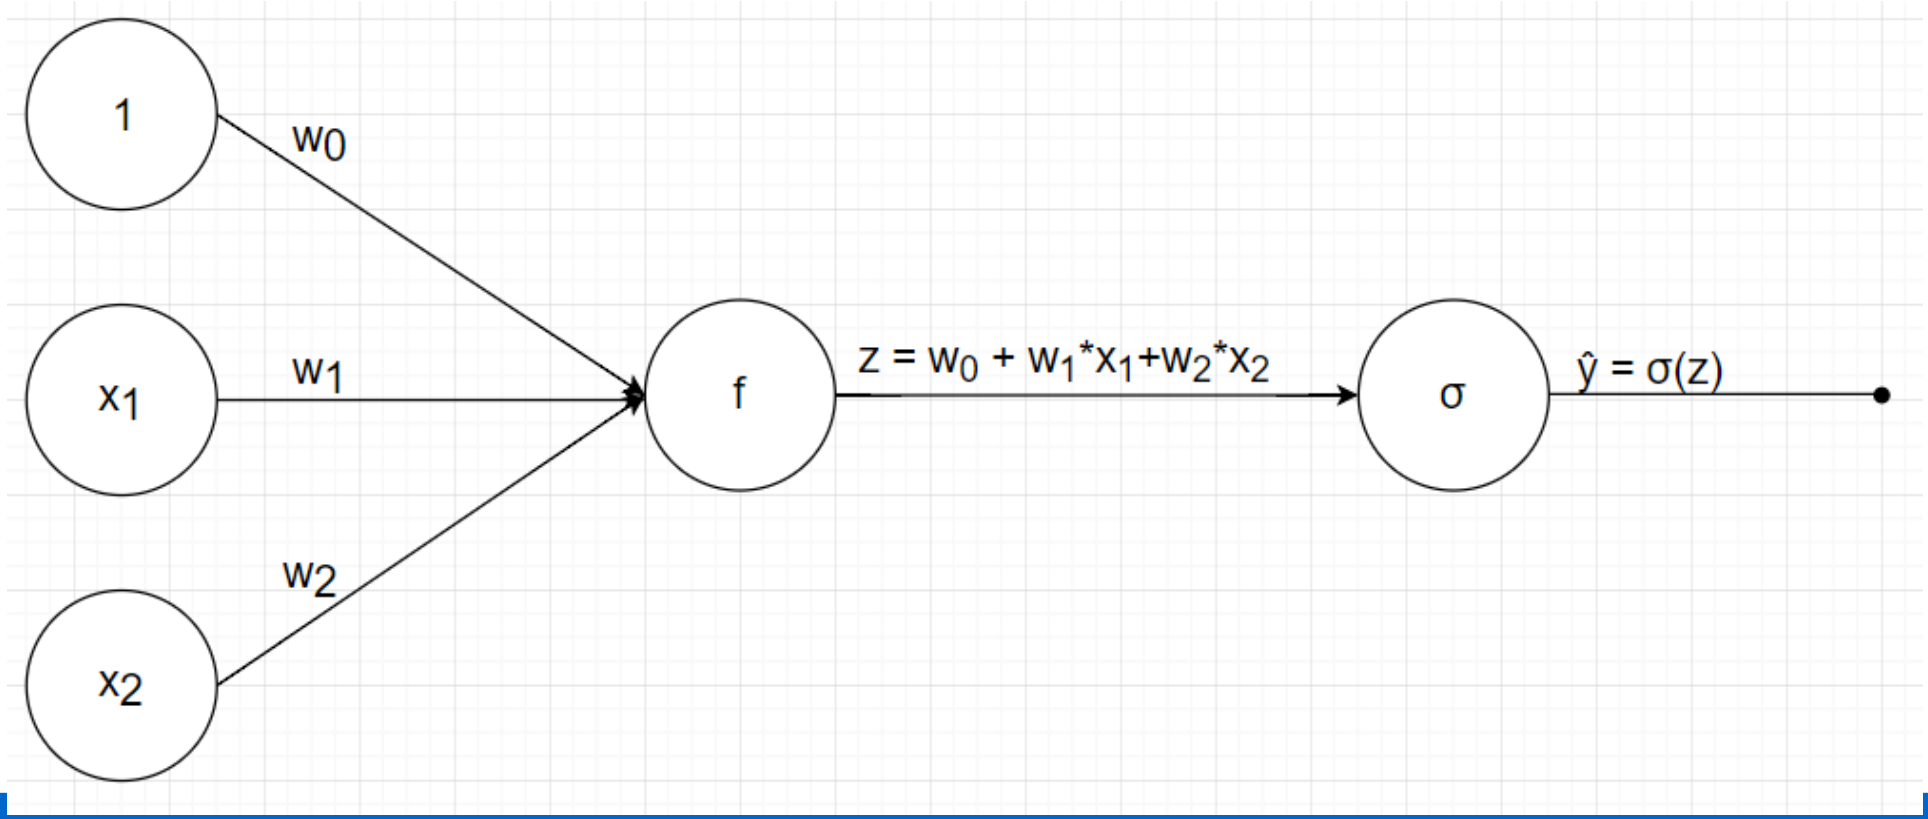

Mạng neural nhân tạo

- Để biểu diễn gọn lại ta sẽ gộp hai bước trên thành một trên biểu đồ sau:

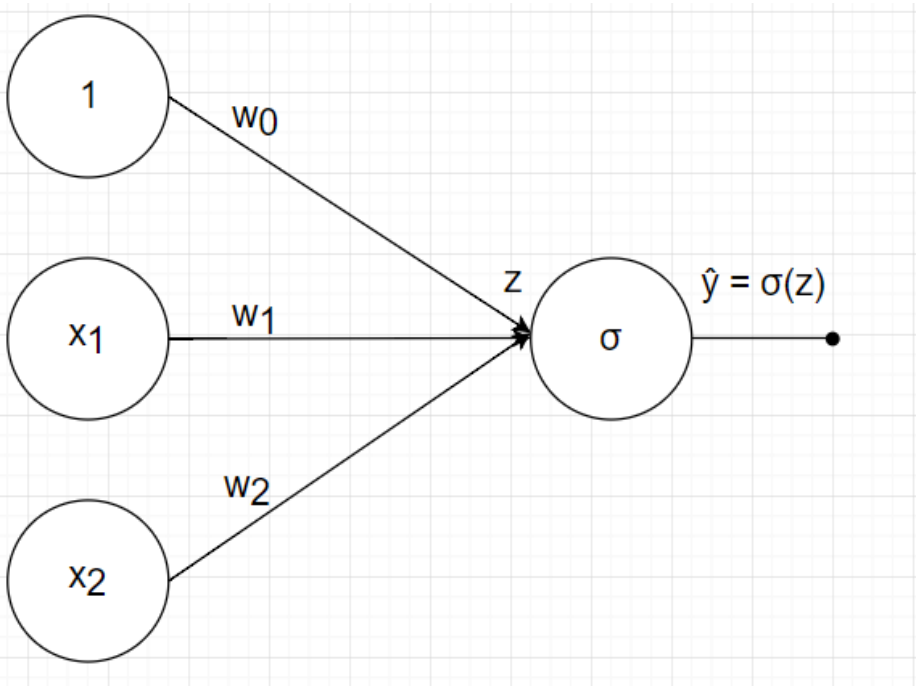

Hệ số w_0 được gọi là bias

Mạng neural nhân tạo

- Layer đầu tiên là input layer
- các layer ở giữa được gọi là hidden layer
- Layer cuối cùng gọi là output layer
- Các hình tròn được gọi là node
- Mỗi mô hình luôn có 1 input layer, 1 output layer, có thể có hoặc không có các hidden layer.
- Tổng số layer trong mô hình được quy ước là số layer-1(không tính input layer)

Mạng neural nhân tạo

- 1 input layer
- 2 hidden layer
- 1 output layer
- Số lượng layer của mô hình là 3 layer

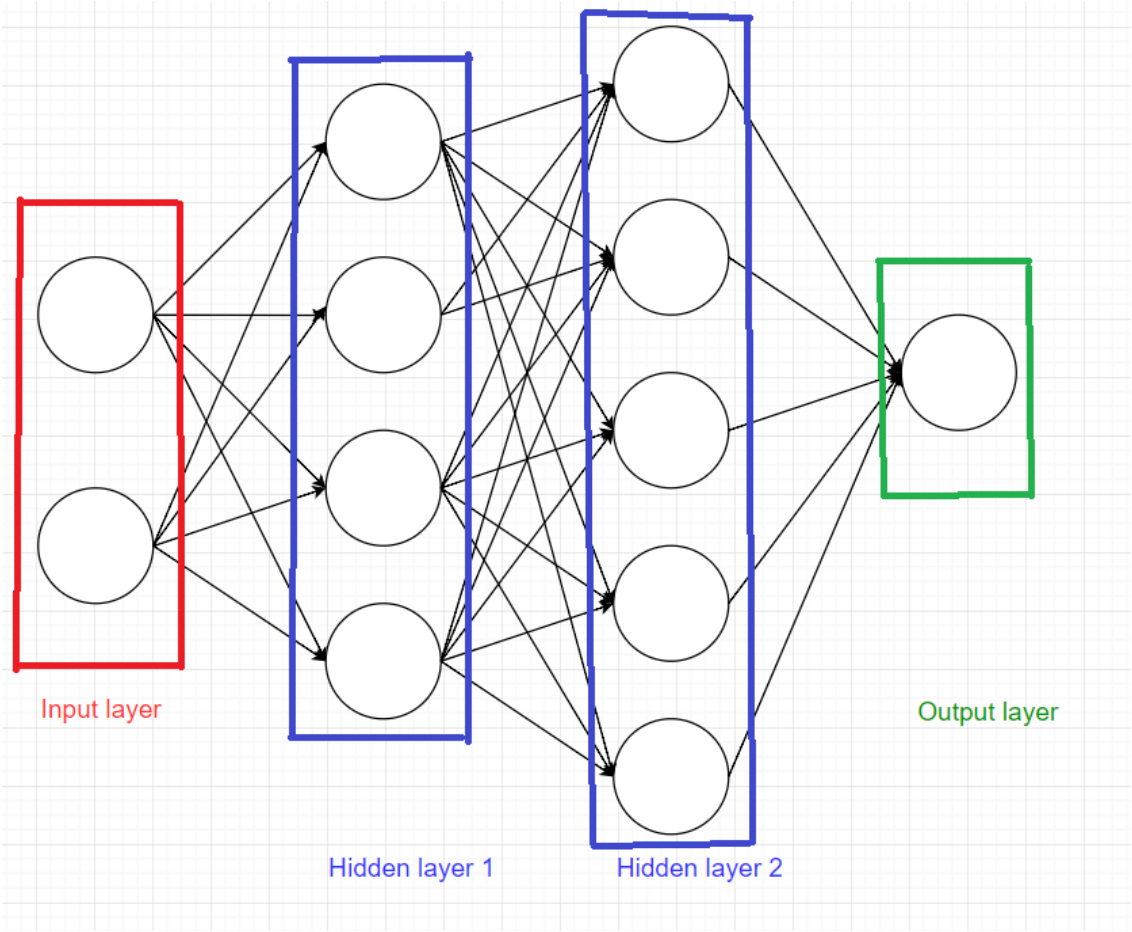

Mạng neural nhân tạo

Mỗi node trong hidden layer và output layer:

- Liên kết với tất cả các node ở layer trước đó với các hệ số w riêng
- Mỗi nút có 1 hệ số bias b riêng
- Diễn ra 2 bước: tính tổng linear và áp dụng activation function.
-

Mạng neural nhân tạo

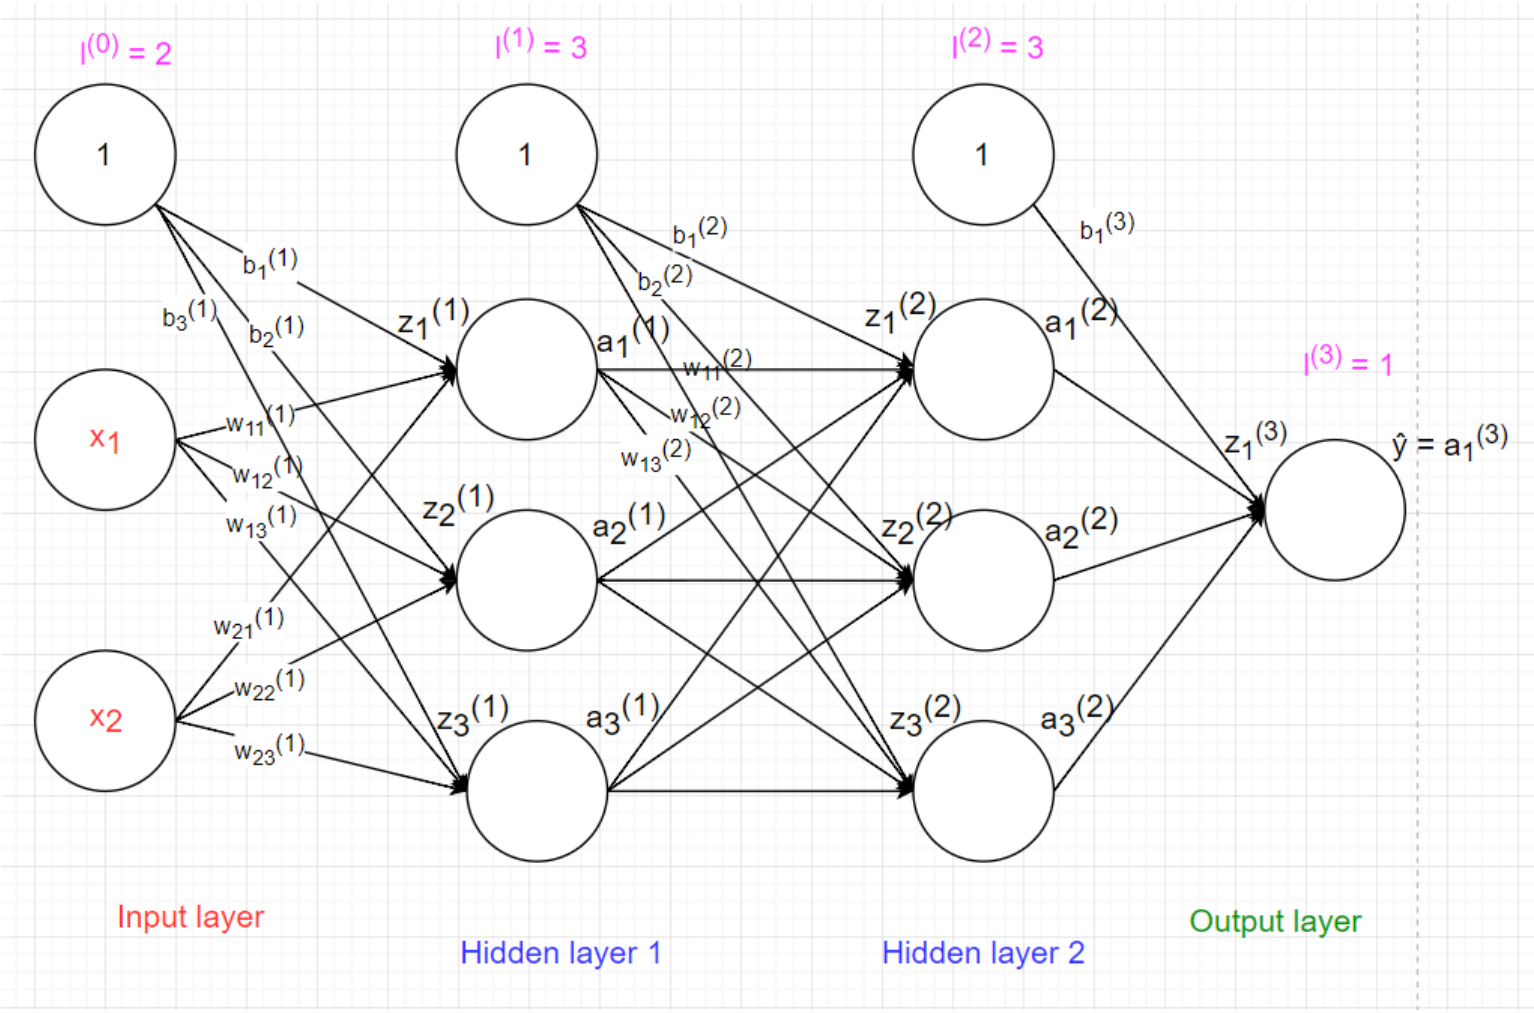

Mạng neural nhân tạo

- Quá trình feedforward

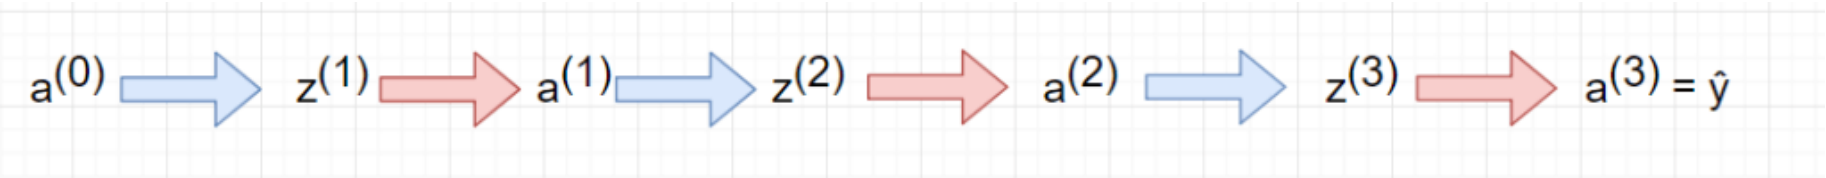

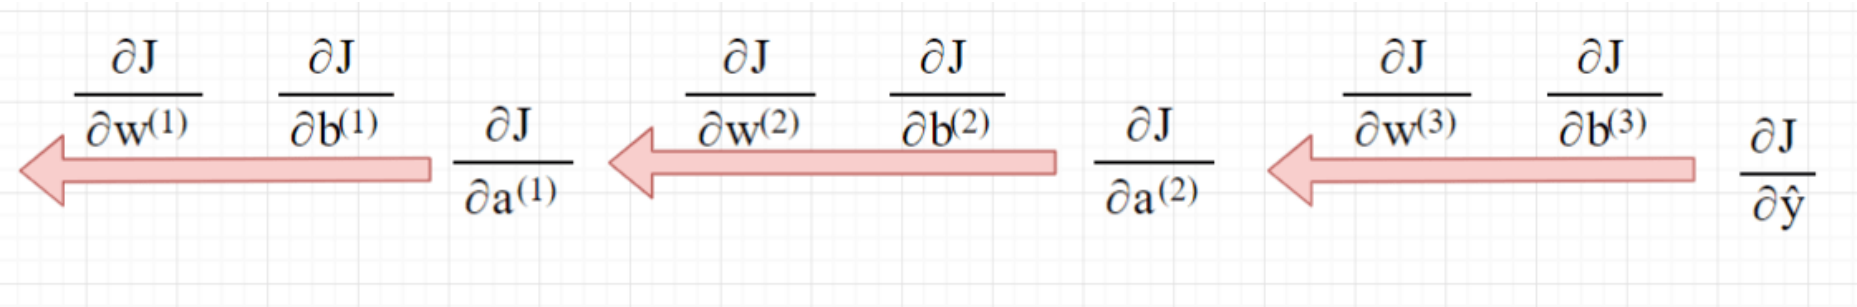

Mạng neural nhân tạo

- Một trong những lợi thế của NN là khả năng được sử dụng như một xấp xỉ hàm tùy ý học từ các mẫu dữ liệu quan sát được.
- Một số yêu cầu chính trong xây dựng mô hình mạng neural là vấn đề chọn mô hình phù hợp bài toán ứng dụng phụ thuộc vào cách mô tả mẫu dữ liệu. Nghĩa là một mô hình quá phức tạp sẽ dẫn đến khó khăn trong quá trình huấn luyện mô hình, trong khi đó những mô hình đơn giản lại không giải quyết được bài toán phức tạp. Vấn đề lựa chọn thuật toán học cũng có ý nghĩa hết sức quan trọng.

Mạng neural nhân tạo

- Thuật toán học chủ yếu liên quan đến việc xây dựng bộ tham số (hyperparameter) và làm sao ước lượng các tham số tối ưu và hội tụ nhanh nhất có thể để phân lớp tốt nhất
- Trong thực tế, lựa chọn và điều chỉnh một thuật toán để huấn luyện trên dữ liệu quan sát yêu cầu một số lượng lớn đáng kể trong thực nghiệm

Mạng nơ ron tích chập-Convolutional neural network

- Convolutional layer

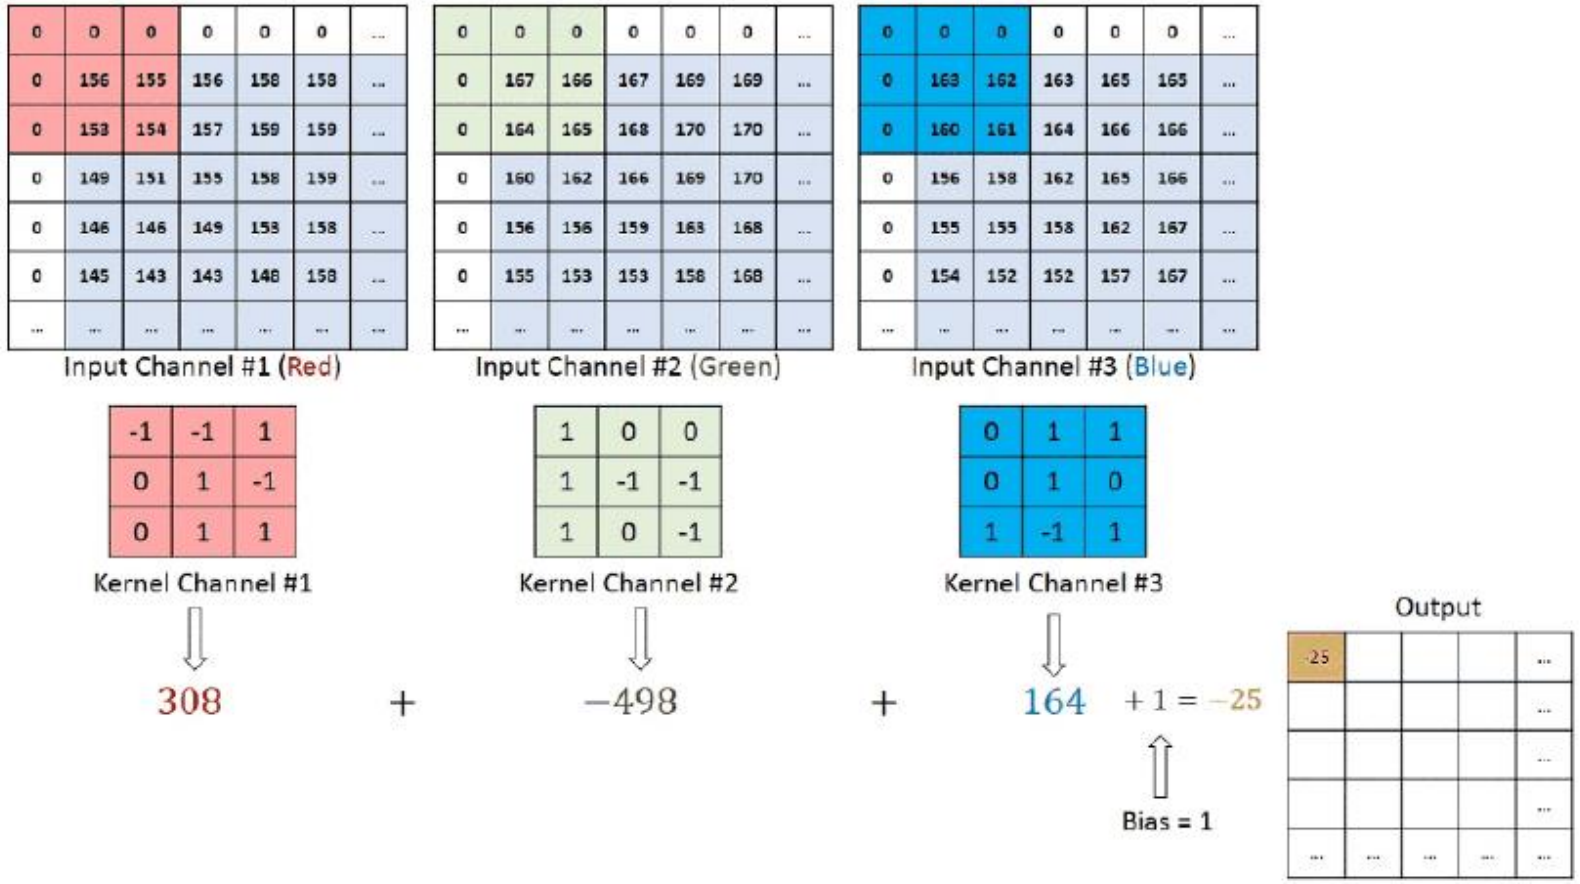

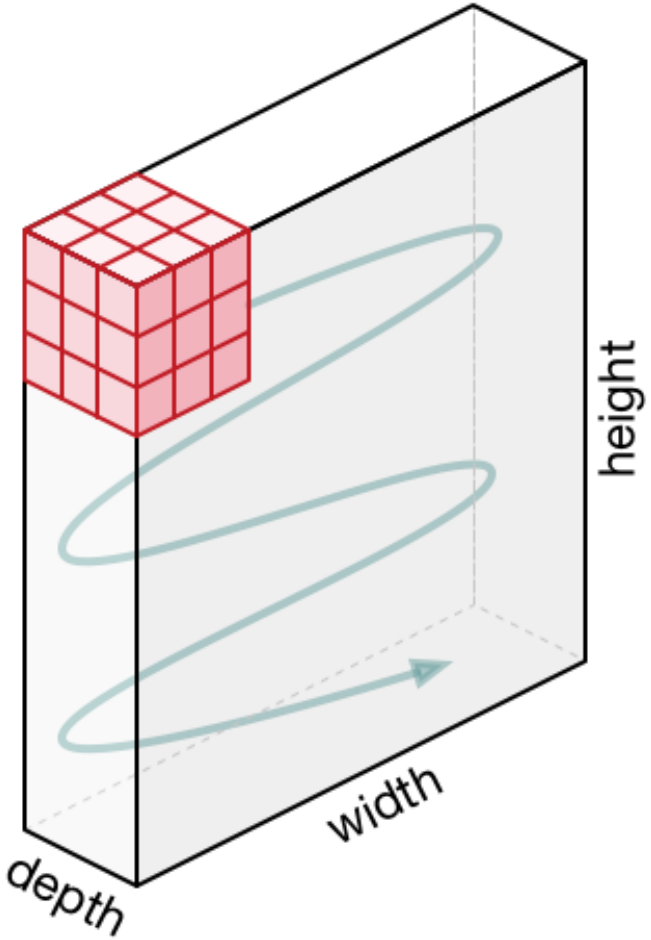

Mạng nơ ron tích chập-Convolutional neural network

- Pooling layer

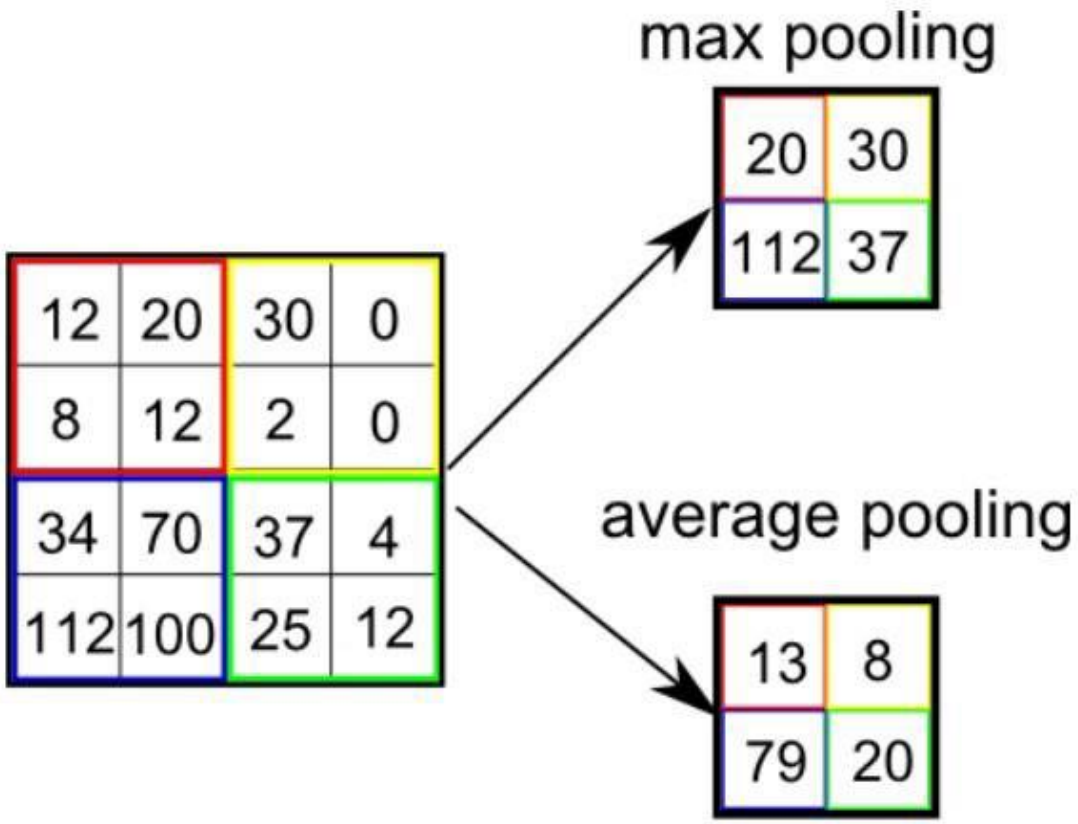

Mạng nơ ron tích chập-Convolutional neural network

- Fully connected layer

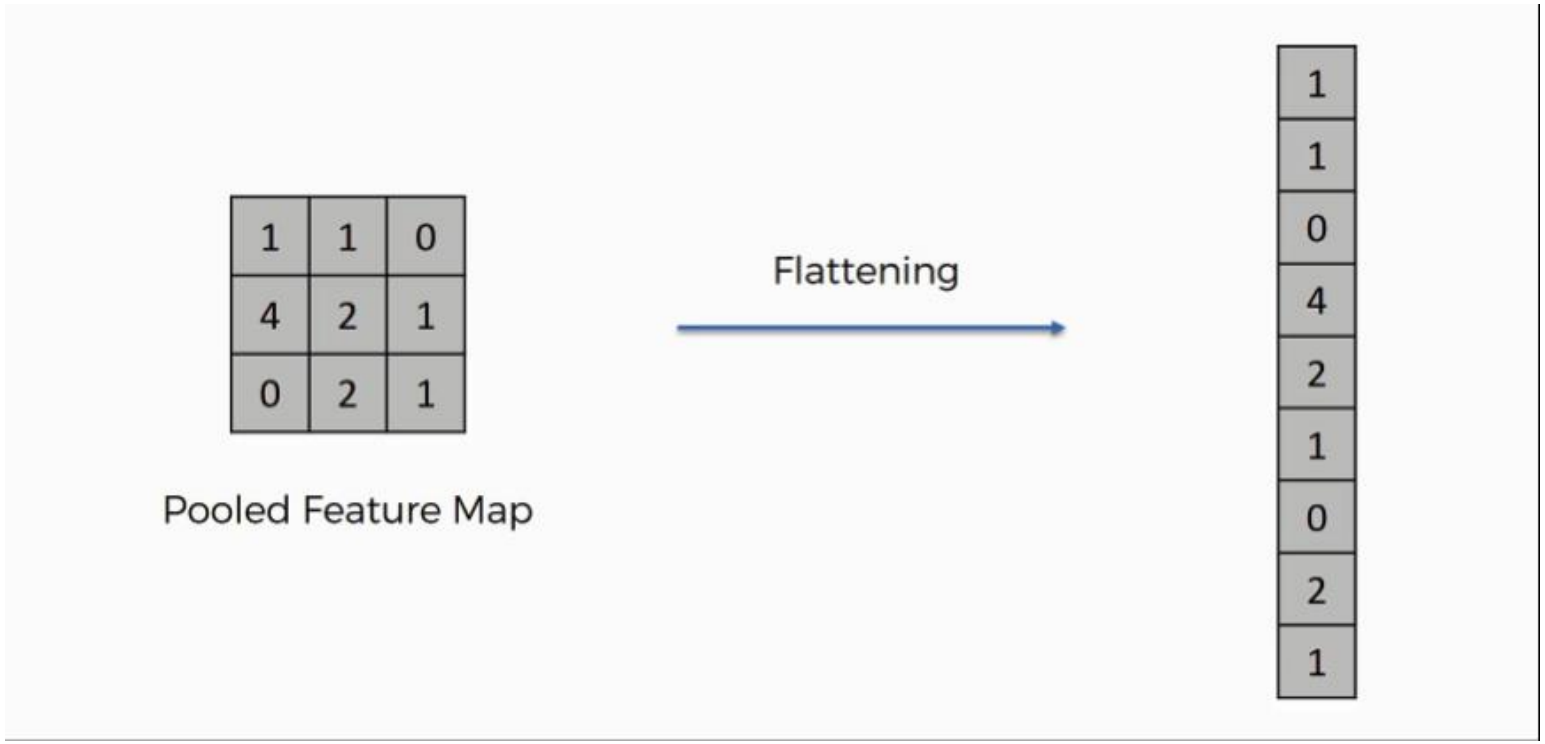

Mạng nơ ron tích chập-Convolutional neural network

LeNet-5

[LeCun et al.,1998]

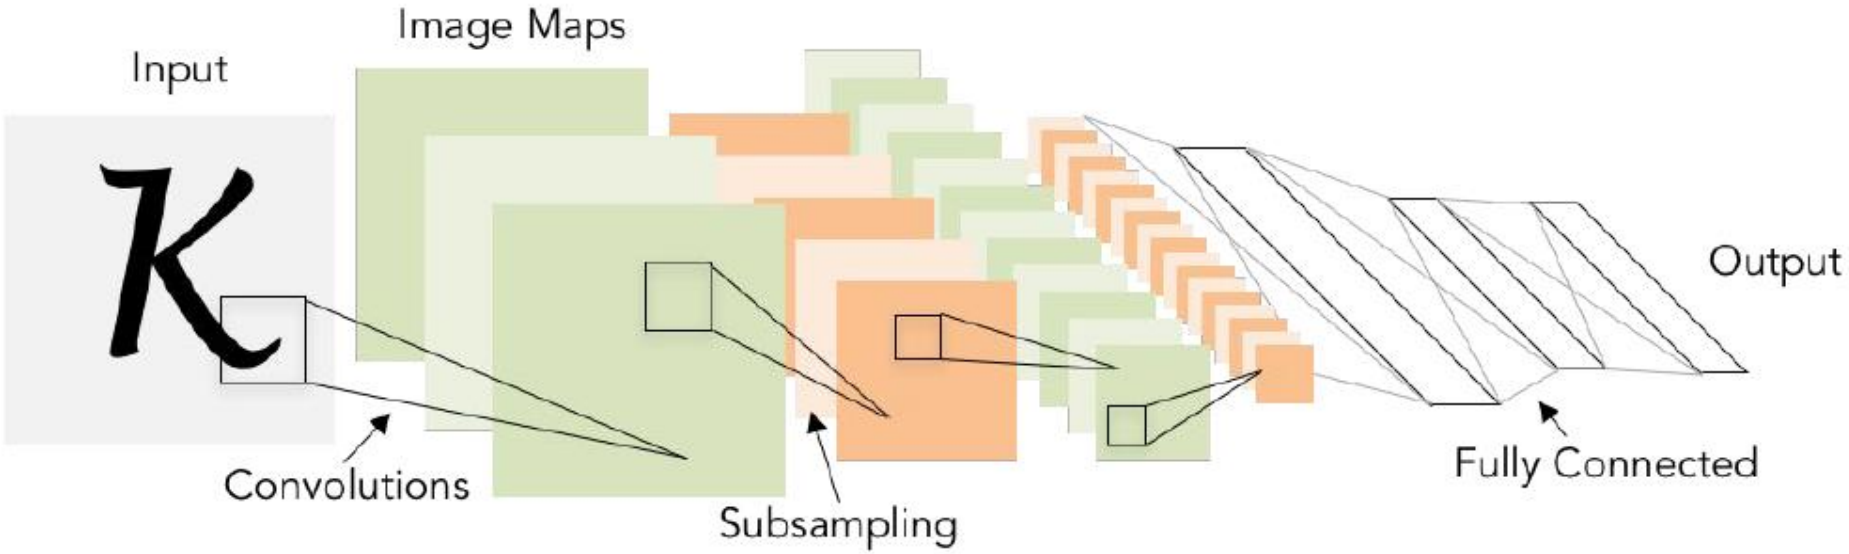

Conv filters were 5x5, applied at stride 1
Subsampling (Pooling) layers were 2x2 applied at stride 2
i.e. architecture is [CONV-POOL-CONV-POOL-FC-FC]

AlexNet

- **Architecture:**
- CONV1
- MAX POOL1
- NORM1
- CONV2
- MAX POOL2
- NORM2
- CONV3
- CONV4
- CONV5
- Max POOL3
- FC6
- FC7
- FC8

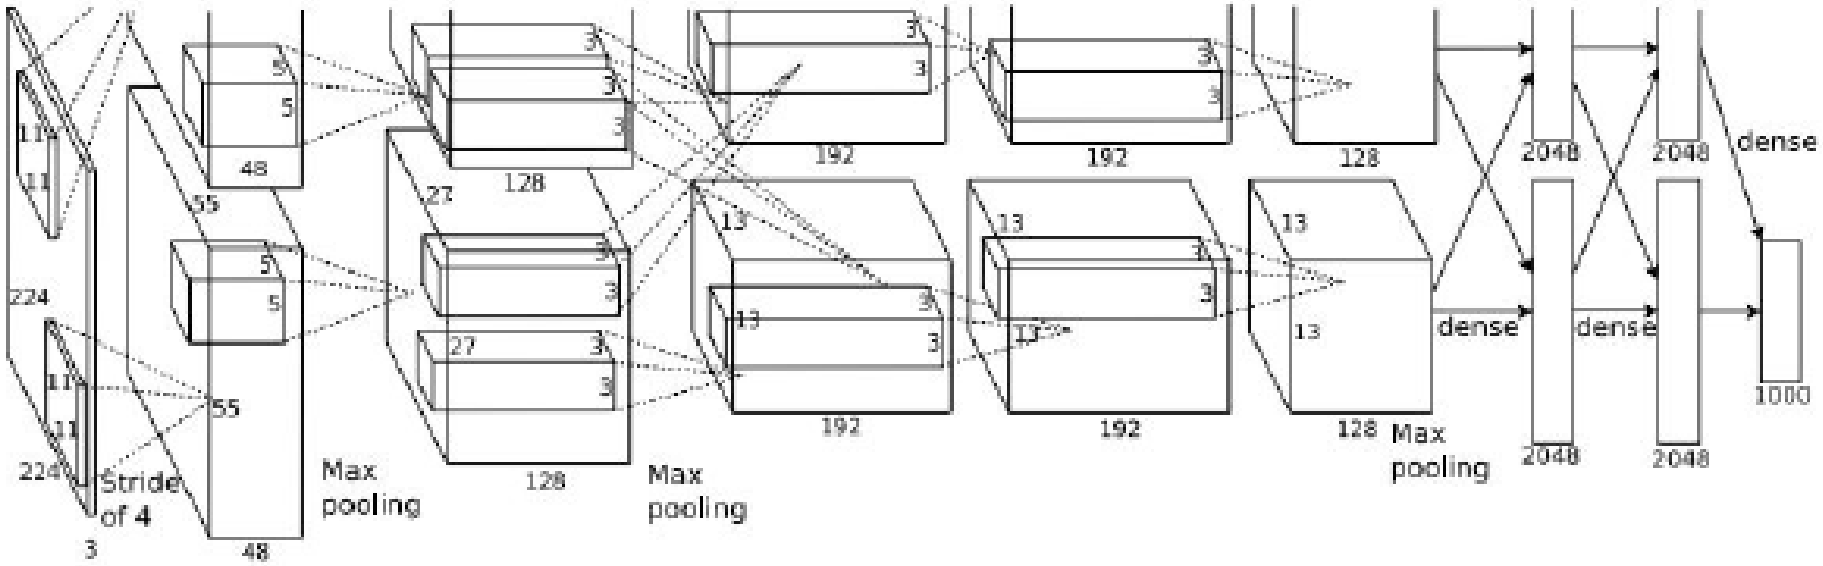

Mạng nơ ron tích chập-Convolutional neural network

ImageNet Large Scale Visual Recognition Challenge (ILSVRC) winners

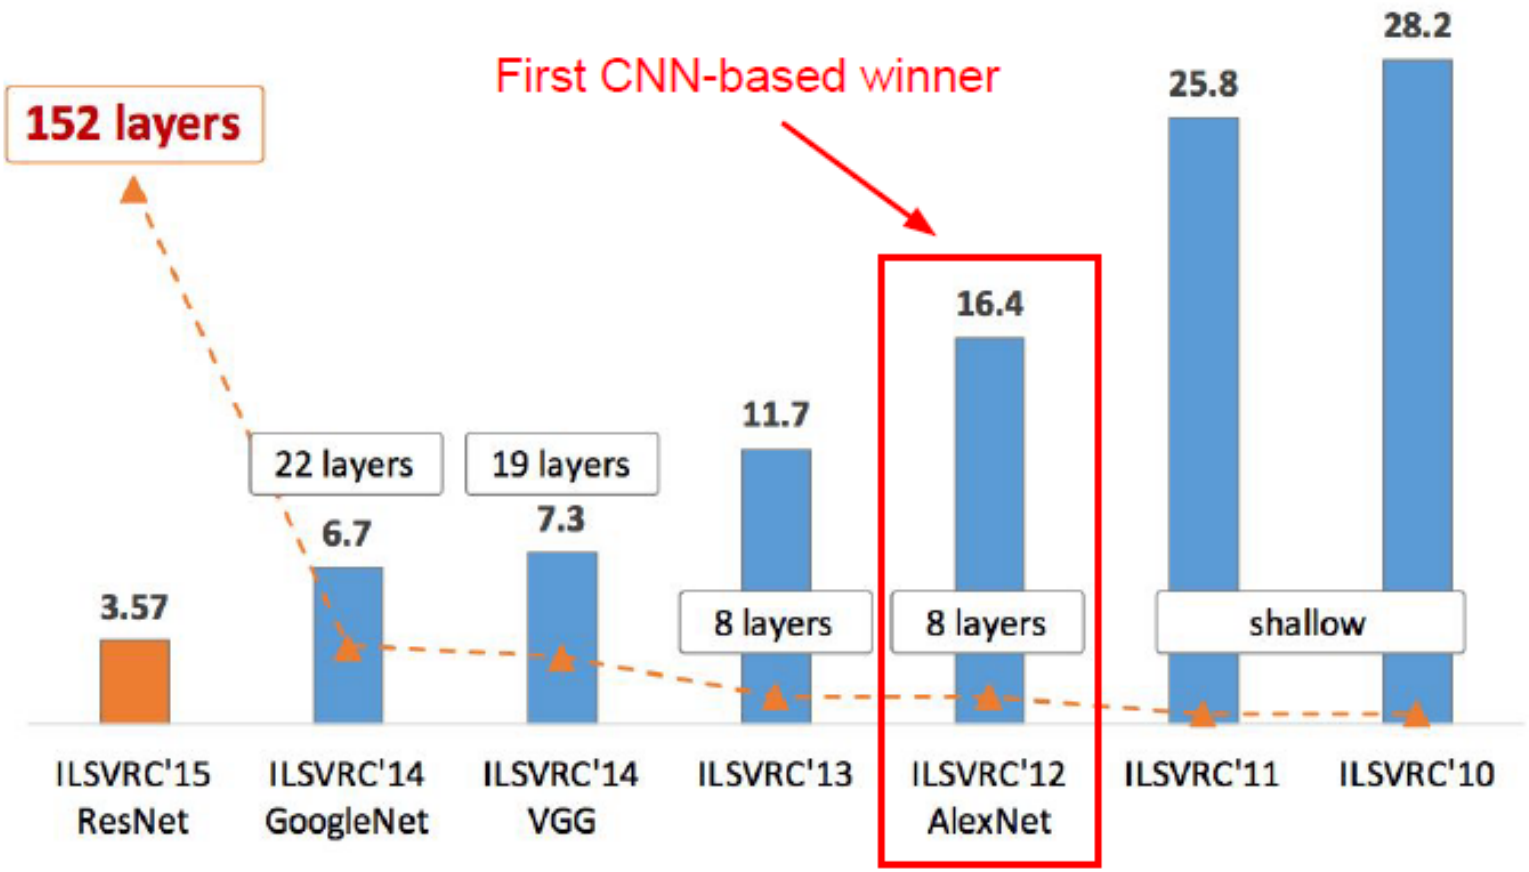

Mạng nơ ron tích chập-Convolutional neural network

Comparing complexity...

Inception-v4: Resnet + Inception!

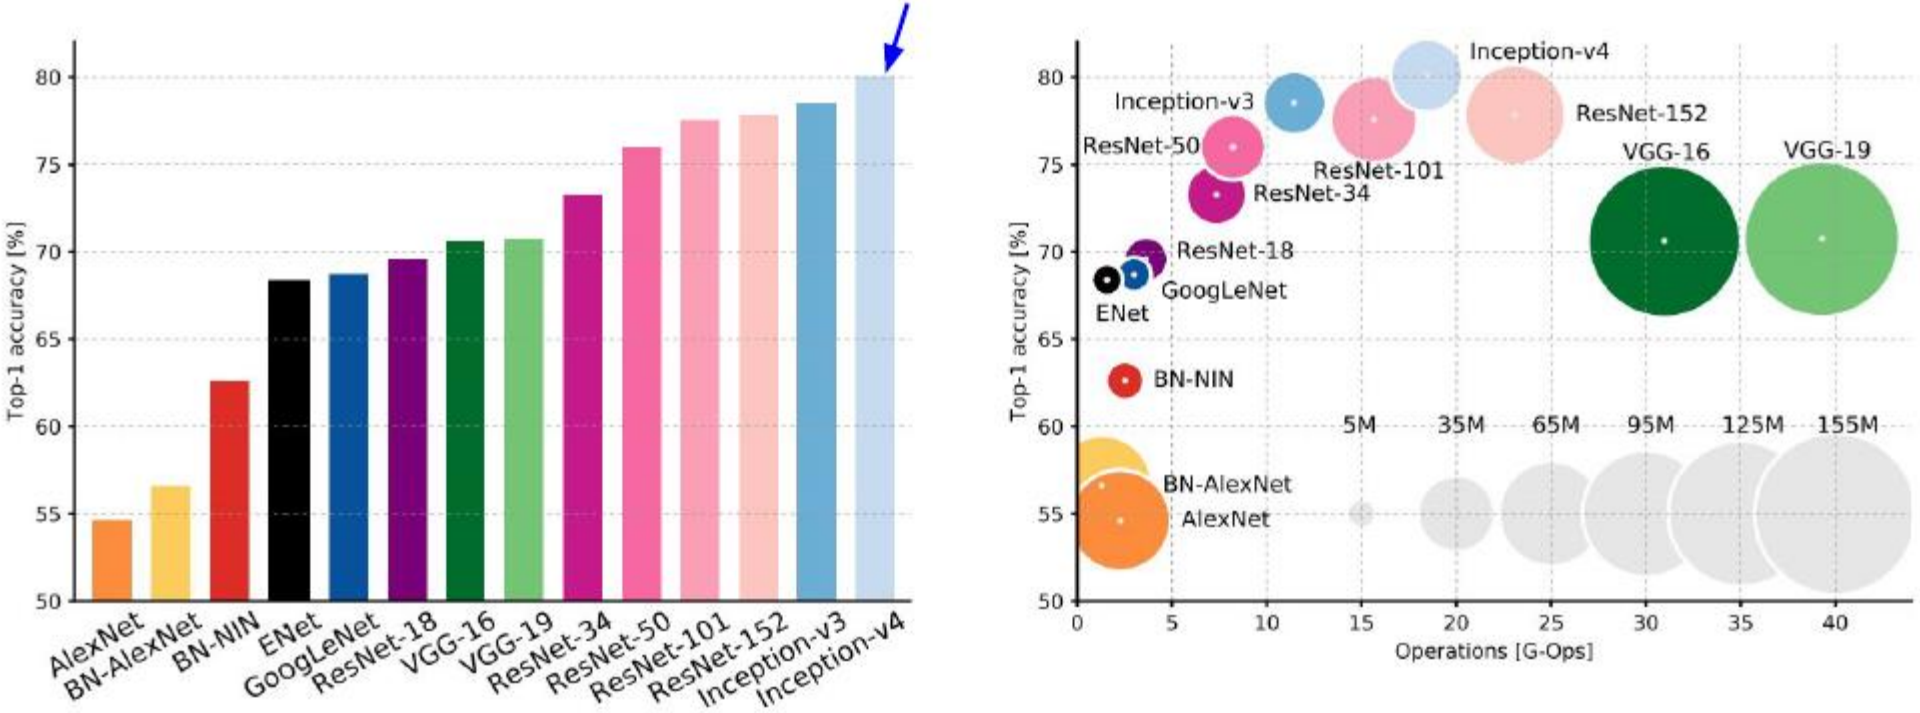

An Analysis of Deep Neural Network Models for Practical Applications, 2017.

Mạng nơ ron tích chập-Convolutional neural network

Các mạng khác

- NiN (Network in Network)
- Wide ResNet
- ResNeXT
- Stochastic Depth
- DenseNet
- FractalNet
- SqueezeNet
- ….

9.2. Phương pháp máy véc tơ hỗ trợ

9.2.1 Giới thiệu

- Phương pháp máy vector hỗ trợ (Support vector machine-SVM): phương pháp học có giám sát.
- Một mô hình SVM là một cách biểu diễn các vector hỗ trợ phân loại trong không gian nhiều chiều và lựa chọn siêu phẳng (hyperplane) phân loại giữa hai lớp sao cho cực đại khoảng cách từ các mẫu dữ liệu huấn luyện (các điểm trong không gian n chiều) tới mặt phẳng phân loại.

9.2.1. Giới thiệu

- Phương pháp phân lớp được sử dụng rộng rãi
- SVM thực hiện hiệu quả trên tập dữ liệu lớn và xử lý hiệu quả trên không gian có số chiều lớn, đặc biệt áp dụng cho các bài toán phân loại dữ liệu hình ảnh, văn bản, và tiếng nói,…
- Thư viện LibSVM là một trong những công cụ được sử dụng khá phổ biến hiện nay.

9.2.2. Phân loại tuyến tính

- Tập dữ liệu huấn luyện S gồm n mẫu $(x_1, y_1),\ldots,(x_n, y_n)$
  - x_i là mẫu dữ liệu được biểu diễn dưới dạng các điểm trong không gian p chiều
  - $y_i \in \{-1\ 1\}$ là nhãn tương ứng để chỉ lớp của mẫu dữ liệu đó
- Mục tiêu: tìm một siêu phẳng có khả năng phân tách tập mẫu thành 2 tập theo nhãn của nó với lề đạt khoảng cách cực đại
  - Lề là khoảng cách từ siêu phẳng đến các điểm (trong p chiều) gần nhất

9.2.2. Phân loại tuyến tính

- Siêu phẳng trong không gian đa chiều có thể được viết dưới dạng
- $w \bullet x - b = 0$
- w là vector pháp tuyến của siêu phẳng
- b/$\| w \|$ được xác định là khoảng cách từ siêu phẳng đến gốc tọa độ theo vector pháp tuyến w.

9.2.2. Phân loại tuyến tính

- Lề cực đại (maximal margin) là khoảng cách lớn nhất từ siêu phẳng đến các điểm gần nhất, nghĩa là khoảng cách xa nhất từ siêu phẳng đến đường thẳng song song với nó đi qua điểm gần nhất, mà không chứa điểm dữ liệu nào bên trong nó
- Các vector hỗ trợ (support vectors) là các điểm dữ liệu gần nhất nằm trên lề cực đại

9.2.2. Phân loại tuyến tính

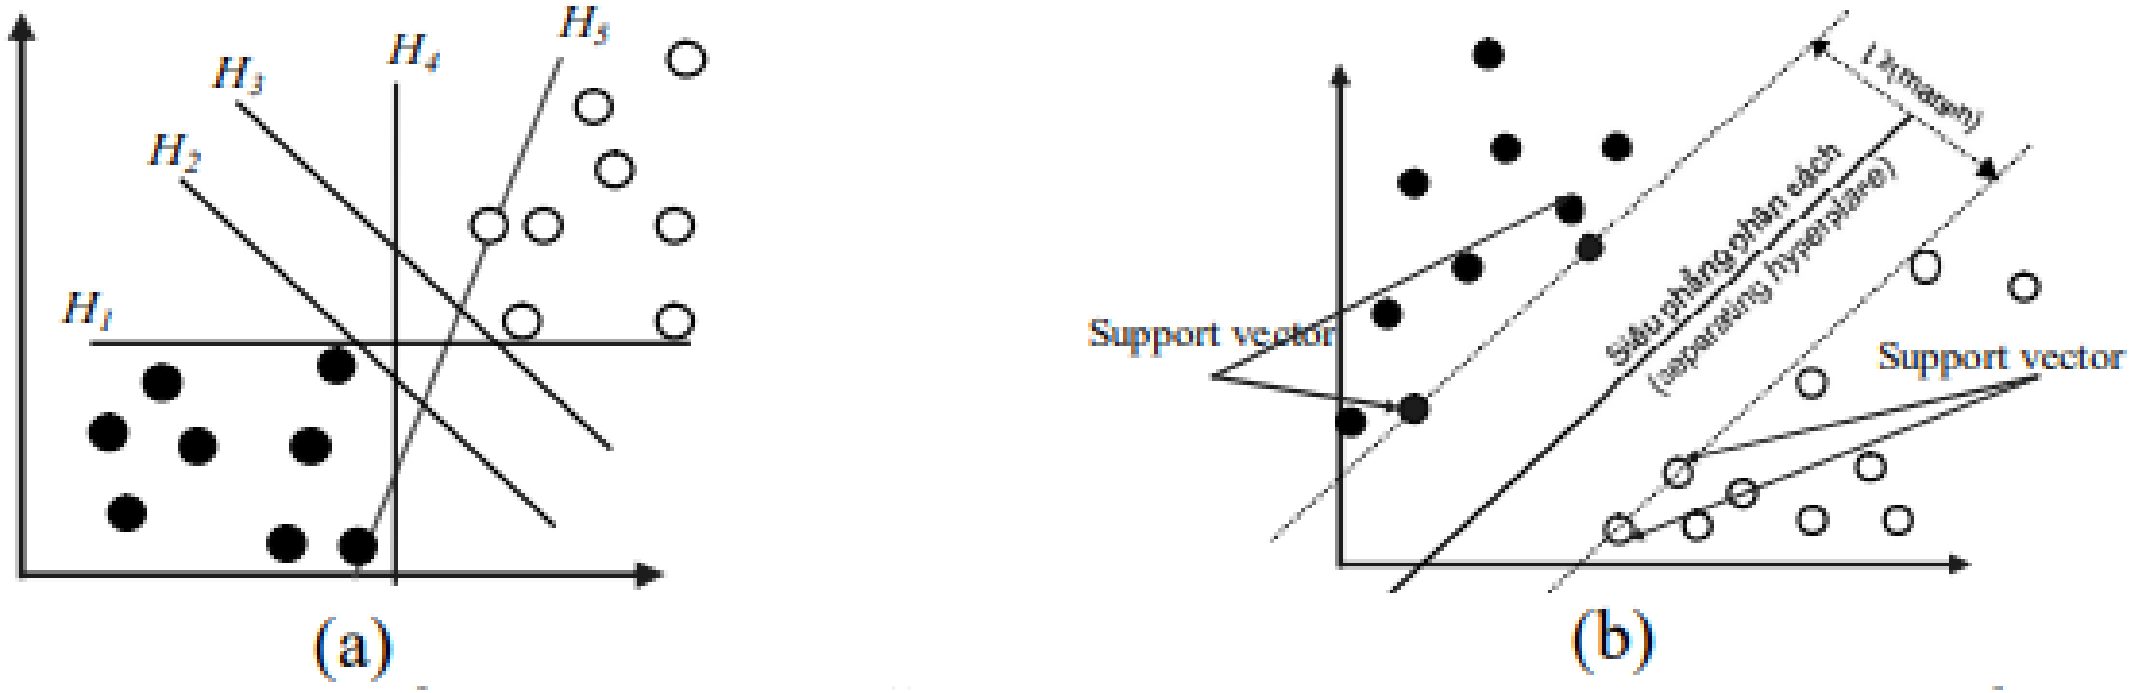

Hình 7.2. Siêu phẳng phân tách mẫu dữ liệu thành 2 lớp: a) các siêu phẳng ứng cử viên; b) lề phân loại và các vector hỗ trợ tìm được

9.2.2. Phân loại tuyến tính

$$w.x_i + b \geq +1 \;\; khi \; y_i = +1$$

$$w.x_i + b \leq -1 \;\; khi \; y_i = -1$$

Kết hợp hai công thức lại ta có :

$$y_i(w.x_i + b) \geq 1 \; với \; i = 1,..,n$$

9.2.2. Phân loại tuyến tính

- Đối với vector hỗ trợ x_i là các điểm nằm trên đường biên giới hạn của siêu phẳng H_+:
  - $w.x_i+b= +1$
  - khoảng cách đến gốc tọa độ là $|1-b|/||w||$
- Các điểm nằm trên đường biên giới hạn của siêu phẳng H_-:
  - $w.x_i+b=-1$
  - khoảng cách đến gốc tọa độ là $|-1-b/||w||$

9.2.2. Phân loại tuyến tính

- Bài toán tối ưu tương đối khó giải vì hàm mục tiêu phụ thuộc vào $||w||$, là một hàm có khai căn
- Có thể thay $||w||$ bằng hàm mục tiêu $\frac{1}{2} ||w||^2$ mà không làm thay đổi lời giải đối với bài toán
- Cực tiểu hóa mục tiêu $\frac{1}{2} ||w||^2$ theo w và b với điều kiện $y_i(w.x_i+b) \geq 1$

9.2.2. Phân loại tuyến tính

- Bằng cách thêm các nhân tử Lagrange α, bài toán trở thành dạng sau:
- $\min_{w,b} \max_{\alpha \geq 0} \left\{ \frac{1}{2} \|w\|^2 - \sum_{i=1}^{n} \alpha_i [y_i (w.x_i - b) - 1] \right\}$

9.2.2. Phân loại tuyến tính

- Sau khi huấn luyện, các mẫu có $\alpha_i > 0$ được gọi là vector hỗ trợ và nằm trên một trong hai siêu phẳng H_+ hoặc H_-. Khi đã xác định được tập vector hỗ trợ phân loại nghĩa là đã thu được mô hình máy phân loại SVM, với mỗi mẫu thử (đánh giá, testing) có thể đơn giản được phân loại theo siêu phẳng H_+ và H_- tạo ra bằng cách dùng hàm dấu theo công thức sau:

- Sign(w.x+b)

9.2.2. Phân loại tuyến tính

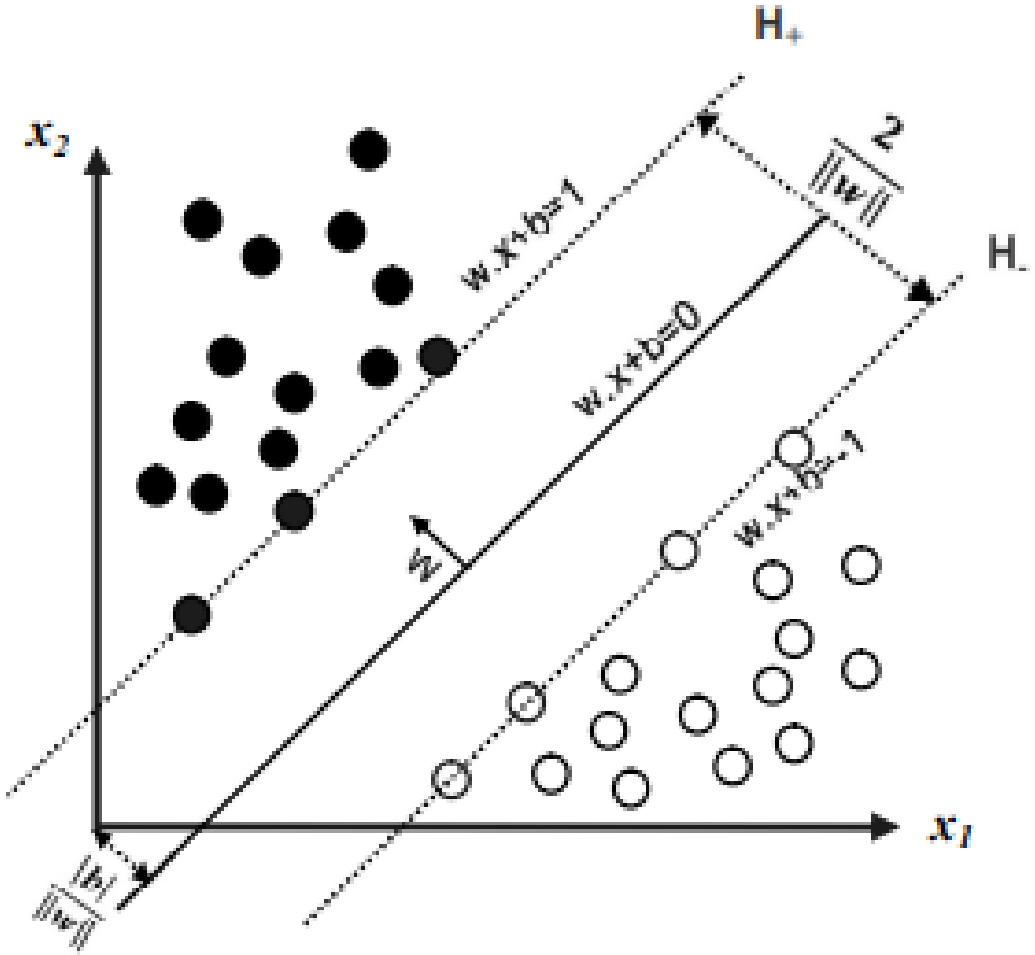

9.2.2. Phân loại tuyến tính

- Theo điều kiện Karush-Kuhn-tucker (KKT):
- $w = \sum_{i=1}^{n} \alpha_i \, y_i x_i$
- Điều kiện KKT được thể hiện như sau:
- $\alpha_i = 0 \leftrightarrow y_i(w.x_i+b) \geq 1$
- $\alpha_i = C \leftrightarrow y_i(w.x_i+b) \leq 1$
- $0 \leq \alpha_i \leq C \leftrightarrow y_i(w.x_i+b) = 1$

9.2.3. Phân loại tuyến tính lề mềm

- Phương pháp lề mềm sử dụng thêm các biến bổ sung ξ_i (xem như giá trị bù cho phần tử sai) nhằm đo độ sai lệch của mẫu bị phân loại sai x_i qua đó giá trị này có tác dụng kéo phần tử x_i về đúng phía nhãn.
- $y_i(w.x_i-b)\geq 1-\xi_i$ với i=1,…,n
- $\min\limits_{w,\xi,b}\left\{\frac{1}{2}\|w\|^2+C\sum_{i=1}^{n}\xi_i\right\}$ $với\ y_i(w.x_i-b)\geq 1-\xi_i,\ \ \xi_i\geq 0$
- $\min\limits_{w,\xi,b}\max\limits_{\alpha,\beta}\left\{\frac{1}{2}\|w\|^2+C\sum_{i=1}^{n}\xi_i-\sum_{i=1}^{n}\alpha_i[y_i(w.x_i-b)-1+\xi_i]-\sum_{i=1}^{n}\beta_i\xi_i\right\}$

9.2.4. Hàm nhân

- Hàm nhân (hay còn gọi là hàm lõi, Kernel function) ký hiệu K là một hàm số trên không gian X, với mọi cặp vector u, v ∈ X, ta có:
- K(u, v) $=\Phi(u)\Phi(v)$
- Với Φ là ánh xạ từ không gian mẫu X tới một không gian thuộc tính F được xác định Φ: $R^d \rightarrow F$
- $f(x) = \sum_{e_i \neq 0} y_i \alpha_i K(x_i, x) + b$

9.2.4. Hàm nhân

- Hàm nhân đa thức trên không gian R^d có dạng:
- $K(u, v) = (u.v)^p$
- Hàm nhân RBF: Hàm cơ sở bán kính là một hàm giá trị thực mà giá trị của nó chỉ phụ thuộc vào khoảng cách từ gốc tọa độ, sao cho thỏa mãn điều kiện $\Phi(x) = \Phi(||x||)$.
- Có một số dạng hàm RBF như hàm mũ $K(u, v) = e^{-\|u-v\|^2/2\sigma^2}$ với σ thường được gọi là độ rộng của hàm hay giá trị độ lệch chuẩn

9.2.5. Tuyến tính hóa phân loại phi tuyến

- Thực hiện ánh xạ vector đặc trưng phi tuyến vào không gian nhiều chiều hơn để có thể tuyến tính hóa rồi dùng phân loại tuyến tính trong không gian mới này
- $\Phi: R^d \rightarrow F$
- Đối với một vector đặc trưng ban đầu $x \in R^d$ và vector đặc trưng đã biến đổi được xác định theo hàm biến đổi $\Phi(x)$ với nhãn của nó vẫn giữ nguyên
- Mẫu huấn luyện ban đầu được biến đổi thành $(\Phi(x1),y1),\ldots,(\Phi(x_n),y_n)$

9.2.5. Tuyến tính hóa phân loại phi tuyến

- Phân loại phi tuyến thực hiện bằng cách biến đổi qua một không gian khác để có thể tuyến tính hóa phân loại

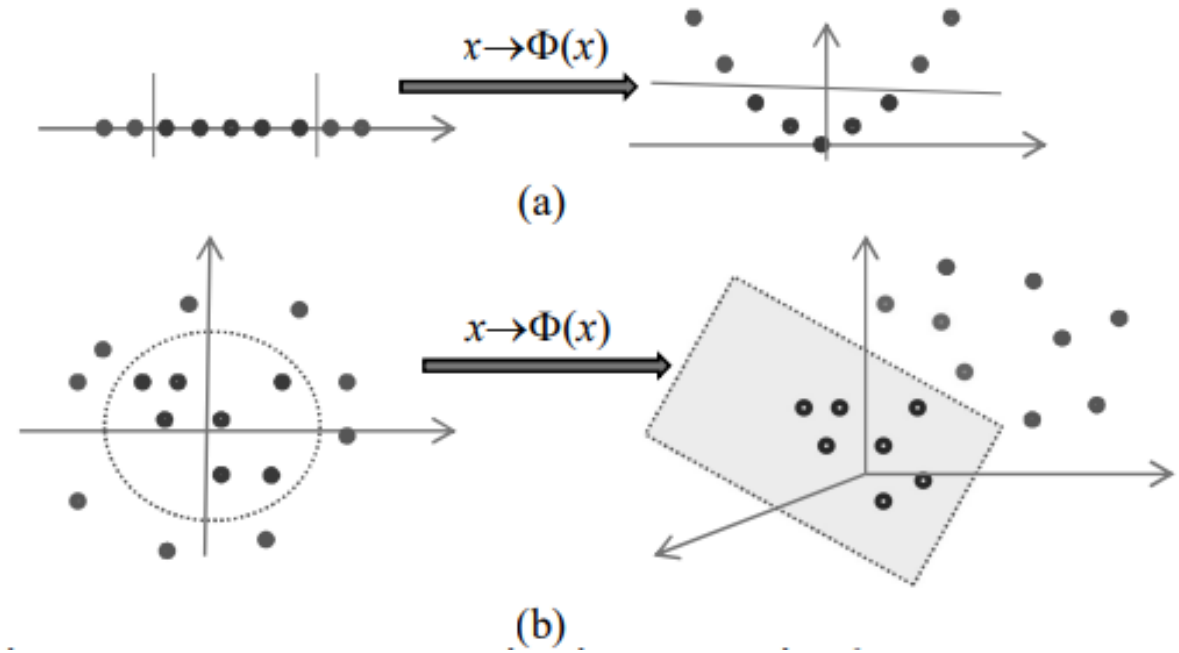

9.3 Các độ đo hệ thống

- Chúng ta cần một phép đánh giá để xem mô hình sử dụng có hiệu quả không và để so sánh khả năng của các mô hình.

1. Accuracy (độ chính xác):

- Acc = Số mẫu nhận dạng đúng/Tổng số mẫu nhận dạng
- Y_true = [0, 0, 0, 0, 1, 1, 1, 2, 2, 2]
- Y_pred = [0, 1, 0, 2, 1, 1, 0, 2, 1, 2]
- Độ chính xác =6/10=0.6 (60%)

Confusion matrix (Ma trận nhầm lẫn)

Y_true = [0, 0, 0, 0, 1, 1, 1, 2, 2, 2]
Y_pred = [0, 1, 0, 2, 1, 1, 0, 2, 1, 2]

		Predict			
		0	1	2	Tổng
True label	0	2	1	1	4
	1	1	2	0	3
	2	0	1	2	3

- Confusion matrix thể hiện có bao nhiêu điểm dữ liệu *thực sự* thuộc vào một class, và được *dự đoán* là rơi vào một class.

normalized confusion matrix, ta lấy mỗi hàng của *unnormalized confusion matrix* sẽ được chia cho tổng các phần tử trên hàng đó.

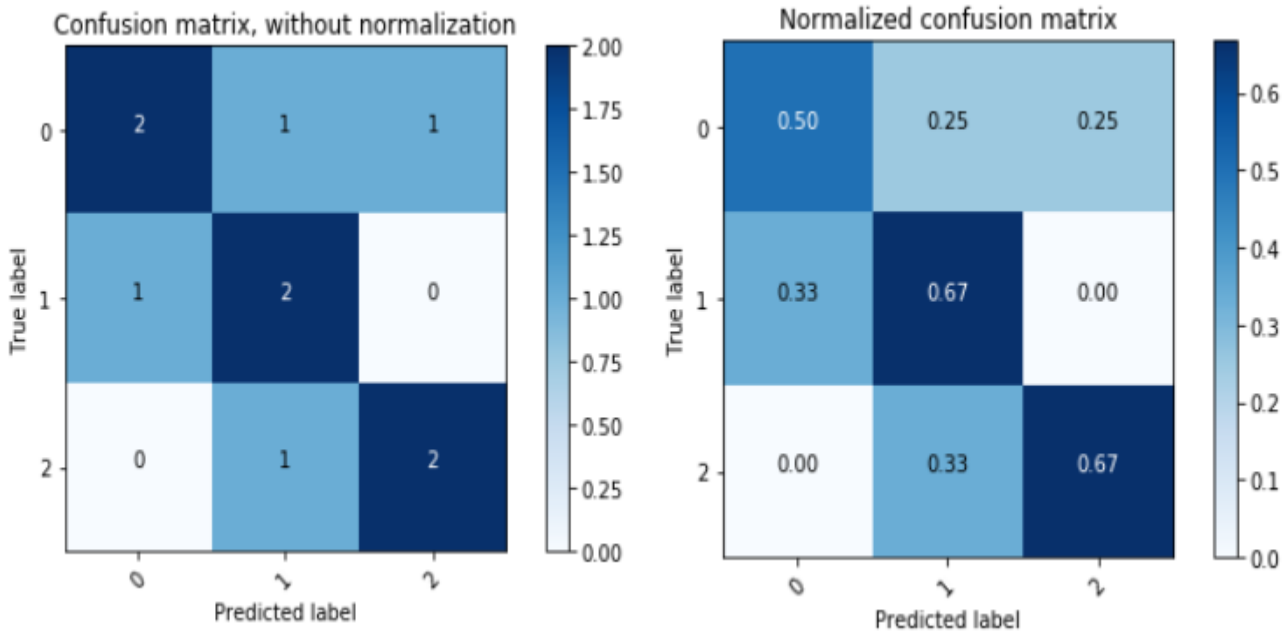

True/False Positive/Negative

- Cách đánh giá này thường được áp dụng cho các bài toán phân lớp có hai lớp dữ liệu. Cụ thể hơn, trong hai lớp dữ liệu này có một lớp quan *trọng* hơn lớp kia và cần được dự đoán chính xác.
- Ví dụ, trong bài toán xác định có bệnh ung thư hay không thì việc không bị *sót* (miss) quan trọng hơn là việc chẩn đoán nhầm *âm tính* thành *dương tính*.
- Trong bài toán xác định có mìn dưới lòng đất hay không thì việc *bỏ sót* nghiêm trọng hơn việc *báo động nhầm* rất nhiều.
- Trong bài toán lọc email rác thì việc cho nhầm email quan trọng vào thùng rác nghiêm trọng hơn việc xác định một email rác là email thường.

True/False Positive/Negative

- Định nghĩa lớp dữ liệu *quan trọng* hơn cần được xác định đúng là lớp *Positive* (P-dương tính), lớp còn lại được gọi là *Negative* (N-âm tính).
- True Positive (TP): số lượng điểm của lớp *positive* được phân loại đúng là *positive*.
- True Negative (TN): số lượng điểm của lớp *negative* được phân loại đúng là *negative*.
- False Positive (FP): số lượng điểm của lớp *negative* bị phân loại nhầm thành *positive*.
- False Negative (FN): số lượng điểm của lớp *positive* bị phân loại nhầm thành *negative*

		Predicted	
		Positive	Negative
Actual	Positive	TP	FN
	Negative	FP	TN

True/False Positive/Negative

- **Với các bài toán có nhiều lớp dữ liệu**, ta có thể xây dựng bảng True/False Positive/Negative cho **mỗi lớp** nếu coi lớp đó là lớp *Positive*, các lớp còn lại gộp chung thành lớp *Negative*, giống như cách làm trong one-vs-rest.

		Predicted		
		cat	dog	rabbit
Actual	Cat	5	3	0
	Dog	2	3	1
	rabbit	0	2	11

		Predicted	
		Cat	Non-cat
Actual	Cat	5 TP	3 FN
	Non-cat	2 FP	17 TN

Precision và recall

- Với bài toán phân loại mà tập dữ liệu của các lớp là chênh lệch nhau rất nhiều, có một phép hiệu quả thường được sử dụng là Precision-Recall.
- Trước hết xét bài toán phân loại nhị phân. Ta cũng coi một trong hai lớp là *positive*, lớp còn lại là *negative*.
- Với một cách xác định một lớp là *positive*, **Precision** được định nghĩa là tỉ lệ số điểm **true positive** trong số những điểm **được phân loại là *positive*** (TP + FP).
- **Recall** được định nghĩa là tỉ lệ số điểm **true positive** trong số những điểm thực sự **là *positive*** (TP + FN).

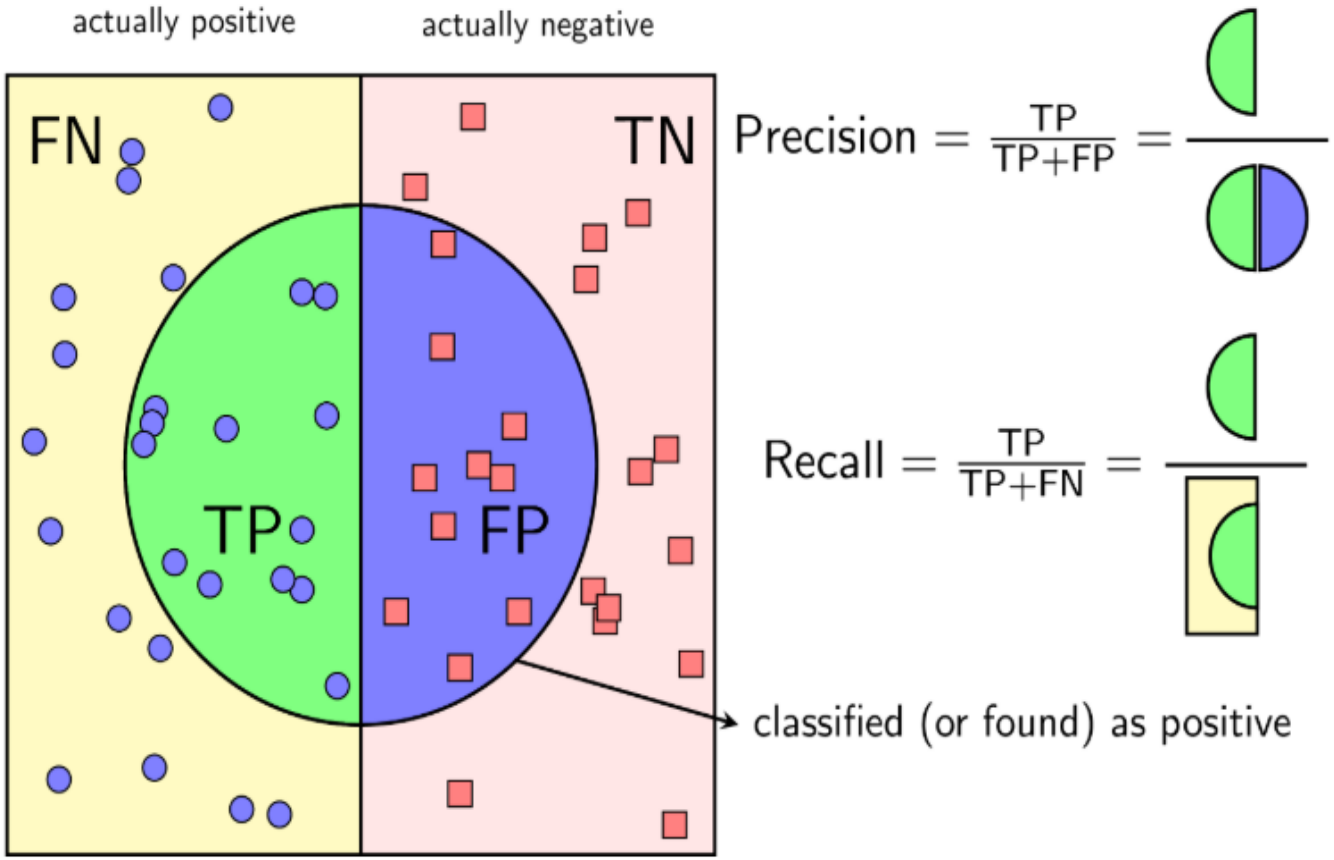

Precision và recall

- Precision cao đồng nghĩa với việc độ chính xác của các điểm tìm được là cao.
- Recall cao đồng nghĩa với việc True Positive Rate cao, tức tỉ lệ bỏ sót các điểm thực sự *positive* là thấp.
- Khi Precision = 1, mọi điểm tìm được đều thực sự là *positive*, tức không có điểm *negative* nào lẫn vào kết quả.
- Tuy nhiên, Precision = 1 không đảm bảo mô hình là tốt, vì câu hỏi đặt ra là liệu mô hình đã tìm được tất cả các điểm *positive* hay chưa. Nếu một mô hình chỉ tìm được đúng một điểm *positive* mà nó chắc chắn nhất thì ta không thể gọi nó là một mô hình tốt.

Precision và recall

- Khi Recall = 1, mọi điểm *positive* đều được tìm thấy. Tuy nhiên, đại lượng này lại không đo liệu có bao nhiêu điểm *negative* bị lẫn trong đó. Nếu mô hình phân loại mọi điểm là *positive* thì chắc chắn Recall = 1.
- Một mô hình phân lớp tốt là mô hình có cả Precision và Recall đều cao, tức càng gần một càng tốt.

F1-score

$$\frac{2}{F_1} = \frac{1}{\text{precision}} + \frac{1}{\text{recall}} \text{ hay } F_1 = 2\frac{1}{\frac{1}{\text{precision}} + \frac{1}{\text{recall}}} = 2\frac{\text{precion} \cdot recall}{\text{precision} + \text{recall}}$$

F1 score có giá trị nằm trong nửa khoảng (0,1]. F1 càng cao, bộ phân lớp càng tốt. Khi cả recall và precision đều bằng 1 (tốt nhất có thể), F1=1.

precision	recall	F_1
1	1	1
0.1	0.1	0.1
0.5	0.5	0.5
1	0.1	0.182
0.3	0.8	0.36

Như vậy, một bộ phân lớp với precision = recall = 0.5 tốt hơn một bộ phân lớp khác với precision = 0.3, recall = 0.8 theo cách đo này.

Bài tập 1

- Y_true = [0, 0, 0, 1, 1, 1, 1, 2, 2, 2, 3, 3, 3, 3, 4, 5, 5, 5, 5, 5]
- Y_pred = [5, 0, 0, 2, 3, 4, 1, 0, 2, 2, 0, 3, 2, 3, 4, 0, 1, 5, 5, 1]
- Tính accuracy và confusion matrix
- Đưa về dạng confusion matrix với 0: positive, khác 0 là negative
- Tính precision và recall với lớp 0
- Tính độ đo F1

- Accuracy=10/20=50%
- Confusion matrix

		Predict					
		0	1	2	3	4	5
True label	0	2	0	0	0	0	1
	1	0	1	1	1	1	0
	2	1	0	2	0	0	0
	3	1	0	1	2	0	0
	4	0	0	0	0	1	0
	5	1	2	0	0	0	2

- confusion matrix với 0: positive, khác 0 là negative

		Predict	
		0	Khác 0
True label	0	2	1
	Khác 0	3	14

- Precision= 2/(2+3)=2/5=0.4
- Recall=2/(2+1)=2/3=0.67
- F1=2x0.4x0.67/(0.4+0.67)=0.5

Cám ơn đã chú ý lắng nghe!